

De 8 PMU a estimación global y localización multi-evento

Teoría unificada Hybrid-DAE Bayesiana, evidencia experimental actual y programa de validación
ANDES + pandapower para IEEE 39-bus

Documento técnico de trabajo – PMU Fault Detection

10 de septiembre de 2026

Resumen

Este documento consolida el razonamiento, el modelo físico, la inferencia Bayesiana, el tratamiento de múltiples eventos, la incertidumbre de modelo, el papel de machine learning y la batería de validación necesaria para convertir el prototipo de detección/localización de eventos PMU en un estimador físico-recursivo defendible científicamente. El caso de estudio mantiene únicamente ocho PMU observadas en el IEEE 39-bus, en los buses {2, 5, 6, 10, 19, 22, 29, 39}, y busca reconstruir estados/PMU virtuales en los 31 buses restantes mientras infiere cero, uno o múltiples cambios físicos de configuración. El objetivo no es presentar un “clasificador mejor”, sino derivar una aproximación recursiva al posterior $p(X, \Theta, Q, S, C | Y_{\mathcal{P}})$, donde X son estados dinámicos y algebraicos, Θ parámetros inciertos, Q configuración física, S saltos sparse y C discrepancia de modelo. Se incluyen resultados de las campañas Python Phase-0 a Phase-2V, sus fallos, la interpretación de esos fallos y un plan completo de validación con ANDES como simulador dinámico y pandapower como verificación AC independiente.

Tesis central del documento. La pregunta correcta no es si “8 PMU pueden medir 39 buses instantáneamente”, sino si la historia temporal de las ocho PMU, restringida por las ecuaciones DAE de la red, contiene suficiente información para reconstruir los funcionales eléctricos ocultos y distinguir los cambios de configuración físicamente admisibles. El estado, el evento, su severidad y la incertidumbre deben surgir del mismo modelo generativo.

Índice

1. Qué problema estamos resolviendo realmente	4
1.1. Contrato experimental del SGSMA 2026	4
1.2. Input, estado, configuración y output	4
2. Partir de las ecuaciones eléctricas, no del algoritmo	4
2.1. Red AC completa	4
2.2. Corriente de terminal de rama	5
2.3. KCL como restricción algebraica central	5
3. Dinámica de generación síncrona, control y cargas	5
3.1. Swing equation como núcleo mínimo	5
3.2. Modelo electromagnético de mayor orden	5
3.3. AVR y gobernador	6
3.4. Cargas ZIP/dinámicas	6
4. IBR: GFL y GFM dentro de la misma DAE	6
4.1. GFL con PLL	6
4.2. GFM/VSG	6
5. Modelo híbrido unificado	7
5.1. DAE generativa	7
5.2. Configuración física	7

5.3. Evento como salto de configuración	7
6. Measurement model de PMU	7
6.1. Representación interna	7
6.2. Frecuencia y ROCOF	7
6.3. Sesgos instrumentales	8
7. De la física al estimador: derivación, no ensamblaje	8
7.1. Posterior objetivo	8
7.2. Caso lineal-gaussiano: aparece Kalman	8
7.3. Por qué aparece un horizonte	8
7.4. Fixed-lag MAP	8
7.5. Iteración Gauss–Newton/Laplace	9
7.6. Marginalización de estados antiguos	9
8. Varios eventos: pasar de una categoría a un conjunto aleatorio	9
8.1. Por qué el softmax de una causa es matemáticamente incorrecto	9
8.2. Marked point process	9
8.3. Likelihood de un soporte	10
8.4. Exacto para 0/1/2; escalable para 3+	10
9. Modelo incorrecto no debe convertirse en un evento falso	10
9.1. El fallo que descubrió Phase-2M	10
9.2. Separación de cuatro fuentes de residual	10
9.3. Discrepancia Gauss–Markov normal	10
9.4. Discrepancia condicionada al evento mediante ensemble físico	11
9.5. Posterior preevento sobre el modelo	11
10. Probabilidades honestas: calibración, no scores	11
10.1. Evidencia marginal y Woodbury	11
10.2. Métricas de calibración	11
11. Identificabilidad y distinguibilidad	11
11.1. Eliminar nuisance state	11
11.2. Métricas estructurales	12
12. Papel de machine learning: extensión natural, no sustitución	12
12.1. Qué no debe aprender ML	12
12.2. Primera extensión: likelihood/discrepancy	12
12.3. Segunda extensión: dinámica residual	12
12.4. Tercera extensión opcional: correction de log-evidence	12
13. Evidencia experimental acumulada hasta Phase-2V	12
13.1. Lectura correcta de los experimentos	12
13.2. Resultados Phase-2V clave	13
13.3. Frontera de severidad	13

13.4. Model mismatch fuera de distribución	14
13.5. Pares simultáneos	15
13.6. Pérdida de dos PMU	15
14. Qué ya consideramos hipótesis respaldadas y qué no	15
15. Arquitectura final propuesta	16
16. Programa ANDES + pandapower: por qué ambos	16
17. Batería completa de experimentos	16
18. Diseño de escenarios y randomización	17
18.1. Operating points	17
18.2. Dinámica	17
18.3. Eventos	18
18.4. Noise/integrity	18
19. Métricas de reconstrucción, eventos y causalidad	18
19.1. Estado / PMU virtual	18
19.2. Conjunto de eventos	18
19.3. Reconfigure-and-verify	18
20. Gates de investigación y reglas de no autoengaño	19
21. Escala de Monte Carlo recomendada	19
22. Comparación que debe decidir si el nuevo método vale la pena	19
23. Novedad científica: qué sí y qué no	19
24. Roadmap de implementación inmediato	20
24.1. Bloque A: no negociable	20
24.2. Bloque B: estado	20
24.3. Bloque C: eventos	20
24.4. Bloque D: batería	20
24.5. Bloque E: external holdout	20
25. Criterio para considerar que el método “funciona”	20
A. Prompt maestro para Claude Code / Codex	20
B. Notas de implementación ANDES y pandapower	33
C. Bibliografía mínima	33

1. Qué problema estamos resolviendo realmente

1.1. Contrato experimental del SGSMA 2026

El documento oficial de la competencia describe un IEEE 39-bus con ocho PMU y tareas de detección, clasificación y localización. La ubicación exacta indicada es PMU1–PMU8 en los buses 39, 29, 10, 22, 19, 2, 5 y 6, respectivamente, sobre base de 100 MVA y frecuencia nominal de 60 Hz [1]. Cada archivo de PMU contiene fasores trifásicos de tensión y corriente, frecuencia, ROCOF, una máscara `DATA_PRESENT` y una etiqueta de evento para entrenamiento/evaluación [1]. La guía además contempla fallas, outages, cambios de generación/carga, missing/bad data y eventos concurrentes.

En la formulación final ordenamos el conjunto observado como

$$\mathcal{P} = \{2, 5, 6, 10, 19, 22, 29, 39\}, \quad |\mathcal{P}| = 8,$$

y el conjunto no instrumentado como

$$\mathcal{U} = \{1, \dots, 39\} \setminus \mathcal{P}, \quad |\mathcal{U}| = 31.$$

1.2. Input, estado, configuración y output

Queremos que las entradas del estimador sean exclusivamente señales accesibles en operación:

$$Y_{\mathcal{P},1:k} = \{y_{p,t} : p \in \mathcal{P}, t \leq k\},$$

además de metadata eléctrica conocida o estimada previamente (topología nominal, parámetros, modelos de dispositivo y calidad de medida). El estimador no recibe el verdadero estado interno ni la etiqueta del evento.

Separaremos las variables en cinco clases:

$$x(t) : \text{estados dinámicos de máquinas/controladores/conversores}, \quad (1)$$

$$z(t) : \text{variables algebraicas de red, especialmente } V_i, \quad (2)$$

$$\theta(t) : \text{parámetros físicos inciertos que varían lentamente}, \quad (3)$$

$$q(t) : \text{configuración física actual}, \quad (4)$$

$$s_k = q_k - q_{k-1} : \text{saltos físicos raros y sparse}. \quad (5)$$

Además, introduciremos c_k como estado latente de discrepancia de modelo y b_k para sesgos instrumentales lentos.

El output deseado tiene dos capas. La primera es de reconstrucción:

$$\hat{y}_{\mathcal{U},k} = h_{\mathcal{U}}(\hat{x}_k, \hat{z}_k),$$

que produce PMU virtuales/estados eléctricos en los 31 buses ocultos. La segunda es de causalidad física:

$$P(M_k = m \mid Y), \quad P(b_{g,k} = 1 \mid Y), \quad p(a_{g,k} \mid b_{g,k} = 1, Y),$$

donde M_k es el número de eventos activos, g identifica una fuente física y a_g su magnitud.

2. Partir de las ecuaciones eléctricas, no del algoritmo

2.1. Red AC completa

Sea

$$V = [V_1, \dots, V_N]^\top \in \mathbb{C}^N, \quad V_i = |V_i|e^{j\vartheta_i}.$$

La ecuación nodal es

$$\boxed{I = Y_{\text{bus}}(q, \theta)V} \quad (6)$$

y la potencia compleja inyectada en el bus i :

$$\boxed{S_i = P_i + jQ_i = V_i I_i^*}. \quad (7)$$

Escribiendo $Y_{ij} = G_{ij} + jB_{ij}$ y $\vartheta_{ij} = \vartheta_i - \vartheta_j$:

$$P_i = |V_i| \sum_j |V_j| [G_{ij} \cos \vartheta_{ij} + B_{ij} \sin \vartheta_{ij}], \quad (8)$$

$$Q_i = |V_i| \sum_j |V_j| [G_{ij} \sin \vartheta_{ij} - B_{ij} \cos \vartheta_{ij}]. \quad (9)$$

La relación power-angle clásica aparece como aproximación para una rama fuertemente inductiva:

$$P_{ij} \approx \frac{|V_i||V_j|}{X_{ij}} \sin(\vartheta_i - \vartheta_j). \quad (10)$$

El estimador final no debe usar esta aproximación cuando dispone de (6)–(9); sirve para intuición y para los primeros prototipos.

2.2. Corriente de terminal de rama

Una PMU no mide una “corriente abstracta del bus”. Si el canal de corriente corresponde al terminal $i \rightarrow j$ de una rama, el modelo π produce

$$I_{ij} = Y_{ff}^{ij} V_i + Y_{ft}^{ij} V_j, \quad (11)$$

$$I_{ji} = Y_{tf}^{ij} V_i + Y_{tt}^{ij} V_j. \quad (12)$$

La orientación de terminal, taps y signos debe considerarse parte del operador de medida. Nuestros trabajos anteriores mostraron que una convención incorrecta de corriente puede producir buen resultado in-domain y mala transferencia. Por ello la batería futura contiene un gate específico de medición antes de ejecutar cualquier benchmark de localización.

2.3. KCL como restricción algebraica central

La forma más compacta del sistema completo es

$$\boxed{0 = I_{SG}(x_{SG}, V) + I_{IBR}(x_{IBR}, V) - I_L(V, x_L) - Y(q, \theta)V.} \quad (13)$$

Esta ecuación es el corazón del componente algebraico $g(x, z, q, \theta) = 0$. No debe convertirse en una feature ni en una penalización neural opcional: si el modelo de dispositivo es conocido, KCL se impone físicamente.

3. Dinámica de generación síncrona, control y cargas

3.1. Swing equation como núcleo mínimo

Para una máquina síncrona g :

$$\dot{\delta}_g = \omega_b \Delta \omega_g, \quad (14)$$

$$M_g \dot{\Delta \omega}_g = P_{m,g} - P_{e,g} - D_g \Delta \omega_g. \quad (15)$$

La potencia eléctrica no es una entrada independiente:

$$P_{e,g} = \Re\{V_g I_g^*\}.$$

En un modelo clásico puede aproximarse por

$$P_e \simeq \frac{E'_g |V_g|}{X'_d} \sin(\delta_g - \vartheta_g).$$

3.2. Modelo electromagnético de mayor orden

Para una representación transitoria/subtransitoria, el estado de máquina puede incluir E'_q, E'_d, E''_q, E''_d , rotor y velocidad. Una forma ilustrativa de cuarto orden es

$$T'_{do} \dot{E}'_q = E_{fd} - E'_q - (X_d - X'_d) I_d, \quad (16)$$

$$T'_{qo} \dot{E}'_d = -E'_d + (X_q - X'_q) I_q. \quad (17)$$

Para el benchmark final se prefiere usar el modelo dinámico que ya provea el caso ANDES, por ejemplo GENROU si está disponible, en lugar de reimplementar ecuaciones incompletas. ANDES dispone de modelos de generador síncrono y de una formulación DAE simbólico-numérica [6, 7].

3.3. AVR y governor

Un AVR conceptual de primer orden puede escribirse

$$T_A \dot{E}_{fd} = -E_{fd} + K_A(V_{ref} - |V_t|),$$

y un governor simple:

$$T_g \dot{P}_m = -P_m + P_{ref} - \frac{1}{R_g} \Delta\omega.$$

En ANDES la implementación debe usar controladores existentes y modificar el target dinámico correcto. La documentación reciente enfatiza que, cuando una máquina dinámica reemplaza una generación estática, cambios de potencia deben realizarse sobre referencias del governor en lugar de escribir un valor estático inactivo; análogamente, si una carga dinámica ZIP/FLoad reemplaza la PQ estática, debe modificarse el setpoint del modelo dinámico [9].

3.4. Cargas ZIP/dinámicas

Una carga ZIP puede escribirse como

$$P(V) = P_0 [a_Z(V/V_0)^2 + a_I(V/V_0) + a_P], \quad (18)$$

$$Q(V) = Q_0 [b_Z(V/V_0)^2 + b_I(V/V_0) + b_P], \quad (19)$$

con coeficientes que suman uno por canal. En la validación deben existir tanto cargas PQ como ZIP/FLoad para evitar que la diferencia GEN/LOAD sea artificialmente fácil o imposible por un único modelo de inyección.

4. IBR: GFL y GFM dentro de la misma DAE

4.1. GFL con PLL

Para un convertidor grid-following en marco dq , un bloque PLL simplificado puede escribirse

$$\dot{\xi}_{PLL} = v_q, \quad (20)$$

$$\omega_{PLL} = \omega_0 + K_p^{PLL} v_q + K_i^{PLL} \xi_{PLL}, \quad (21)$$

$$\dot{\theta}_{PLL} = \omega_{PLL}. \quad (22)$$

El filtro de corriente sigue, esquemáticamente,

$$L_f \dot{i}_d = v_{cd} - v_d - R_f i_d + \omega_{PLL} L_f i_q, \quad (23)$$

$$L_f \dot{i}_q = v_{cq} - v_q - R_f i_q - \omega_{PLL} L_f i_d, \quad (24)$$

y

$$P = \frac{3}{2}(v_d i_d + v_q i_q), \quad (25)$$

$$Q = \frac{3}{2}(v_q i_d - v_d i_q). \quad (26)$$

En ANDES deben preferirse los modelos renovables/converter disponibles en la versión instalada. La documentación actual incluye REGC/REGCP1 con PLL y modelos de planta/electrical control, además de modelos de converter grid-forming/VSG como REGCV1 [10].

4.2. GFM/VSG

Un modelo grid-forming simplificado de tipo VSG puede contener

$$\dot{\theta}_c = \omega_c, \quad (27)$$

$$M_v \dot{\omega}_c = P^* - P - D_v(\omega_c - \omega_0), \quad (28)$$

$$\tau_E \dot{E} = E^* - E - k_Q(Q - Q^*). \quad (29)$$

En el estudio final no se declarará “IBR” por el mero hecho de reducir M . Se ejecutarán escenarios GFL/GFM explícitos o, si la librería/caso no permite inicializarlos con estabilidad, se documentará la limitación como tal.

5. Modelo híbrido unificado

5.1. DAE generativa

La planta completa queda

$$\dot{x} = f(x, z, u, q, \theta) + w_x, \quad (30)$$

$$0 = g(x, z, u, q, \theta), \quad (31)$$

$$y_{\mathcal{P}} = h_{\mathcal{P}}(x, z, b) + v. \quad (32)$$

Aquí z incluye al menos la representación real de los voltajes complejos nodales, y x agrupa los estados de dispositivos. La variable u contiene órdenes conocidas. La variable q representa aquello que define qué sistema físico existe en ese instante.

5.2. Configuración física

Proponemos, a nivel conceptual,

$$q = \begin{bmatrix} \sigma^{line} \\ y^{fault} \\ P_G, Q_G \\ P_L, Q_L \\ m^{IBR} \end{bmatrix}.$$

Una rama ℓ tiene $\sigma_{\ell} \in \{0, 1\}$. Una falla shunt en bus i modifica

$$Y_{bus} \leftarrow Y_{bus} + y_i^F e_i e_i^{\top}.$$

Un cambio de generación/carga modifica la inyección o setpoint dinámico correspondiente.

5.3. Evento como salto de configuración

La definición clave es

$$q_k = q_{k-1} + s_k. \quad (33)$$

Normalmente $s_k = 0$. Un evento es $s_k \neq 0$. Su estructura natural es group-sparse:

$$\|s_k\|_{0,\mathcal{G}} \ll n_q.$$

Esto no es una regularización escogida por conveniencia: expresa que en un instante normal no cambian simultáneamente decenas de activos independientes.

6. Measurement model de PMU

6.1. Representación interna

Aunque el dataset oficial exporte magnitud/ángulo de fases A/B/C, para inferencia numérica es conveniente trabajar en coordenadas cartesianas del fasor positivo:

$$y_p = [\Re V_p, \Im V_p, \Re I_{p\ell}, \Im I_{p\ell}, f_p, \text{ROCOF}_p]^{\top}.$$

El conjunto completo observado es la concatenación de ocho PMU.

6.2. Frecuencia y ROCOF

Idealmente, con $V_i = \rho_i e^{j\vartheta_i}$,

$$f_i = f_0 + \frac{1}{2\pi} \dot{\vartheta}_i, \quad \text{ROCOF}_i = \frac{1}{2\pi} \ddot{\vartheta}_i.$$

Sin embargo, un PMU real obtiene frecuencia/ROCOF mediante un operador temporal. Por ello la forma correcta es

$$f^{PMU} = \mathcal{H}_f[\vartheta], \quad \text{ROCOF}^{PMU} = \mathcal{H}_r[\vartheta].$$

ANDES dispone de modelos de frecuencia/ROCOF y PMU que deben preferirse o, como mínimo, usarse para validar el operador implementado [11].

6.3. Sesgos instrumentales

Se modelan estados lentos

$$b_{k+1} = b_k + \eta_k^b$$

que pueden representar sesgo de fase, gain de tensión/corriente, frequency bias y clock bias. Esto es análogo al tratamiento de biases de sensores en navegación inercial, pero aquí la corrección se propaga a través de la red eléctrica.

7. De la física al estimador: derivación, no ensamblaje

7.1. Posterior objetivo

Dados (30)–(33), la pregunta óptima es inferir

$$p(X_{0:k}, Z_{0:k}, Q_{0:k}, S_{1:k}, \Theta, B, C \mid Y_{\mathcal{P}, 1:k}). \quad (34)$$

No se escoge primero EKF, MHE o LASSO. Esos objetos aparecen como aproximaciones computacionales o casos restringidos de (34).

7.2. Caso lineal-gaussiano: aparece Kalman

Si eliminamos la DAE, los jumps y la no linealidad:

$$x_{k+1} = Ax_k + w_k, \quad y_k = Cx_k + v_k,$$

con gaussianas, el posterior permanece gaussiano y la corrección MAP/MMSE produce

$$K = P^- C^\top (C P^- C^\top + R)^{-1}, \quad \hat{x}^+ = \hat{x}^- + K(y - C\hat{x}^-).$$

Por diseño, el método general debe reducirse a Kalman en esta condición. Esto proporciona un sanity check teórico y unit tests sobre problemas lineales pequeños [2].

7.3. Por qué aparece un horizonte

Con ocho PMU, una medida instantánea puede no contener suficientes direcciones independientes. En un sistema linealizado,

$$\mathcal{O}_N = \begin{bmatrix} C \\ CA \\ \vdots \\ CA^N \end{bmatrix}.$$

Aunque $\text{rank } \mathcal{O}_N < n$, un output oculto $z_h = L_h x$ puede ser reconstruible si

$$\ker \mathcal{O}_N \subseteq \ker L_h. \quad (35)$$

Esto motiva un horizonte por información, no como parche. En nuestros prototipos la historia de varias muestras aumentó sustancialmente el rango/condicionamiento y redujo el error de hidden state.

7.4. Fixed-lag MAP

En una ventana $\mathcal{W}_k = \{k - N, \dots, k\}$, la función MAP genérica es

$$J = \frac{1}{2} \left\| \xi_{k-N} - \hat{\xi}_A \right\|_{P_A^{-1}}^2 + \frac{1}{2} \sum_t \|r_t^x\|_{Q^{-1}}^2 + \frac{1}{2} \sum_t \|r_t^y\|_{R^{-1}}^2 \quad (36)$$

$$+ \frac{1}{2} \sum_t \|\theta_t - \theta_{t-1}\|_{Q_\theta^{-1}}^2 + \frac{1}{2} \sum_t \|b_t - b_{t-1}\|_{Q_b^{-1}}^2 + \Phi(S) + \Psi(C), \quad (37)$$

sujeto a $g(x_t, z_t, q_t, \theta_t) = 0$ y $q_t - q_{t-1} - s_t = 0$.

7.5. Iteración Gauss–Newton/Laplace

Alrededor de una trayectoria $\chi^{(r)}$, se escribe

$$\chi^{(r+1)} = \chi^{(r)} + \Delta^{(r)}.$$

Cada factor se linealiza. La iteración restringida tiene estructura KKT:

$$\begin{bmatrix} \Lambda^{(r)} & C^{(r)\top} \\ C^{(r)} & 0 \end{bmatrix} \begin{bmatrix} \Delta^{(r)} \\ \lambda^{(r)} \end{bmatrix} = \begin{bmatrix} \eta^{(r)} \\ -c^{(r)} \end{bmatrix}. \quad (38)$$

La matriz Λ suma información de prior/arrival, dinámica, PMU, parámetros, biases, discrepancy y jumps. Debido a la causalidad temporal es block-banded/sparse, lo que permite Cholesky disperso, eliminación y actualización recursiva.

7.6. Marginalización de estados antiguos

Si una variable a sale de la ventana y las restantes son b , con información

$$\Lambda = \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix},$$

el arrival information nuevo es el complemento de Schur:

$$\Lambda_A^{new} = \Lambda_{bb} - \Lambda_{ba} \Lambda_{aa}^{-1} \Lambda_{ab}.$$

La recursión de horizonte móvil se deriva así de una marginalización probabilística, no de añadir arbitrariamente un MHE.

8. Varios eventos: pasar de una categoría a un conjunto aleatorio

8.1. Por qué el softmax de una causa es matemáticamente incorrecto

Un vector categórico $p_j = P(H_j | Y)$ con $\sum_j p_j = 1$ implica exactamente una causa. Nuestros experimentos demostraron que este supuesto fracasa cuando coexisten dos eventos físicos. La representación correcta introduce indicadores Bernoulli:

$$b_{g,\tau} \in \{0, 1\}, \quad b_{g,\tau} \sim \text{Bernoulli}(\pi_{g,\tau}),$$

y amplitudes

$$a_{g,\tau} | b_{g,\tau} = 1 \sim p_g(a).$$

Así,

$$s = \sum_{g,\tau} b_{g,\tau} B_g a_{g,\tau}. \quad (39)$$

La cantidad de eventos

$$M = \sum_{g,\tau} b_{g,\tau}$$

es aleatoria.

8.2. Marked point process

En tiempo continuo, una formulación compacta es

$$dq_t = \int_{\mathcal{M}} B(m) a N(dt, dm, da),$$

donde N es un marked point process y la marca contiene familia, activo y severidad. Esta forma permite simultaneidad, secuencias y cascadas sin cambiar de ontología.

8.3. Likelihood de un soporte

Después de linearizar/marginalizar nuisance state, para un soporte $\mathcal{S}$:

$$r = D_{\mathcal{S}} a_{\mathcal{S}} + \epsilon, \quad a_{\mathcal{S}} \sim \mathcal{N}(\mu_{\mathcal{S}}, \Gamma_{\mathcal{S}}),$$

por lo que

$$r \mid \mathcal{S} \sim \mathcal{N}(D_{\mathcal{S}} \mu_{\mathcal{S}}, \Sigma + D_{\mathcal{S}} \Gamma_{\mathcal{S}} D_{\mathcal{S}}^{\top}). \quad (40)$$

Entonces

$$P(\mathcal{S} \mid Y) \propto p(Y \mid \mathcal{S}) P(\mathcal{S}).$$

La inferencia entrega $P(M = m \mid Y)$, inclusión marginal $P(b_g = 1 \mid Y)$, MAP support y posteriors de amplitud.

8.4. Exacto para 0/1/2; escalable para 3+

Con $G = 102$ hipótesis, 0/1/2 eventos requieren

$$1 + G + \binom{G}{2} = 5254$$

soportes, manejables como oracle de referencia. Para 3+ se usarán SBL/variational Bernoulli-Gaussian/beam search/Rao-Blackwellized proposals, verificando el solver aproximado contra el oracle exacto en subproblemas.

9. Modelo incorrecto no debe convertirse en un evento falso

9.1. El fallo que descubrió Phase-2M

Bajo model mismatch observamos que un evento real se explicaba como dos: el segundo bloque compensaba errores de R, X, B, M, D , IBR o medida. El modelo reducido

$$r = DS + \epsilon$$

no tenía ningún lugar donde ubicar discrepancia estructurada.

9.2. Separación de cuatro fuentes de residual

La versión correcta es

$$r = H\delta X + DS + LC + \epsilon. \quad (41)$$

Interpretación:

- $H\delta X$: incertidumbre de estado;
- DS : cambios físicos abruptos y sparse;
- LC : discrepancy suave/estructurada del modelo;
- ϵ : ruido PMU rápido.

9.3. Discrepancia Gauss-Markov normal

Un baseline sin ML es

$$c_{k+1} = F_c c_k + \eta_k^c, \quad r_k^{normal} = U c_k + \epsilon_k.$$

Si $C \sim \mathcal{N}(0, K_c)$, se integra analíticamente:

$$LC + \epsilon \sim \mathcal{N}(0, LK_c L^{\top} + R).$$

Incluyendo la covarianza de estado:

$$\Sigma_{eff} = R + HP_X H^{\top} + LK_c L^{\top}.$$

9.4. Discrepancia condicionada al evento mediante ensemble físico

La corrección que resultó más efectiva en Phase-2N fue reconocer que la propia firma de un evento cambia con θ . Para cada evento g , un ensemble $\theta^{(m)}$ genera firmas $G_g^{(m)}$. Su SVD define un subespacio de incertidumbre U_g :

$$r \mid g = G_g a_g + U_g c_g + \epsilon, \quad c_g \sim \mathcal{N}(0, I).$$

El coeficiente c_g también puede marginalizarse. Esto evita activar otro evento sólo porque la firma nominal de g no coincide exactamente con la firma real.

9.5. Posterior preevento sobre el modelo

Usando únicamente operación normal antes del evento se puede estimar

$$p(\theta \mid Y_{pre}).$$

Nuestros prototipos usaron inicialmente una biblioteca discreta y definieron

$$\alpha = 1 - P(\theta = \theta_{nom} \mid Y_{pre})$$

como medida de activación de model discrepancy. El objetivo final es reemplazar esta biblioteca por un posterior continuo sobre parámetros físicos.

10. Probabilidades honestas: calibración, no scores

10.1. Evidencia marginal y Woodbury

Para un candidato de baja dimensión,

$$S_j = \Sigma + D_j \Gamma_j D_j^\top.$$

En lugar de invertir una matriz grande, la identidad de Woodbury da

$$S_j^{-1} = \Sigma^{-1} - \Sigma^{-1} D_j (\Gamma_j^{-1} + D_j^\top \Sigma^{-1} D_j)^{-1} D_j^\top \Sigma^{-1}.$$

El log-evidence incluye el término cuadrático y el determinante, penalizando automáticamente modelos excesivamente flexibles.

10.2. Métricas de calibración

Un posterior operacional debe evaluarse con

- negative log likelihood;
- Brier score;
- expected calibration error (ECE);
- reliability diagrams;
- cobertura de credible intervals de estados y severidades.

Un 99 % Top-1 con ECE alto no es una validación probabilística.

11. Identificabilidad y distinguibilidad

11.1. Eliminar nuisance state

En una ventana linealizada

$$r = \mathcal{O} \delta x + \mathcal{G} s + \epsilon.$$

El proyector ponderado fuera del subespacio de estado produce

$$\Pi_{\mathcal{O}}^\perp = I - \mathcal{O}(\mathcal{O}^\top W \mathcal{O})^\dagger \mathcal{O}^\top W,$$

y

$$\tilde{r} = \tilde{\mathcal{G}} s + \tilde{\epsilon}.$$

Dos candidatos individuales son localmente indistinguibles si sus subespacios proyectados coinciden o se vuelven casi colineales.

11.2. Métricas estructurales

Para cada par i, j deben calcularse

$$\mu_{ij} = \frac{\|D_i^\top \Sigma^{-1} D_j\|}{\|D_i\|_{\Sigma^{-1}} \|D_j\|_{\Sigma^{-1}}}, \quad (42)$$

$$\sigma_{min}^{ij} = \sigma_{min}([D_i \ D_j]), \quad (43)$$

además de principal angles, KL/Bhattacharyya distance y Fisher information. La hipótesis científica es que errores LINE+LINE y LOAD+LOAD se concentran en pares con alta coherencia/bajo σ_{min} .

12. Papel de machine learning: extensión natural, no sustitución

12.1. Qué no debe aprender ML

No se propone una red que mapee directamente $Y \rightarrow \text{BUS17}$ como método principal. Tampoco se usa una PINN para reaprender Kirchhoff aproximadamente cuando KCL puede imponerse exactamente.

12.2. Primera extensión: likelihood/discrepancy

La primera capa aprendida debe estimar aquello que la física conoce imperfectamente:

$$(\mu_{model,k}, L_{model,k}) = \mathcal{N}_\phi(\hat{x}_k, q_k, \text{mask}_k, r_{k-L:k-1}),$$

$$\Sigma_{model,k} = L_{model,k} L_{model,k}^\top + \epsilon I.$$

Así ML aprende la distribución de residual/model error y no la causa física.

12.3. Segunda extensión: dinámica residual

Puede aprenderse

$$c_{k+1} = f_\phi(c_k, \hat{x}_k, q_k) + \eta_k$$

o una corrección acotada

$$\dot{x} = f_{phys}(x, z, q, \theta) + B_r \Delta f_\phi(x, z, u).$$

KCL y la semántica de q permanecen intactas.

12.4. Tercera extensión opcional: correction de log-evidence

Sólo después de validar las dos anteriores:

$$\ell_j^{hybrid} = \ell_j^{physics} + \beta \Delta \ell_{\phi,j}.$$

La red recibe features físicas de candidato (residual, amplitud posterior, variance, graph context), no decenas de miles de estadísticas arbitrarias.

13. Evidencia experimental acumulada hasta Phase-2V

13.1. Lectura correcta de los experimentos

Las campañas Python realizadas hasta ahora no son resultados de publicación porque usan surrogates dinámicos progresivos. Su valor es falsar decisiones estructurales antes de construir la DAE completa. Cada fase añadió dificultad deliberadamente.

Fase	Qué se probó	Hallazgo principal
Phase-0	swing lineal estructural, 8 PMU, hidden states	historia temporal puede dar alta observabilidad; bus-step y line signatures son localizables en surrogate.

Phase-1	power-angle no lineal, V/I/f	single-event inversion fuerte; model mismatch de reacciones degrada bus-source y produce posterior sobreconfiado.
Phase-2	AC dynamic-phasor con Y_{bus} complejo	hidden-state reconstruction sobrevive; una discretización explícita inestable fue detectada y reparada; 4 familias single-event fuertes.
Phase-2M	0/1/2 eventos Bernoulli-Gaussian	single-cause fallaba en dobles; posterior sobre conjuntos recuperó gran parte de las parejas, pero model mismatch inventaba segundos eventos.
Phase-2N	discrepancy condicionada al modelo/evento	separó mejor evento verdadero de error de modelo; cardinalidad single hard dejó de colapsar en el benchmark dirigido.
Phase-2V	nueva batería: seeds, null, 2 PMU loss, severidad, OOD, pair types	confirmó mecanismo pero expuso límites de baja magnitud, pares coherentes y model mismatch OOD.

13.2. Resultados Phase-2V clave

Cuadro 2: Resultados internos de validación Phase-2V. Son evidencia preliminar, no claim final de ANDES/RAW.

Prueba	N	Soporte exacto	Cardinalidad correcta
Matched single, nuevas semillas	24	100.0 %	100.0 %
Matched double, nuevas semillas	40	90.0 %	100.0 %
Hard single, nuevas semillas	24	100.0 %	100.0 %
Hard double, nuevas semillas	40	87.5 %	97.5 %
Hard single, 2 PMU ausentes	16	100.0 %	100.0 %
Hard double, 2 PMU ausentes	20	80.0 %	100.0 %
Todos los pair types hard	144	86.11 %	98.61 %
GEN/LOAD hard, amplitud ≥ 0.10 pu	100	100.0 %	100.0 %

En el control null de Phase-2V se observaron cero declaraciones físicas falsas en 90 ventanas finitas con 0, 1 o 2 PMU removidas; esto no autoriza a afirmar FAR=0 y sólo justifica ampliar el test a horas/millones de frames.

13.3. Frontera de severidad

La sensibilidad a pasos GEN/LOAD bajo hard shift mostró una transición empírica: 0.05 pu alcanzó 55 % de soporte exacto, 0.075 pu 90 %, y a partir de 0.10 pu se obtuvo 100 % en 100 casos de esa campaña. En base 100 MVA, 0.10 pu corresponde a una escala de 10 MW. La lección no es que el umbral universal sea 10 MW; la lección es que el método posee un límite de SNR/identificabilidad medible que debe caracterizarse por familia, operating point y PMU set.




Figura 1: Phase-2V: sensibilidad de localización/cardinalidad a la magnitud de eventos GEN/LOAD bajo hard shift.

13.4. Model mismatch fuera de distribución




Figura 2: Phase-2V: degradación al aumentar el mismatch físico más allá del rango usado para construir el modelo de discrepancia.

13.5. Pares simultáneos




Figura 3: Phase-2V: exact support para diferentes tipos de pares simultáneos. LINE+LINE y LOAD+LOAD fueron los más difíciles en este sample.

13.6. Pérdida de dos PMU




Figura 4: Phase-2V: degradación del soporte exacto al perder dos de las ocho PMU.

14. Qué ya consideramos hipótesis respaldadas y qué no

Respaldado preliminarmente. (i) La historia de 8 PMU puede contener información suficiente para reconstruir funcionales de buses ocultos en modelos dinámicos razonables. (ii) Una localización por inversión física puede reemplazar un hard-routing classifier en casos controlados. (iii) El posterior sobre conjuntos es necesario para múltiples eventos. (iv) Separar model discrepancy de physical jumps evita un fallo real observado. (v) reconfigure-and-verify aporta una prueba causal adicional.

Todavía no demostrado. (i) Exactitud sobre una DAE ANDES completa con modelos dinámicos reales. (ii) Transferencia a RAW sin tuning. (iii) Calibración probabilística robusta de extremo a extremo. (iv) soporte de 3+ eventos a escala completa. (v) robustez universal a GFL/GFM y a PMU measurement operators realistas. (vi) novedad teórica final frente a toda la literatura de hybrid-system diagnosis/state-input estimation.

15. Arquitectura final propuesta




Figura 5: Arquitectura conceptual: una sola inferencia física produce hidden states y un posterior sobre múltiples cambios de configuración, mientras model discrepancy absorbe errores que no deben convertirse en eventos falsos.

16. Programa ANDES + pandapower: por qué ambos

ANDES es el motor dinámico principal porque proporciona power flow, time-domain simulation y una representación DAE simbólico-numérica; además incluye casos IEEE, modelos síncronos, cargas dinámicas, PMU/frecuencia, timed events y convertidores renovables [6, 7, 10]. pandapower aporta un segundo stack de AC power flow/topología y distribuye un `case39()`, útil para verificar conversiones, branch flows y convenciones de red [12].

La separación de roles será:

- **pandapower**: golden/static cross-check del caso 39, Ybus/flows, contingencias estáticas, validación de conversiones;
- **ANDES**: dinámica DAE, máquinas/controles/IBR/cargas, faults/toggles/setpoint changes, PMU/frequency time series;
- **estimator propio**: sólo ve 8 PMU, nunca el true state de ANDES durante inferencia.

17. Batería completa de experimentos

La siguiente tabla resume la campaña. La especificación operativa completa está en el prompt de implementación incluido como apéndice.

ID	Experimento	Criterio / pregunta principal
E00	Environment/reproducibility	¿Las versiones, seeds, checkpoints y manifests reproducen exactamente el run?
E01	ANDES–pandapower static parity	¿Mismo caso físico, V_m/V_a , P/Q , taps/shunts/flows entendidos?
E02	PMU measurement audit	¿ V/I -terminal/ $f/ROCOF$ y polaridades están congelados correctamente?
E03	Descriptor/functional observability	¿Qué horizonte y qué PMU-loss patterns preservan hidden outputs?

E04	Hidden-state nominal	¿8 PMU reconstruyen 31 buses con TVE/f/ROCOF y credible intervals válidos?
E05	Lag sweep	trade-off error vs causal delay; buscar lag mínimo útil.
E06	Parameter mismatch	sensibilidad a R/X/B, taps, H/D, controladores, ZIP, IBR.
E07	PMU loss	1 PMU, 2 PMU, bursts; reportar worst-case.
E08	Sensor imperfections	white/colored/correlated noise, gain/phase/frequency bias, clock skew, bad data.
E09	Single-event all-family	FAULT/LINE/GEN/LOAD compiten conjuntamente; no family-known shortcut.
E10	Severity boundary	localizar 50/90/95 % detectability por familia.
E11	Two simultaneous	diez pair types, exact support/cardinality/calibration.
E12	Two sequential	separación de onset 0–60 frames; cuándo se resuelven como dos.
E13	Protection cascade	fault-clear-trip y otras secuencias físicamente plausibles.
E14	Long null/FAR	al menos 1e6 frames/windows; falsas alarmas por hora/día.
E15	Integrity/cyber	missing, bad data, stuck, phase/clock corruption.
E16	Open-set	eventos fuera de q-space; el output correcto es UNKNOWN/abstención.
E17	Three events	escalabilidad de variational/SBL versus oracle reducido.
E18	IBR mix	penetración 0–80 %, GFL/GFM mixes, conditioning y robustness.
E19	OOD operating point/topology	dispatch, line params, feasible topology, IBR mix fuera de entrenamiento.
E20	Discrepancy ablation	sensor-only, +state covariance, +low-rank, +event-conditioned, +continuous theta, +ML.
E21	Calibration	NLL/Brier/ECE/reliability/coverage.
E22	Distinguishability atlas	principal angles/coherence/ σ_{min} /KL vs errors observados.
E23	PMU-placement counterfactual	SGSMA vs random vs observability vs multi-event-distinguishability optimized.
E24	Hackathon baseline comparison	accuracy/OOD/calibration/multi-event/hidden state/runtime.
E25	External replay	RAW/independent simulator sólo después de congelar el método.

18. Diseño de escenarios y randomización

18.1. Operating points

Los escenarios deben variar carga y generación manteniendo factibilidad AC. Cada operating point debe resolverse primero con power flow; si no converge, se rechaza con reason code. Las variaciones deben cubrir nominal, moderate shift, hard shift y OOD.

18.2. Dinámica

Aleatorizar dentro de bandas físicamente justificables H , D , parámetros AVR/governor, ZIP y controladores IBR. Las bandas y unidades se guardan en el manifest. No modificar simultáneamente todo sin mantener trazabilidad; usar diseños estratificados para atribuir fallos.

18.3. Eventos

El generador de escenarios debe permitir:

- fault shunt con severidad/duración/tipo;
- line trip persistente;
- generation setpoint step/trip;
- load step/drop;
- simultaneous 0–3 events;
- onsets distintos;
- fault clearing y cascadas;
- integrity events independientes de physical events.

18.4. Noise/integrity

Separar sensor noise, correlated/colored noise, static bias, clock/time errors, missingness y bad data. Cada capa debe poder activarse/desactivarse para ablation.

19. Métricas de reconstrucción, eventos y causalidad

19.1. Estado / PMU virtual

Reportar por bus y agregado:

$$RMSE(|V|), \quad RMSE(\vartheta), \quad TVE, \quad RMSE(f), \quad RMSE(ROCOF),$$

además de terminal-current TVE, NLL y cobertura de intervals. El error debe mostrarse frente a electrical distance a la PMU observada más cercana.

19.2. Conjunto de eventos

Para multi-eventos:

- exact support;
- cardinality accuracy;
- set Jaccard / set F1;
- family accuracy;
- marginal source inclusion;
- onset MAE;
- severity RMSE y interval coverage;
- NLL/Brier/ECE de inclusion/cardinality.

19.3. Reconfigure-and-verify

Reservar frames futuros no usados para inferir el soporte y aplicar la configuración inferida. Definir

$$\mathcal{R}_{verify} = 1 - \frac{E_{post}}{E_{pre}},$$

donde las energías son residuales blanqueados. La causa correcta debe reducir de forma material el residual futuro; una hipótesis que sólo ajusta el onset pero no predice el futuro no es causalmente satisfactoria.

20. Gates de investigación y reglas de no autoengaño

1. No ejecutar localización si E01/E02 no pasan.
2. No reportar hidden state sin baseline trivial y coverage.
3. No llamar “probabilidad” a un score sin E21.
4. No llamar éxito a cardinalidad correcta con source support incorrecto.
5. No ocultar rejected simulations.
6. No entrenar discrepancy ML con el external holdout.
7. No bajar severidades sólo hasta donde el método siga en 100 %; explorar hasta que falle.
8. No usar true onset en el resultado final; puede existir como oracle ablation.
9. No usar family-known localizer como primary score.
10. No cambiar PMU mapping según escenario.

21. Escala de Monte Carlo recomendada

Tres modos:

- **smoke:** 1–3 seeds/cell para verificar software;
- **standard:** 10–20 seeds/cell para desarrollo;
- **paper:** muestras suficientes para intervalos y tails.

Mínimos recomendados para paper: ≥ 500 trayectorias de hidden-state reconstruction; cada source single-event con ≥ 20 repeticiones cuando sea viable; ≥ 100 dobles por pair type; ≥ 1000 triples estratificados; ≥ 100 muestras por severidad cerca de la transición; $\geq 10^6$ frames/windows normales para FAR; ≥ 500 OOD escenarios.

22. Comparación que debe decidir si el nuevo método vale la pena

El baseline histórico de la hackathon era un recognizer discriminativo con gran cantidad de features y clasificadores jerárquicos. El nuevo método no debe declararse superior por estética. Se compara en exactamente los mismos splits:

Método	In-domain	OOD	Hidden state	Multi-event	Calibration
Hackathon ExtraTrees	fuerte esperable	a medir	no nativo	limitada	a medir
Physics-only Bayes	a medir	fuerte hipótesis	sí	sí	explícita
ML-only temporal/GNN	potencialmente fuerte	riesgo	no necesariamente	aprendida	a medir
Physics + learned discrepancy	candidato final	candidato final	sí	sí	explícita

La hipótesis que realmente debe falsarse es que el híbrido mejora transferencia/calibración bajo mismatch sin sacrificar el soporte físico del estimador.

23. Novedad científica: qué sí y qué no

No es nuevo usar Bayes para una causa, usar EKF, usar MHE, usar sparse recovery ni hacer DSE con DAE. Existe trabajo cercano en DSE recursivo para DAEs incompletas que generaliza IEKF y deriva condiciones de estimabilidad/PMU placement [3]; existen trabajos de state/unknown-input estimation [4]; y sparse Bayesian learning es una teoría clásica [5]. Por tanto la contribución no debe redactarse como “inventamos Bayes/Kalman sparse”.

La posible contribución, si sobrevive la revisión bibliográfica y la validación completa, es la unificación específica:

functional sparse-PMU reconstruction + hybrid physical configuration jumps + multi-event posterior + model-discrepancy sep

La teoría debe acompañarse de condiciones de reconstructibilidad/distinguibilidad y no sólo de benchmarks.

24. Roadmap de implementación inmediato

24.1. Bloque A: no negociable

Crear repo/folder, environment audit, ANDES IEEE-39, pandapower case39, conversión/parity y PMU measurement contract. No avanzar mientras haya diferencias eléctricas no explicadas.

24.2. Bloque B: estado

Extraer f, g, h , construir fixed-lag MAP y validar contra problemas lineales/casos pequeños. Evitar discretizaciones de covarianza inestables. Implementar gauge handling explícito.

24.3. Bloque C: eventos

Construir q, s , exact oracle 0/1/2, luego scalable 3+. Integrar model discrepancy y posterior θ .

24.4. Bloque D: batería

Ejecutar E03–E23 con manifests y outputs reproducibles. Sólo después integrar ML y comparar con baseline.

24.5. Bloque E: external holdout

Congelar commit, hyperparameters y priors. Ejecutar RAW/holdout una sola vez para la evaluación formal.

25. Criterio para considerar que el método “funciona”

No existe un único porcentaje mágico. Consideraremos el núcleo técnicamente validado cuando, sobre una DAE independiente del surrogate de desarrollo:

1. los hidden outputs sean reconstruibles con error y coverage útiles en nominal y mismatch;
2. single-event se resuelva conjuntamente por familia/fuente sin shortcut;
3. multi-event mantenga exact support/cardinality alto y degrade coherentemente con los indicadores de distinguibilidad;
4. no-event tenga FAR operacional bajo;
5. las probabilidades estén calibradas;
6. model discrepancy no se convierta sistemáticamente en eventos falsos;
7. reconfigure-and-verify mejore predicción futura;
8. OOD/external transfer sea materialmente mejor o al menos más seguro/calibrado que el baseline discriminativo.

A. Prompt maestro para Claude Code / Codex

El siguiente prompt está diseñado para entregarse directamente a un agente de código con acceso al repositorio. Incluye la arquitectura, los gates, la batería E00–E25, ANDES, pandapower, outputs y reglas anti-leakage.

```
# MASTER IMPLEMENTATION PROMPT - PMU Hybrid-DAE Bayesian State/Event Estimator

You are taking over a research-grade Python implementation for a power-systems paper. Work autonomously, inspect the repository before modifying it, and make local commits only. Do not push. Do not ask me to hand-hold normal implementation decisions. If an API differs from this prompt, inspect the installed package source/docs and adapt while preserving the mathematical contract below.

## 0. Mission

Create a new self-contained research folder for a full validation campaign of a physics-first Bayesian hybrid-DAE estimator on the IEEE 39-bus system with only eight observed PMU buses:

‘{2, 5, 6, 10, 19, 22, 29, 39}’.
```

The estimator must reconstruct the unmeasured network state / virtual PMUs at the remaining 31 buses and infer 0, 1, 2, and eventually 3 physical events, including simultaneous and sequential events. The primary dynamic simulator is ****ANDES****. ****pandapower**** is the independent AC power-flow/topology cross-check. If a `PowerDynamics.jl` implementation already exists in the repository, it may be used as an optional third holdout, but it must not block the ANDES + pandapower core campaign.

The scientific question is not "can a classifier recognize event labels?" It is:

> Given sparse PMU histories and a nonlinear electrical network model, what state trajectory and what sparse physical configuration changes are most probable, with calibrated uncertainty?

The implementation must be leakage-safe, resumable, deterministic by seed, auditable, and capable of producing paper-ready CSV/Parquet tables and plots.

1. Non-negotiable scientific rules

1. ****Do not use hidden true states during inference.**** They are allowed only for post-hoc evaluation.
2. ****Do not use event labels as estimator inputs.**** Labels are evaluation ground truth only.
3. ****Do not tune on RAW0001/RAW0002 or any designated external holdout.**** If such files exist, keep them isolated under `'data/external_holdout/'` and only use them after the simulator/estimator is frozen.
4. ****No random-window leakage.**** Split by scenario/operating point/model seed, not by adjacent time windows.
5. ****Do not assume a PMU current-terminal orientation.**** Discover it from authoritative metadata/repository files; validate magnitude and polarity; freeze it in a manifest. If exact metadata are unavailable, define the measurement terminal explicitly and label the experiment as a controlled synthetic study.
6. ****Do not fake detailed IBR fidelity.**** If an ANDES model is unavailable or fails initialization, document it and use a simpler model under a clearly named ablation. Never relabel a low-inertia swing surrogate as GFL/GFM.
7. ****Do not hide failures.**** Save rejected/non-converged simulations with reason codes.
8. ****Do not report scores without uncertainty.**** Use bootstrap or Wilson intervals where appropriate.
9. ****Do not call uncalibrated scores probabilities.**** Probability outputs must be checked with NLL/Brier/ECE/reliability.
10. ****Do not let learned ML replace KCL/Ybus/event semantics.**** ML may learn uncertainty/model discrepancy; the physical event support remains physically interpretable.
11. ****No "inverse crime" as the only validation.**** Always include simulator/parameter/operator mismatch.
12. Every result must be reproducible from a frozen manifest containing code commit, package versions, seed, solver settings, PMU map, event parameters, model parameters, and data split.

2. Repository/folder structure

Create a dedicated branch, e.g.

```
'research/pmu-hybrid-dae-bayes-v1'
```

Create a folder such as:

```
'''text
research/pmu_hybrid_dae_bayes/
  README.md
  pyproject.toml
  environment-lock.txt
  configs/
    base_ieee39.yaml
    pmu_map.yaml
    experiment_smoke.yaml
    experiment_standard.yaml
    experiment_paper.yaml
  src/pmu_hybrid/
    __init__.py
  cases/
    ieee39_andes.py
    ieee39_pandapower.py
    parity.py
  physics/
    network.py
    measurement.py
    synchronous.py
    loads.py
    ibr.py
    events.py
    configuration.py
  simulator/
    andes_backend.py
    pandapower_backend.py
    scenario.py
    noise.py
    integrity.py
    export.py
  estimator/
    state.py
    fixed_lag.py
    dae_linearization.py
    jumps.py
    discrepancy.py
    posterior.py
    calibration.py
  ml/
    residual_covariance.py
    discrepancy_model.py
  metrics/
    state_metrics.py
    event_metrics.py
    calibration_metrics.py
```

```

experiments/
  e00_environment.py
  e01_static_parity.py
  ...
  e25_external_holdout.py
plotting/
  paper_plots.py
utils/
  seeds.py
  manifests.py
  logging.py
  cache.py
tests/
output/
  manifests/
  datasets/
  results/
  plots/
  reports/
  rejected/
'''

If the repo already has conventions, integrate with them instead of duplicating infrastructure.

---

# 3. Dependency and environment audit

Before writing the estimator:

- print and save exact versions of Python, NumPy, SciPy, pandas, matplotlib, ANDES, pandapower, scikit-learn, PyTorch/JAX if used;
- run ANDES self-test / smallest shipped case;
- locate the shipped ANDES 'ieee39' case and inspect whether it includes dynamic data;
- load 'pandapower.networks.case39()';
- save 'output/reports/environment_audit.md';
- pin the successfully tested environment.

Prefer the current stable APIs available in the environment. ANDES supports power flow and time-domain simulation with a DAE
representation; its current model library includes synchronous generators/controllers, ZIP/FLoad, PMU/frequency models,
renewable converter models, timed faults/toggles/alters. Do not hard-code version-specific calls without feature detection.

---

# 4. Source-of-truth IEEE-39 model and PMU map

Use the official competition mapping:

- PMU buses: 39, 29, 10, 22, 19, 2, 5, 6
- canonical sorted set used by the estimator: '{2,5,6,10,19,22,29,39}'
- 100 MVA base, nominal 60 Hz unless the loaded case specifies otherwise.

Build a canonical bus/branch/device map and write it to 'configs/base_ieee39.yaml'.

The first mandatory test is static parity:

1. Load/build IEEE-39 in ANDES and solve power flow.
2. Load 'pandapower.networks.case39()' and solve AC power flow.
3. Align bus numbering, branch directions, transformer taps, shunts, base values.
4. Compare:
  - Vm per bus,
  - Va per bus after common angle gauge alignment,
  - P/Q net injections,
  - branch P/Q flows in both directions.
5. Fail the pipeline if parity is not understood. Do not "tune around" mismatches.

Target after consistent data conversion:

- voltage magnitude differences: as close to numerical equivalence as the source cases allow;
- angle differences after reference alignment: documented and small;
- branch-flow differences: documented with transformer/tap conventions.

If ANDES and pandapower shipped cases are not exactly parameter-identical, create a shared canonical case from one authoritative data
set and import/translate it into both frameworks; keep a conversion manifest.

---

# 5. Physics model to implement

The theoretical plant is a semi-explicit nonlinear hybrid DAE:

'''text
x_dot = f(x, z, u, q, theta) + w_x
0 = g(x, z, u, q, theta)
y_P = h_P(x, z, b) + v
q_k = q_{k-1} + s_k
'''

where:

- 'x': dynamic states (synchronous machines, AVR, governor, PLL, converter states, etc.);
- 'z': algebraic network variables, especially bus complex voltages;
- 'u': known controls/setpoints;
- 'q': physical configuration;

```

```

- 'theta': slowly uncertain physical parameters;
- 's': rare sparse configuration jumps;
- 'b': slow measurement biases.

## 5.1 Network equations

Use complex nodal network equations, not hand-crafted features:

'''text
I = Ybus(q, theta) V
S_i = V_i conj(I_i) = P_i + j Q_i
'''

Equivalent polar power-flow identities must be unit-tested:

'''text
P_i = |V_i| sum_j |V_j| [G_ij cos(theta_i-theta_j) + B_ij sin(theta_i-theta_j)]
Q_i = |V_i| sum_j |V_j| [G_ij sin(theta_i-theta_j) - B_ij cos(theta_i-theta_j)]
'''

For each measured branch terminal:

'''text
I_ij = Yff_ij V_i + Yft_ij V_j
I_ji = Ytf_ij V_i + Ytt_ij V_j
S_ij = V_i conj(I_ij)
'''

Do not use a bus-current abstraction where the competition measures a branch terminal current.

## 5.2 Synchronous generation

Prefer a physically standard dynamic configuration using ANDES models available in the installed version:

- synchronous machine: 'GENROU' when feasible (or the closest verified shipped dynamic IEEE-39 data);
- exciter: a suitable supported exciter, e.g. IEEE1/EXST1/other case-native model;
- governor: 'TGOV1' or case-native turbine governor;
- preserve the native dynamic case if ANDES already ships one.

At minimum the estimator theory recognizes the swing relation:

'''text
delta_dot = omega_b * Deltaomega
M Deltaomega_dot = P_m - P_e - D Deltaomega
'''

but do not reduce the final ANDES benchmark to this if higher-order machine models are available.

For generator setpoint changes with an active governor/dynamic machine, modify the correct dynamic control target, not a disabled static PV value. Inspect ANDES dynamic-control examples and the installed model API. Save the exact intervention target in the scenario manifest.

## 5.3 Loads

Use static PQ for baseline plus dynamic ZIP/Fload experiments.

ZIP concept:

'''text
P(V)=P0[a_Z(V/V0)^2 + a_I(V/V0) + a_P]
Q(V)=Q0[b_Z(V/V0)^2 + b_I(V/V0) + b_P]
'''

When a dynamic ZIP/Fload is active, intervene on the correct dynamic-load parameter/setpoint, not a disabled static PQ parameter.

## 5.4 IBR models

Create explicit IBR scenarios; do not merely reduce inertia.

Where supported and stable in the installed ANDES release, use:

- GFL: REGC_A/REGCP1-style converter with PLL plus REECA1/REPCA1 controls as appropriate;
- GFM: REGCV1/REGCV2/VSG-style model where available;
- save exact model composition and controller parameters.

Required scenario mixes:

'''text
IBR penetration: 0%, 20%, 40%, 60%, 80%
GFL:GFM mix: 100:0, 75:25, 50:50, 25:75, 0:100 where feasible
'''

If a requested mix cannot initialize stably, record the failure and run the closest stable feasible subset rather than silently changing parameters.

---

# 6. PMU observation operator

The estimator receives data from only eight buses.

Canonical internal representation per observed PMU should be positive-sequence / phasor-space quantities:

```

```

'''text
Re(V), Im(V), Re(I_terminal), Im(I_terminal), f, ROCOF, DATA_PRESENT
'''

The competition CSVs use three-phase magnitudes/angles. If the simulator is positive-sequence, do **not** pretend it has unbalanced
three-phase physics. Either:

1. keep the estimator in positive-sequence coordinates; or
2. create balanced phase A/B/C values only as a compatibility export layer and label them as such.

Frequency/ROCOF must be treated as measurement-operator outputs, not ideal derivatives by assumption. Prefer ANDES 'BusFreq' /
'BusROCOF' / PMU measurement models if available; otherwise implement a documented causal PMU-like estimator and compare it with
the ideal derivative in an ablation.

The estimator must output virtual PMU quantities for the 31 uninstrumented buses:

'''text
V_hat_i, angle_hat_i, f_hat_i, ROCOF_hat_i
'''

and all branch terminal currents derivable from the reconstructed state/configuration.

---

# 7. Physical configuration and event model

Represent all physical events as changes in a single configuration object 'q'.

At minimum:

'''text
q = [line_status,
     fault_shunts,
     generator_setpoint/configuration,
     load_setpoint/configuration,
     IBR_mode_or_status]
'''

and

'''text
q_k = q_{k-1} + s_k.
'''

A physical event is a sparse block of 's_k', not a class label.

Examples:

'''text
LINE l: sigma_l : 1 -> 0
FAULT i: Ybus -> Ybus + y_f e_i e_i^T
GEN i: generator setpoint/trip parameter changes
LOAD i: load P/Q or load-model setpoint changes
'''

Support groups must preserve family + physical source + amplitude dimensions.

---

# 8. Stochastic multi-event model

Do not use a categorical "one event only" softmax.

For each physical group 'g' and candidate onset 'tau':

'''text
b_{g,tau} ~ Bernoulli(pi_{g,tau})
a_{g,tau} | b=1 ~ p_g(a)
s = sum_{g,tau} b_{g,tau} B_g a_{g,tau}
'''

Use nonlocal/sign-aware slabs for physical changes where appropriate so an "active" event cannot collapse to a meaningless
infinitesimal amplitude.

The output must include:

'''text
P(M = 0 | Y), P(M = 1 | Y), P(M = 2 | Y), ...
P(b_g = 1 | Y) for every physical source
MAP support
posterior amplitude mean/covariance
posterior onset distribution
family marginals
source marginals
'''

For 0/1/2 events, an exact support enumerator is acceptable as a reference oracle if computationally feasible. For 3+ events,
implement a scalable approximation such as variational Bernoulli-Gaussian inference, sparse Bayesian learning, beam search, or
Rao-Blackwellized support proposals. The scalable solver must be checked against the exact 0/1/2 oracle on overlapping small
cases.

---

```

9. State estimator / fixed-lag nonlinear DAE smoother

Do not start from an EKF name. Implement the estimator as a fixed-lag MAP problem induced by the physical generative model.

For a window ‘ $W_k=\{k-N,\dots,k\}$ ’ solve approximately:

```

'''text
min over X,Z,Theta,B,S,C

    0.5 ||xi_{k-N} - xi_arrival||_{P_arrival^{-1}}^2
+ 0.5 sum_t ||r_dyn,t||_{Q^{-1}}^2
+ 0.5 sum_t ||r_pmu,t||_{R^{-1}}^2
+ parameter-drift priors
+ measurement-bias priors
+ model-discrepancy priors
- log p(S)

```

```

subject to
    g(x_t,z_t,q_t,theta_t)=0
    q_t=q_{t-1}+s_t.
'''

```

Use iterated Gauss-Newton / Laplace approximation and exploit sparse block-banded structure. The linearized KKT/information step is conceptually:

```

'''text
[ Lambda C^T ] [Delta] = [ eta ]
[ C 0 ] [lambda] [-c]
'''

```

where Lambda accumulates arrival, dynamics, PMU, parameter, bias, discrepancy, and jump information.

When the oldest state exits the window, marginalize it with a Schur complement to form the next arrival information. This is the causal fixed-lag implementation; full-record RTS may be used only as an offline upper-bound ablation.

For stiff DAE dynamics, do not use an unstable low-order explicit covariance transition approximation. Use ANDES/implicit DAE Jacobians, an implicit discrete sensitivity map, matrix exponential where justified, or another numerically stable construction. Add a test that reports the spectral radius of every local discrete transition approximation used by the estimator.

10. Model uncertainty / discrepancy: the repair that must be preserved

The key failure discovered in earlier experiments was that model mismatch could be misinterpreted as a second physical event.

The estimator must therefore distinguish:

```

'''text
state uncertainty H deltaX
physical sparse jumps D S
model discrepancy L C
sensor noise epsilon
'''

```

so that locally:

```

'''text
r = H deltaX + D S + L C + epsilon.
'''

```

Implement two complementary discrepancy representations:

10.1 Physics-ensemble event-conditioned discrepancy

Create an ensemble of plausible physical parameter models ‘ $\theta^{(m)}$ ’ by varying:

- R/X/B;
- transformer parameters if uncertain;
- generator H/D and selected machine/controller parameters;
- load ZIP/dynamic coefficients;
- IBR controller/time constants;
- PMU gain/phase/frequency bias.

For each physical event candidate ‘g’, compute the ensemble of candidate signatures and obtain a low-rank SVD/PCA uncertainty subspace ‘ U_g ’. Model:

```

'''text
r | event g = G_g a_g + U_g c_g + epsilon
c_g ~ N(0,I).
'''

```

Marginalize ‘ c_g ’ analytically where possible.

10.2 Continuous latent discrepancy from normal pre-event innovations

Fit, on **normal data only**, a low-rank colored residual model:

```

'''text
c_{k+1} = F_c c_k + eta_k
r_k^normal = U c_k + epsilon_k.
'''

```

Start with PCA/SVD + linear Gauss-Markov/AR dynamics. This is the baseline. Do not use ML first.

```

Only after the physics-only stochastic discrepancy model is frozen, add the optional learned extension:

'''text
c_{k+1} = f_phi(c_k, x_hat_k, q_hat_k) + eta
Q_c,k = Q_phi(context)
'''

or a conditional residual likelihood. Train this on normal/mismatch data, not event labels, for the primary ML ablation.

---

# 11. Bayesian evidence and probabilities

For a local linearized physical candidate support S:

'''text
r = D_S a_S + epsilon_eff

a_S ~ N(mu_S, Gamma_S)
epsilon_eff ~ N(0, Sigma_eff)
'''

then

'''text
r | S ~ N(D_S mu_S,
          Sigma_eff + D_S Gamma_S D_S^T).
'''

Use numerically stable Woodbury / determinant lemma / Cholesky computations. Work in log space and normalize with logsumexp.

The posterior is:

'''text
P(S | Y) proportional to p(Y | S) P(S).
'''

The cardinality prior must be explicitly configured, sensitivity-tested, and never tuned on the final holdout.

Probability calibration is a first-class metric. Save reliability diagrams for:

- event present vs normal;
- cardinality M;
- marginal source inclusion;
- family marginal.

---

# 12. Observable / distinguishable structure analysis

Before celebrating accuracy, compute structural diagnostics.

## 12.1 Functional observability

For each operating point / linearization and horizon N:

'''text
O_N = [C; CA; ...; CA^N]
'''

or the corresponding descriptor-system construction.

Report:

- numerical rank versus horizon;
- singular-value spectrum;
- condition number after physical scaling/whitening;
- functional observability residual for hidden outputs.

The relevant functional condition is of the form:

'''text
ker(O_N) subset ker(L_hidden).
'''

## 12.2 Event distinguishability

After projecting out nuisance state directions:

'''text
r_tilde = Pi_0_perp r = D_tilde s + epsilon.
'''

For every important pair or pair-support compute:

- principal angles between event-signature subspaces;
- normalized coherence;
- smallest singular value of '[D_i D_j]';
- KL / Bhattacharyya distance between candidate predictive distributions;
- Fisher information for event amplitude/source where applicable.

Use these metrics to explain failures such as LINE+LINE or LOAD+LOAD rather than hiding them.

```

```

---

# 13. Complete experiment battery

Implement a common scenario generator and then run the following experiments. Every experiment must have 'smoke', 'standard', and
'paper' configurations.

## E00 - environment and deterministic reproducibility

- package/version audit;
- deterministic seed test;
- checkpoint/resume test;
- exact rerun equality for manifests/results within numeric tolerance.

Gate: must pass before all other experiments.

## E01 - ANDES pandapower AC static parity

- bus Vm/Va;
- P/Q injections;
- branch P/Q;
- taps/shunts;
- reference-angle handling.

Gate: no unexplained material mismatch.

## E02 - PMU measurement-operator audit

For all 8 PMU buses:

- complex V;
- exact terminal current direction/sign;
- f;
- ROCOF;
- DATA_PRESENT mask.

Compare analytical branch-current formulas with simulator outputs.

Gate: current polarity/magnitude must be frozen and unit-tested.

## E03 - nonlinear/descriptor observability study

Across operating points, IBR mixes and PMU-loss patterns:

- rank/conditioning versus horizon;
- hidden-output functional observability;
- identify the minimal useful lag.

## E04 - hidden-state/virtual-PMU reconstruction, nominal

Only 8 observed PMUs. Evaluate all 31 hidden buses.

Metrics:

'''text
RMSE(|V|), RMSE(angle), TVE,
RMSE(f), RMSE(ROCOF),
branch-current TVE,
95% posterior interval coverage,
NLL
'''

Compare:

- one-step EKF/IEKF baseline;
- iterated fixed-lag smoother;
- offline full-record smoother upper bound.

## E05 - fixed-lag sweep

Lag values approximately:

'''text
0, 1, 3, 5, 10, 15, 30, 60 frames
'''

Plot reconstruction error and event support accuracy against causal delay.

## E06 - physical parameter mismatch

Sweep independent and coupled variations in:

- line R/X/B;
- transformer tap/impedance;
- machine H/D;
- AVR/governor parameters;
- load ZIP coefficients;
- IBR controller/time constants.

Include in-distribution and deliberately out-of-distribution levels.

## E07 - PMU loss / data availability

```

```

Test:
- no loss;
- every single PMU removed one at a time;
- every pair of PMUs removed, or a stratified set if compute is excessive;
- random intermittent dropout;
- burst dropout of 0.1-5 s.

Report worst-case PMU(s), not only averages.

## E08 - sensor imperfections

Sweep:
- white Gaussian noise;
- AR(1) colored noise;
- cross-PMU correlated noise;
- voltage/current gain bias;
- phase bias;
- frequency bias;
- clock/time skew;
- quantization;
- outliers/heavy tails;
- bad data frames.

## E09 - single-event joint family/source inference

Jointly compete all physical sources without giving the family to the estimator.

Families:
- FAULT;
- LINE;
- GENERATION;
- LOAD.

Report exact source, family, Top-k, posterior calibration, amplitude, onset.

## E10 - severity / detectability boundary

For every family, sweep severity down toward the noise/model-discrepancy floor.

GEN/LOAD example:

'''text
0.025, 0.05, 0.075, 0.10, 0.15, 0.20, 0.35, 0.5, 0.8, 1.1 pu
'''

FAULT:
- fault admittance/resistance;
- duration 1-30 cycles;
- different fault types if model supports them.

LINE:
- complete trip;
- high-impedance/partial topology change only if physically supported.

Estimate the empirical 50%, 90%, and 95% localization thresholds.

## E11 - two simultaneous physical events

Stratify all pair types:

'''text
FAULT+FAULT
FAULT+LINE
FAULT+GEN
FAULT+LOAD
LINE+LINE
LINE+GEN
LINE+LOAD
GEN+GEN
GEN+LOAD
LOAD+LOAD
'''

For each pair type in paper mode use at least 100 independent cases, more for the hardest pair types.

Metrics:
- exact support;
- Jaccard / set F1;
- correct cardinality;
- both true sources in top marginal inclusions;
- source-specific inclusion probability calibration.

## E12 - non-simultaneous two-event sequences

Sample independent onsets with separations:

```

```

'''text
0, 1, 2, 3, 5, 10, 15, 30, 60 frames.
'''

Measure when the estimator resolves one event versus two.

## E13 - protection/cascade sequence

Explicitly test physically plausible cascades such as:

'''text
bus fault -> clearing -> line trip
fault -> generator/controller response
line trip -> overload-related second trip (if modeling supports it)
'''

This is a marked temporal point-process validation, not a multi-label classifier test.

## E14 - no-event long-run false-alarm campaign

Simulate long normal operation across operating points and mismatch.

Paper target: at least the equivalent of multiple hours at 30 fps; preferably 1e6+ evaluated frames/windows.

Report false alarms per hour/day and run-length distribution, not only frame accuracy.

## E15 - integrity/cyber events

- missing data;
- bad data;
- stuck-at values;
- channel swaps if realistic;
- isolated PMU clock/phase corruption.

The estimator must separate measurement faults from physical configuration jumps where identifiable.

## E16 - open-set unknown event

Create events outside the modeled q-space, e.g.:

- controller mode changes not represented in the hypothesis set;
- combined measurement corruption not in training;
- parameter jump outside supported prior;
- unusual oscillatory forcing.

Required behavior is calibrated abstention/UNKNOWN, not forced classification.

## E17 - three simultaneous events

Test at least:

- one topology + two nodal;
- two topology + one nodal;
- three nodal;
- fault + line + nodal.

Use exact enumeration only on reduced candidate sets for oracle checks; use the scalable sparse Bayesian/variational solver for the full source set.

## E18 - IBR penetration and GFL/GFM mix

Run the reconstruction/event battery across the IBR penetration/mix grid defined above.

Measure:

- hidden-state error;
- event source accuracy;
- posterior calibration;
- numerical conditioning;
- sensitivity to PLL/controller parameter uncertainty.

## E19 - topology/operating-point OOD

Train/design discrepancy model on one range and test on:

- load/generation dispatch outside training range;
- altered line parameters;
- changed but feasible pre-event topology;
- IBR mix outside the training envelope.

## E20 - model-discrepancy ablation

Compare:

'''text
M0: sensor noise only
M1: + state covariance
M2: + normal low-rank colored discrepancy
M3: + event-conditioned physics-ensemble discrepancy
M4: + continuous theta estimation
M5: + learned residual/discrepancy model
'''

```

The ML model is justified only if M5 improves external/OOD performance or calibration, not merely same-simulator accuracy.

E21 - probability calibration

For every posterior output compute:

- negative log likelihood;
- Brier score;
- ECE;
- reliability diagrams;
- coverage of amplitude/state credible intervals.

If necessary, use a calibration split and temperature/isotonic-style post-calibration, but report pre- and post-calibration. Do not calibrate on the final external holdout.

E22 - distinguishability failure atlas

For all pair types, map:

- principal angle/coherence;
- sigma_min of joint signature;
- electrical/geodesic distance;
- PMU distance;
- event severity;
- observed support accuracy.

Test whether theoretical distinguishability predicts empirical errors.

E23 - PMU-placement counterfactual

Keep 8 PMUs total. Compare:

- official SGSMA placement;
- random feasible placements;
- observability-optimized placement;
- multi-event-distinguishability-optimized placement.

Do not change the official-placement primary results; this is a scientific counterfactual.

E24 - comparison with ML/hackathon baseline

If the historical ExtraTrees pipeline is available, freeze it and compare on exactly the same scenario splits.

Compare:

- in-domain accuracy;
- OOD accuracy;
- hidden-state capability;
- multi-event support;
- calibration;
- parameter count;
- runtime;
- robustness to PMU loss.

Do not rewrite the baseline to make it weaker.

E25 - external replay

Only after all code/hyperparameters are frozen:

- replay RAW0001 / available real competition traces if present;
- if RAW0002 is designated holdout, never inspect it before the frozen evaluation;
- compare waveform residuals, event posteriors, hidden-state plausibility, and false-alarm behavior.

If external raw data are not present, leave the runner and manifest contract implemented but skip the execution.

14. Monte Carlo scale

Every experiment supports:

```
“text
smoke: 1-3 seeds/cell, seconds/minutes
standard: 10-20 seeds/cell
paper: enough cases for confidence intervals and stable tails
“
```

Recommended paper-scale minimums:

- hidden reconstruction: ≥ 500 independent trajectories;
- single-event localization: every source $\times \geq 20$ repetitions when computationally feasible;
- double events: ≥ 100 per pair-type, stratified source pairs;
- triple events: ≥ 1000 total stratified scenarios;
- weak-event sweep: ≥ 100 cases per severity near the transition;
- null/FAR: $\geq 1e6$ evaluated frames/windows across multiple operating points;
- OOD mismatch: ≥ 500 independent scenarios.

Use parallel workers with deterministic seed assignment, checkpointing, and resumable manifests.

15. Metrics

```

## State / virtual PMU

- magnitude RMSE;
- angle RMSE after gauge alignment;
- TVE;
- frequency RMSE;
- ROCOF RMSE;
- terminal-current TVE;
- credible-interval coverage;
- state NLL;
- error versus electrical distance to nearest observed PMU.

## Event set

- exact support recovery;
- cardinality accuracy;
- set Jaccard and set F1;
- family accuracy;
- source Top-1/Top-3;
- onset MAE;
- event-magnitude RMSE/credible interval coverage;
- marginal inclusion NLL/Brier/ECE;
- UNKNOWN/abstention AUROC/AUPRC where applicable.

## Causal verification

Reserve future frames not used in support inference. Apply the inferred physical configuration and compute:

'''text
R_verify = 1 - E_post / E_pre
'''

where the energies are whitened residual energies. The correct physical support should explain held-out future data better than wrong
supports.

## Operational

- inference latency;
- real-time factor;
- memory;
- number of Newton/Gauss-Newton iterations;
- solver convergence/rejection rate.

---

# 16. Success/failure gates

Use explicit stop gates.

- **G0 static parity:** no unexplained material AC mismatch.
- **G1 measurement operator:** terminal current polarity/magnitude frozen and verified.
- **G2 state estimator:** hidden-state errors must be materially better than naive persistence/interpolation and posterior coverage
  must be credible.
- **G3 single-event:** no family-known shortcut; joint family/source performance reported.
- **G4 multi-event:** exact support and cardinality both reported. High cardinality with poor exact support is not "success".
- **G5 discrepancy:** one-event hard-shift cases must not systematically create a second event.
- **G6 calibration:** high accuracy with ECE/NLL failure is not accepted as probabilistic validation.
- **G7 OOD:** performance degradation must be characterized, not hidden.
- **G8 external:** no publication-ready claim until at least one independent simulator or external trace is evaluated.

When a gate fails, stop the downstream claim, diagnose, add a focused falsification experiment, and document the change.

---

# 17. ML extension - only after physics baseline is frozen

The required "physics-informed ML" version should be a natural uncertainty/discrepancy extension, not a replacement classifier.

Primary ML experiment:

'''text
input:
  physical state estimate/context,
  PMU mask,
  operating point,
  recent normal innovations,
  optionally theta posterior summary

output:
  residual mean/covariance or low-rank latent discrepancy dynamics
'''

Examples:

'''text
(mu_model, L_model) = NN_phi(context)
Sigma_model = L_model L_model^T + eps I
'''

or

'''text

```

```

c_{k+1} = f_phi(c_k, context) + eta.
'''

Train it primarily on normal/mismatch records. Evaluate whether it improves:

- hard/OOD support recovery;
- probability calibration;
- false extra-event rate;
- hidden-state credible-interval coverage.

Only if necessary add a second, smaller learned correction to the **physical candidate log evidence**:

'''text
ell_hybrid,j = ell_physics,j + beta * Deltaell_phi,j
'''

with strict ablations. A direct raw-waveform classifier must remain an external baseline, not the proposed estimator.

---

# 18. Tests required

Add unit/integration tests for at least:

- Ybus/tap/shunt construction;
- branch terminal current formulas and direction;
- angle gauge invariance;
- power balance;
- event intervention semantics;
- persistent line status after trip;
- transient fault clearing;
- generator/load setpoint semantics in ANDES;
- PMU dropout masks;
- deterministic seed manifests;
- log-likelihood equivalence versus brute-force Gaussian evaluation on tiny matrices;
- Woodbury/determinant-lemma implementation;
- exact 0/1/2 support posterior normalization;
- marginal inclusion probabilities;
- Schur-complement marginalization;
- fixed-lag versus batch solution on a tiny linear-Gaussian reference problem;
- no hidden-state leakage into estimator inputs;
- train/test scenario split leakage audit.

---

# 19. Paper-ready outputs

For every experiment automatically write:

'''text
output/manifests/<experiment>/<run_id>.json
output/results/<experiment>/per_case.parquet
output/results/<experiment>/summary.csv
output/plots/<experiment>/*.pdf or *.png
output/reports/<experiment>.md
'''

Create a final consolidated report containing:

- exact equations/model versions;
- scenario counts;
- rejection counts and reasons;
- state-reconstruction tables;
- event-support tables;
- calibration plots;
- distinguishability atlas;
- PMU-loss heatmap;
- severity curves;
- OOD curves;
- runtime/scalability;
- ablation table;
- explicit list of failed hypotheses and unresolved limitations.

No cherry-picking. Every planned experiment has a row in a registry with status 'PASS', 'FAIL', 'SKIPPED_WITH_REASON', or 'PENDING'.

---

# 20. Implementation order

Execute in this order and commit after each completed block:

1. environment + folder scaffold;
2. canonical IEEE-39 + ANDES/pandapower static parity;
3. PMU measurement operator audit;
4. scenario/event/noise generator;
5. virtual-PMU extraction;
6. baseline state estimator and fixed-lag smoother;
7. observability/functional-observability analysis;
8. exact 0/1/2 Bayesian event oracle;
9. model-discrepancy layer;
10. single/double/sequential event battery;
11. scalable 3+ event solver;
12. explicit IBR scenarios;

```

```

13. probability calibration;
14. ML discrepancy extension;
15. baseline comparison;
16. external replay last.

Do not skip directly to ML.

---

# 21. First deliverable I want from you

Create the folder and execute phases 1-4 above. Then return a concise report with:

1. branch/commit;
2. exact package versions;
3. where the ANDES IEEE-39 case came from and what dynamic models it contains;
4. ANDES pandapower static parity table;
5. frozen PMU/terminal-current mapping status;
6. implemented scenario/event/noise API;
7. tests and pass/fail count;
8. any physical-model inconsistencies discovered;
9. the exact command for the smoke suite;
10. the next implementation step.

Do not report a localization accuracy yet unless the parity and measurement gates are already passed.

---

# 22. Scientific target

The final desired object is not a black-box classifier. It is a recursive approximation to

'''text
p(X_{k-N:k}, Theta, Q_{k-N:k}, S_{k-N:k}, C_{k-N:k} | Y_{P,k-N:k})
'''

from which we obtain simultaneously:

'''text
hidden/virtual PMUs at 31 unobserved buses,
state covariance/credible intervals,
P(number of physical events),
P(each source is active),
family/source/onset/severity posterior,
model-discrepancy posterior,
held-out future causal verification.
'''

Known linear-Gaussian Kalman filtering, fixed-lag smoothing, sparse input inversion, and single-event hypothesis testing should
emerge as restricted special cases of this formulation, not as unrelated modules glued together.

Proceed.

```

B. Notas de implementación ANDES y pandapower

ANDES distribuye casos IEEE 14/39 y dispone de power flow, TDS y una estructura **System** con almacenamiento DAE [7, 8]. La documentación de TDS describe integración implícita y configuración de step; para transitorios rápidos se debe usar un internal step apropiado y posteriormente samplear a 30 fps, en vez de obligar al integrador físico a 33.3 ms durante una falla rápida [6]. pandapower distribuye `case39()` y se utilizará como backend independiente para verificar power flow, topología y branch flows [12].

Es importante que el agente inspeccione la versión instalada antes de asumir nombres exactos. Los APIs de investigación cambian. La ecuación/contrato es la fuente de verdad; el wrapper se adapta a la librería, no al revés.

C. Bibliografía mínima

Referencias

- [1] M. Barati, P. Dehghanian, and D. Celeita, “SGSMA 2026 Synchrophasor Anomaly Detection Competition Guide,” Feb. 2026. Documento oficial proporcionado en el proyecto.
- [2] R. E. Kalman, “A New Approach to Linear Filtering and Prediction Problems,” *Journal of Basic Engineering*, vol. 82, no. 1, pp. 35–45, 1960.

- [3] M. Katanić, J. Lygeros, and G. Hug, “Recursive Dynamic State Estimation for Power Systems with an Incomplete Nonlinear DAE Model,” *IET Generation, Transmission & Distribution*, vol. 18, pp. 3657–3668, 2024, doi:10.1049/gtd2.13308.
- [4] P. Lu, “Simultaneous State and Unknown Input Estimation for Continuous-discrete Stochastic Systems,” arXiv:2005.05211, 2020.
- [5] M. E. Tipping, “Sparse Bayesian Learning and the Relevance Vector Machine,” *Journal of Machine Learning Research*, vol. 1, pp. 211–244, 2001.
- [6] ANDES Project, *ANDES Manual / Stable Documentation*, CURENT, accessed 2026. ANDES is an open-source Python framework for power-system modeling, power flow, time-domain simulation, and DAE-based analysis.
- [7] ANDES Project, “Test Cases,” documentation: IEEE 14- and 39-bus cases are shipped with the package.
- [8] ANDES Project, “System Architecture,” documentation describing `System`, models, routines and `ss.dae`.
- [9] ANDES Project, “Dynamic Control and Setpoint Changes,” documentation on multi-stage TDS and correct dynamic setpoint updates.
- [10] ANDES Project, “Renewable Generator Models,” documentation for REGCA1/REGCP1 and voltage-controlled/VSG converter models including REGCV1.
- [11] ANDES Project, documentation for BusFreq/BusROCOF/PMU measurement models.
- [12] pandapower Project, “Power System Test Cases / case39,” documentation for `pandapower.networks.case39()`.