

Inferencia física y bayesiana con PMU dispersas

Modelos eléctricos, grafos, procesos estocásticos, estimación funcional y orden de distinguibilidad

Una pregunta unificadora

¿Qué parte de una perturbación observada sólo puede ser explicada por el evento de interés, después de admitir incertidumbre física, mediciones parciales y memoria preevento? ¿A qué orden aparece esa diferencia?

$$\underbrace{\mathcal{E}(\vartheta, q)\dot{\xi} = F(\xi, u, \vartheta, q)}_{\text{planta eléctrica híbrida}} \longrightarrow \underbrace{p(S, a_S, \tau_S, \nu, X, Z \mid Y_{\mathcal{P}})}_{\text{inferencia conjunta}}$$
$$\text{dist}_{\Sigma^{-1}}(\Phi_g(a), \mathcal{M}_0) = |a|^{r_g} c_g + o(|a|^{r_g}).$$

Monografía técnica de investigación

Preparada para el proyecto PMU Fault Detection y la revisión del manuscrito con Astra, Claude Code y Codex.

Versión	Teoría depurada y demostraciones completas bajo hipótesis explícitas.
Corte documental	13 de septiembre de 2026. Resultados numéricos del proyecto: reportados hasta LOAD-BAYES-FD-V2; no reproducidos aquí.
Ámbito	IEEE-39, ocho PMU y 31 buses no instrumentados; extensiones SG/IBR, multievento y aprendizaje delimitadas por separado.
Estado científico	No es un artículo listo para envío ni un certificado de novedad. Las pruebas matemáticas no sustituyen la validación del repositorio.
Incluye registro de claims, contraejemplos, arquitectura de inferencia, comprobaciones algebraicas reproducibles y una agenda concreta de falsación.	

Resumen ejecutivo y contrato de lectura

El objetivo final es reconstruir funcionales eléctricos no medidos y atribuir cambios físicos de la red a partir de observaciones PMU dispersas, sin exigir que cada estado interno, carga o parámetro sea identificable. El documento desarrolla una única cadena: ensamblado físico de red y dispositivos; mapa de observación verdadero; DAE híbrida; perturbaciones y sensibilidad; probabilidad sobre incertidumbres; eliminación o marginalización de variables accesorias; y posterior sobre soporte, tiempo y severidad.

La aportación de mayor interés que se desarrolla aquí es una **jerarquía de órdenes de distinguibilidad**. La información de primer orden puede anularse frente a incertidumbres admisibles sin que desaparezca toda evidencia de evento: la curvatura relativa puede conservar una señal de segundo orden. Se demuestra ese resultado con hipótesis locales precisas, se deriva su escala estadística y se conecta con la historia preevento, los sensores y los errores del diccionario físico. La aplicación concreta a IEEE-39 sigue pendiente; las tasas no regulares y la geometría diferencial no se reivindican como invenciones universales.

El modelo físico principal no se reduce a una swing equation: conserva voltajes complejos, corrientes terminales, cargas ZIP, máquinas, controles y restricciones. El Laplaciano electromecánico y la reducción Kron aparecen después, como herramientas con dominios de validez explícitos. Se incluyen modelos representativos de IBR para ampliar la teoría, *sin afirmar que hayan sido implementados o validados en las campañas descritas*.

Cuatro niveles que nunca deben confundirse

[EST]: resultado establecido, reproducido o particularizado con demostración. **[DER]**: derivación desarrollada aquí; correcta bajo sus hipótesis, pero sin certificación de prioridad bibliográfica. **[REP]**: cifra o estado comunicado por el ejecutor del proyecto, sin reproducción independiente en esta entrega. **[HIP]**: aplicación, ventaja experimental o extensión todavía por verificar.

Fuentes internas. El dossier adjunto Se ha pegado el markdown(4).md [P1] es el inventario inicial de ideas. La auditoría posterior de la conversación [P2] corrige sus afirmaciones fuertes. Los reportes comunicados de E04/E06 y LOAD-BAYES-FD-V2 [P3] aportan evidencia experimental declarada. Las correcciones se explicitan: no se sustituyen silenciosamente resultados históricos por hipótesis nuevas.

Límite de procedencia. El PDF maestro anterior, del mismo día, cerraba en V1 y marcaba V2 pendiente. V2 se incorpora aquí desde el reporte posterior de la conversación, no desde CSV del repositorio. El HEAD comunicado para V2 fue 41bf4e9ff; no se afirma que sea el HEAD actual de un repositorio inspeccionado en esta sesión.

Cómo usarlo para el paper. Los teoremas pueden convertirse en resultados formales sólo conservando todas sus hipótesis. Las cifras [REP] requieren enlace a código, manifest, CSV, unidades y commit antes de entrar al manuscrito. Las propuestas [HIP] no deben redactarse en pasado ni incluirse como resultados obtenidos. No se ha ejecutado aquí PowerDynamics ni se ha modificado la campaña de Luna.

Índice

Resumen ejecutivo y contrato de lectura	2
Notación y convenciones	5
1. Modelo eléctrico completo y contrato de medición	5
1.1. Qué sistema se estima y qué evidencia existe	5
1.2. Red de corriente alterna con transformadores	6
1.3. Cargas ZIP y significado real de un evento	6
1.4. Máquina síncrona: variables que no deben eliminarse sin justificación	7
1.5. AVR, gobernador, estabilizador y saturaciones	7
1.6. Extensión IBR: física explícita, todavía no validada por el banco	8
1.7. Mediciones, frecuencia y referencia angular	8
1.8. Eventos híbridos y semántica física	9
2. Teoría de grafos que conserva la física observada	9
2.1. Pasividad del estampado y Laplacianos admisibles	9
2.2. Reducción Kron y medición parcial	10
2.3. Actualización exacta de frontera para perturbaciones de bajo rango	10
2.4. Simetrías del grafo y límites exactos de localización	11
2.5. Descomposición de Hodge: qué demuestra y qué no	11
3. DAE híbrida, sensibilidad y reducción válida	12
3.1. Existencia local y coordenadas consistentes	12
3.2. Variaciones de primer y segundo orden sin eliminar la DAE	12
3.3. Eventos con inicio y secuencia de modos	13
3.4. Resolvente, Green y modos de grafo	13
3.5. Cambios de operador: identidad exacta, interpretación cuidadosa	13
3.6. FD como referencia numérica y su error controlable	14
4. Procesos estocásticos físicamente compatibles	14
4.1. Ruido dentro de una DAE, no sobre restricciones arbitrarias	14
4.2. Procesos de operación y priors sobre grafos	14
4.3. Covarianza temporal de la física linearizada	15
4.4. Blanqueamiento espacio-temporal y filtro de instrumento	15
4.5. Proceso puntual de eventos y configuración híbrida	16
4.6. Likelihood robusta y significado de su escala	16
5. Observabilidad funcional e identificabilidad de estados ocultos	16
5.1. El funcional, no todos los parámetros, es el objetivo	16
5.2. Estado inicial e inputs desconocidos	17
5.3. Versión no lineal correcta sobre una variedad factible	17
5.4. Priors, regularización y error experimental	17
5.5. Más sensores nunca empeoran la información ideal, pero no garantizan un algoritmo mejor	18
6. Información eficiente, nuisance físico e historia preevento	18
6.1. Dos experimentos estadísticos distintos	18
6.2. Covarianza dependiente del evento	19
6.3. El preevento reduce la incertidumbre admisible	19
6.4. Qué puede aprenderse sin atribuirlo erróneamente al evento	20
7. Orden de distinguibilidad: tangentes, curvatura relativa y límites	20
7.1. Definición del problema geométrico local	20
7.2. Ejemplos que distinguen Fisher nula e imposibilidad exacta	21
7.3. Escala estadística y demostración de un límite de detección	22
7.4. Magnitud y signo pueden aparecer a órdenes distintos	22
7.5. Cómo obtener curvatura relativa desde las ecuaciones eléctricas	22
7.6. Estabilidad numérica de un certificado de primer orden	23

8. Inferencia bayesiana de fuente, severidad y soporte	23
8.1. Likelihood física de uno o varios eventos	23
8.2. Severidad física y priors propios	23
8.3. Caso conjugado como prueba de referencia	24
8.4. Por qué la curvatura puede restaurar cobertura sin inflar ruido	24
8.5. Evidencia no conjugada y posterior de soporte	24
8.6. Detección: fuente conocida, búsqueda de fuente y onset	25
8.7. Distancia entre curvas físicas, no sólo entre tangentes	25
8.8. Multievento: amplitud condicional frente a soporte global	25
8.9. Onset desconocido: una degeneración inevitable en eventos débiles	26
9. Estimador recursivo Hybrid-DAE: derivación y garantías locales	26
9.1. Posterior completo y unidad de información	27
9.2. Discretización dinámica y residuos	27
9.3. Iteración Gauss–Newton restringida	28
9.4. Kalman aparece como marginalización gaussiana exacta	28
9.5. RTS y el valor real de observar el futuro	29
9.6. Prior de llegada con normalización de evidencia	29
9.7. Posterior del campo oculto, no sólo del soporte ganador	29
9.8. Fusión distribuida sin contar la evidencia dos veces	30
10. Aprendizaje restringido, error numérico y detección secuencial	30
10.1. Qué puede aprender ML sin reemplazar la evidencia física	30
10.2. Certificar aproximaciones del operador físico mediante evidencia	31
10.3. Por qué KCL, energía y features derivadas no añaden observaciones independientes	31
10.4. Evidencia secuencial con garantía explícita	32
10.5. Open-set, abstención y decisión	32
11. Claims, evidencia experimental y agenda de contribución	33
11.1. Qué proviene de los archivos y qué se desarrolló aquí	33
11.2. Registro experimental depurado	33
11.3. Claims matemáticos admisibles y expresiones que se retiran	34
11.4. Novedad: qué se reconoce y qué se propone investigar	35
11.5. Experimentos que falsarían la propuesta	35
11.6. Arquitectura operativa propuesta, paso a paso	36
11.7. Instrucciones para redactar el artículo desde esta monografía	36
A. Derivadas eléctricas explícitas y unidades	37
A.1. Jacobiano polar de potencia	37
A.2. Derivadas direccionales complejas de primer y segundo orden	37
A.3. La incertidumbre de magnitud y ángulo	37
B. Comprobaciones algebraicas ejecutadas y reproducibilidad	38
B.1. Cómo reproducir las comprobaciones	38
B.2. Qué faltaría para una comprobación física reproducible	39
B.3. Integridad del material recibido	39
Fuentes internas y bibliografía verificada	40
Referencias externas	40

Notación y convenciones

Símbolo	Significado y precaución
$\mathcal{G} = (\mathcal{V}, \mathcal{E})$	Grafo eléctrico. $n = \mathcal{V} $, $m = \mathcal{E} $. No confundir el grafo eléctrico con el grafo de factores de inferencia.
C_f, C_t	Selectores de buses de origen/destino, de tamaño $m \times n$. Incidencia $B = C_f^\top - C_t^\top$.
Y, Y_f, Y_t	Admitancia nodal y operadores de corriente terminal. Complejos; no se presuponen simétricos ni PSD.
V, I, S	Fasores nodales complejos e inyección $S = V \odot \bar{I}$. Inyección positiva hacia la red.
$\mathcal{R}(V)$	Representación real $(\text{Re } V^\top, \text{Im } V^\top)^\top$; para un orden intercalado se utiliza una permutación explícita.
x, z, ξ	Variables diferenciales, algebraicas y descriptor completo $\xi = \text{col}(x, z)$.
ϑ, q, η	Parámetros físicos, configuración híbrida y variables lentas de operación. No se fijan como intercambiables.
$\mathcal{P}, \mathcal{U}$	Buses instrumentados y ocultos. Caso del proyecto: $\mathcal{P} = \{2, 5, 6, 10, 19, 22, 29, 39\}$ y $ \mathcal{U} = 31$.
$h\varphi, \psi$	Operador real de PMU y funcional objetivo, por ejemplo $\psi = \mathcal{R}(V_{\mathcal{U}})$.
S, a_S, τ_S	Soporte de eventos, amplitudes y tiempos. Aquí S como soporte sólo aparece cuando no se usa S para potencia compleja.
ν, N, Γ_ν	Nuisance: variables accesorias inciertas, sensibilidad de sus observaciones y covarianza de un prior propio.
d_g, q_g, q_{ij}	Tangente, coeficiente cuadrático $q_g = \frac{1}{2} \partial_{aa} \Phi_g$ y derivada mixta $q_{ij} = \partial_{a_i a_j} \Phi$. No son matrices Q de ruido.
Q_w, R_v, Σ	Covarianza de proceso, covarianza de medición y covarianza conjunta de una ventana.
$W, P_\perp, G_\nu$	Blanqueador $W\Sigma W^\top = I$, proyector euclídeo en coordenadas blanqueadas y precisión marginal bayesiana.
A_r, B_r, C_r, D_r	Modelo local reducido obtenido por eliminación válida; D_r es feedthrough, no diccionario de eventos.
$\mathcal{I}, \Lambda$	Información Fisher y precisión gaussiana; Λ_Y denota específicamente una admitancia Kron.
$H[\cdot, \cdot]$	Evaluación bilineal de un Hessiano vectorial. q_g incluye 1/2, la derivada mixta no.
$^\top, ^H, \dagger$	Transpuesta, conjugada transpuesta y pseudoinversa de Moore–Penrose. Cada una tiene un papel distinto.
$\preceq$	Orden de Loewner para matrices reales simétricas o hermitianas; no se aplica a Y compleja arbitraria.

Unidades. $a = 0.01$ significa cambio relativo de 1 %. TVE se define como fracción; TVE en porcentaje es 100 veces esa fracción. Las magnitudes eléctricas se expresan en pu con bases declaradas. Los modelos EMT ilustrativos se escriben en unidades coherentes SI; no se mezclan sus derivadas con ecuaciones pu sin transformar bases.

1 Modelo eléctrico completo y contrato de medición

1.1 Qué sistema se estima y qué evidencia existe

El problema tiene dos tareas relacionadas, pero no equivalentes: reconstruir $\psi(\xi) = \mathcal{R}(V_{\mathcal{U}})$ y decidir qué perturbación física explica los datos. Un posterior preciso para el voltaje no implica localización de fuente, y un clasificador correcto no certifica el voltaje de todos los buses. La versión operativa propuesta debe devolver

ambas cantidades y su incertidumbre, o abstenerse cuando la información no alcance.

El banco reportado usa PowerDynamics IEEE-39 con ocho PMU, modelos ZIP, máquinas de sexto orden y controles AVR/TGOV. Las dimensiones $192 = 114 + 78$ y las métricas de validación son [REP], no constantes universales de IEEE-39. La documentación oficial describe la construcción de esta familia de modelos a partir de tablas y componentes [1]. Las ecuaciones siguientes establecen el contrato físico; los bloques representativos de máquinas e IBR no sustituyen los símbolos y parámetros exactos de la versión congelada del software.

1.2 Red de corriente alterna con transformadores

Para la rama $e = (i, j)$ se adopta un tap $t_e = \tau_e e^{j\phi_e}$ en el lado de origen, admitancia serie $y_e = (r_e + jx_e)^{-1}$ y shunts terminales $y_e^{f,sh}, y_e^{t,sh}$. La primitiva es

$$\begin{bmatrix} I_{e,f} \\ I_{e,t} \end{bmatrix} = \begin{bmatrix} (y_e + y_e^{f,sh})/|t_e|^2 & -y_e/t_e^* \\ -y_e/t_e & y_e + y_e^{t,sh} \end{bmatrix} \begin{bmatrix} V_i \\ V_j \end{bmatrix} =: Y_e^{\text{prim}} \begin{bmatrix} V_i \\ V_j \end{bmatrix}. \quad (1.1)$$

Este convenio se inspira en el estampado convencional de admitancias terminales [2]; otra ubicación de shunts o taps requiere cambiar la primitiva, no corregir después el signo de una corriente.

Con $Y_f = \text{diag}(Y_{ff})C_f + \text{diag}(Y_{ft})C_t$ y $Y_t = \text{diag}(Y_{tf})C_f + \text{diag}(Y_{tt})C_t$,

$$I_f = Y_f V, \quad I_t = Y_t V, \quad Y = C_f^T Y_f + C_t^T Y_t + \text{diag}(y^{bus,sh}). \quad (1.2)$$

La red satisface

$$I_G + I_{IBR} - I_L = YV, \quad S^{net} = \text{diag}(V)\overline{YV}. \quad (1.3)$$

Las sumas no deben contar dos veces los shunts incluidos en Y . Si $Y = G + jB_Y$ y $V_i = v_i e^{j\theta_i}$:

$$P_i = v_i \sum_j v_j [G_{ij} \cos \theta_{ij} + B_{Y,ij} \sin \theta_{ij}], \quad (1.4)$$

$$Q_i = v_i \sum_j v_j [G_{ij} \sin \theta_{ij} - B_{Y,ij} \cos \theta_{ij}], \quad \theta_{ij} = \theta_i - \theta_j. \quad (1.5)$$

Éstas son las restricciones AC que deben permanecer en la DAE y en cualquier actualización estática. La magnitud $v_i = \exp \rho_i$ garantiza positividad sin recurrir a recortes posteriores.

1.2.1 Jacobiano físico sin diferencias finitas como definición

Para una perturbación δV y parámetros $\delta \vartheta$,

$$\delta S = \text{diag}(\overline{YV})\delta V + \text{diag}(V)\overline{Y\delta V} + (\delta Y)\overline{V}. \quad (1.6)$$

En forma polar $\delta V = \text{diag}(V)(\delta \rho + j\delta \theta)$. Sustituirlo en (1.6) y separar partes real e imaginaria entrega el Jacobiano exacto. No se asume holomorfía: el conjugado es esencial. Para parámetros de una rama, δY se obtiene diferenciando (1.1) y estampando únicamente sus terminales. Esta localidad será aprovechada por el grafo de factores.

1.3 Cargas ZIP y significado real de un evento

Con consumo positivo P_{L0}, Q_{L0} , tensión relativa $u_i = v_i/v_{i0}$ y coeficientes que suman uno:

$$P_{L,i}(v_i, a_i) = P_{L0,i}(1 + a_i)(k_{PZ,i}u_i^2 + k_{PI,i}u_i + k_{PP,i}), \quad (1.7)$$

$$Q_{L,i}(v_i, a_i) = Q_{L0,i}(1 + a_i)(k_{QZ,i}u_i^2 + k_{QI,i}u_i + k_{QP,i}), \quad (1.8)$$

$$I_{L,i} = \overline{(P_{L,i} + jQ_{L,i})/V_i}. \quad (1.9)$$

El evento del atlas reportado escala conjuntamente P_{set} y Q_{set} a un tiempo fijado. No es una inyección de corriente constante: tanto el consumo como su derivada respecto a v_i dependen de a_i . Así,

$$\frac{\partial P_L}{\partial a} = P_{L0} f_P(u), \quad \frac{\partial^2 P_L}{\partial a \partial v} = \frac{P_{L0}}{v_0} (2k_{PZ}u + k_{PI}). \quad (1.10)$$

Este término mixto explica por qué evento y nuisance no pueden desacoplarse universalmente. El modelo source-only con matriz fija es una aproximación local; no una taxonomía exacta de toda carga ZIP.

Pueden añadirse cargas dinámicas, por ejemplo

$$T_P \dot{p}_f = P_L(v) - p_f, \quad T_Q \dot{q}_f = Q_L(v) - q_f, \quad I_L = \overline{(p_f + j q_f)/V}, \quad (1.11)$$

o motores de inducción con sus estados electromagnéticos. Esas extensiones se declaran [HIP]; no se atribuyen al banco nominal si no constan en su inventario.

1.4 Máquina síncrona: variables que no deben eliminarse sin justificación

Para fijar signos usamos corriente positiva inyectada por el generador. La transformación al marco rotor dq es una rotación ortogonal explícita; un cambio convencional de 90° redefine E_d, E_q y debe aplicarse a todas las ecuaciones.

Una realización representativa de sexto orden, de dos ejes, mantiene $x_G = \text{col}(\delta, \omega, E'_q, E'_d, E''_q, E''_d)$:

$$\dot{\delta} = \omega_b(\omega - 1), \quad (1.12)$$

$$2H\dot{\omega} = \tau_m - \tau_e - D_m(\omega - 1), \quad (1.13)$$

$$T'_{d0} \dot{E}'_q = E_{fd} - E'_q - (X_d - X'_d)i_d, \quad (1.14)$$

$$T'_{q0} \dot{E}'_d = -E'_d + (X_q - X'_q)i_q, \quad (1.15)$$

$$T''_{d0} \dot{E}''_q = E'_q - E''_q - (X'_d - X''_d)i_d, \quad (1.16)$$

$$T''_{q0} \dot{E}''_d = E'_d - E''_d + (X'_q - X''_q)i_q. \quad (1.17)$$

Las restricciones de estator y la conversión electromecánica son

$$v_d = E''_d - R_s i_d + X''_q i_q, \quad v_q = E''_q - R_s i_q - X''_d i_d, \quad (1.18)$$

$$p_e = v_d i_d + v_q i_q, \quad p_{ag} = p_e + R_s(i_d^2 + i_q^2), \quad \tau_e = p_{ag}/\omega. \quad (1.19)$$

La aproximación $\tau_e \simeq p_{ag}$ sólo es válida cerca de $\omega = 1$. También $\tau_m = P_m/\omega$ cuando el gobernador entrega potencia. Modelos Sauer–Pai/GENROU emplean variables de flujo y coeficientes adicionales: (1.17) es un bloque representativo, no una afirmación de identidad símbolo a símbolo con PowerDynamics. La teoría DAE admite cualquiera de esas realizaciones verificadas [3, 6].

Una alternativa más detallada conserva flujos de estator/rotor. En el marco rotor, con corriente entrando a la máquina y $J = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$,

$$\begin{aligned} v_s &= R_s i_s + \dot{\lambda}_s + \omega_e J \lambda_s, & v_r &= R_r i_r + \dot{\lambda}_r, \\ \text{col}(\lambda_s, \lambda_r) &= \mathcal{L} \text{col}(i_s, i_r), & \mathcal{L} &= \mathcal{L}^\top \succ 0. \end{aligned} \quad (1.20)$$

Con los devanados amortiguadores en cortocircuito, sus entradas v_r son cero; el campo conserva su excitación. La DAE de mayor fidelidad mantiene estos flujos, la energía magnética y la mecánica. El cambio a un modelo de favor transitorio requiere hipótesis sobre las escalas del estator, no borrar estados porque son difíciles de estimar.

1.5 AVR, gobernador, estabilizador y saturaciones

Un AVR de tipo amplificador–excitador–realimentación puede representarse por

$$T_R \dot{v}_m = |V| - v_m, \quad T_F \dot{z}_F = E_{fd} - z_F, \quad (1.21)$$

$$v_F = (K_F/T_F)(E_{fd} - z_F), \quad (1.22)$$

$$T_A \dot{v}_R = K_A(V_{ref} - v_m - v_F + v_{PSS}) - v_R, \quad (1.23)$$

$$T_E \dot{E}_{fd} = v_R - [K_E + S_E(E_{fd})]E_{fd}. \quad (1.24)$$

Los límites de v_R, E_{fd} se modelan mediante ecuaciones híbridas/antiwindup; una trayectoria que cruza un límite no es necesariamente C^2 respecto a su amplitud. Los resultados de Taylor de esta monografía requieren una secuencia de modos fija o sensibilidad híbrida apropiada.

Para el gobernador, una realización del bloque droop–válvula–turbina es

$$T_1 \dot{x}_1 = P_{ref} - (\omega - \omega_{ref})/R_d - x_1, \quad (1.25)$$

$$v = \text{sat}_{[v_{min}, v_{max}]}(x_1), \quad T_3 \dot{x}_2 = v - x_2, \quad (1.26)$$

$$P_m = (T_2/T_3)v + (1 - T_2/T_3)x_2 - D_T(\omega - 1). \quad (1.27)$$

Un PSS puede conservar estados realizables del filtro $K_s \frac{sT_w}{1+sT_w} \frac{1+sT_1^s}{1+sT_2^s} \frac{1+sT_3^s}{1+sT_4^s}$. No se supone su presencia universal: el inventario del banco decide cuáles dispositivos existen.

1.6 Extensión IBR: física explícita, todavía no validada por el banco

Una red con convertidores no se representa adecuadamente cambiando sólo H . En un marco síncrono de velocidad ω_0 , un filtro LCL representativo satisface

$$L_f \dot{i}_f = v_{inv} - v_c - R_f i_f - \omega_0 L_f J i_f, \quad (1.28)$$

$$C_f \dot{v}_c = i_f - i_g - \omega_0 C_f J v_c, \quad (1.29)$$

$$L_g \dot{i}_g = v_c - v_b - R_g i_g - \omega_0 L_g J i_g, \quad (1.30)$$

$$C_{dc} V_{dc} \dot{V}_{dc} = P_{dc} - P_{ac} - P_{loss}. \quad (1.31)$$

Se define $P = \kappa v_b^\top i_g$ y $Q = \kappa(v_{b,q} i_{g,d} - v_{b,d} i_{g,q})$, donde κ depende de la normalización Clarke/Park. Suprimirlo exige justificar las bases.

Grid-following. Una PLL mantiene $\dot{z}_{PLL} = v_q^{PLL}$, $\hat{\omega} = \omega_0 + k_{p,PLL} v_q^{PLL} + k_{i,PLL} z_{PLL}$ y $\hat{\delta} = \hat{\omega} - \omega_0$. Para $|V| > v_{min}$,

$$\begin{bmatrix} i_d^{ref} \\ i_q^{ref} \end{bmatrix} = \frac{1}{\kappa(v_d^2 + v_q^2)} \begin{bmatrix} v_d & v_q \\ v_q & -v_d \end{bmatrix} \begin{bmatrix} P^{ref} \\ Q^{ref} \end{bmatrix}. \quad (1.32)$$

El lazo de corriente conserva un integrador $\dot{z}_i = i^{ref} - i_f$ y una orden $v_{inv}^{cmd} = v_c + R_f i_f + \hat{\omega} L_f J i_f + K_p(i^{ref} - i_f) + K_i z_i$, con límites y retardo si el modelo los requiere.

Grid-forming. Una opción representativa mantiene

$$\dot{\delta}_c = \omega_c - \omega_0, \quad M_v \dot{\omega}_c = P^{ref} - P_f - D_v(\omega_c - \omega_0), \quad (1.33)$$

$$T_p \dot{P}_f = P - P_f, \quad T_q \dot{Q}_f = Q - Q_f, \quad E^{ref} = E_0 + n_q(Q^{ref} - Q_f). \quad (1.34)$$

El lazo de voltaje y el de corriente se acoplan al LCL. Saturación de corriente, dinámica DC, protecciones y modos de soporte de tensión deben permanecer cuando sean relevantes. Estos bloques son [HIP] para futuras campañas IBR. Ningún resultado reportado sobre máquinas síncronas demuestra automáticamente desempeño con PLL/GFM o conmutación de límites.

1.7 Mediciones, frecuencia y referencia angular

El vector primario del proyecto es de 32 canales reales: ocho voltajes y ocho corrientes terminales complejas. Formalmente,

$$y_k = M_k \{h_p(x_k, z_k, \vartheta, q) + b_k\} + v_k, \quad (1.35)$$

donde M_k selecciona canales disponibles, no los sustituye por ceros. Las corrientes nodales completas no se observan salvo evidencia explícita del mapa CT.

La frecuencia ideal relativa al marco es $f = f_0 + \dot{\theta}/(2\pi)$; un instrumento real aplica ventanas, filtros y estimación fasorial. Si f y ROCOF se calculan determinísticamente de la misma historia de voltaje ya utilizada, no son observaciones independientes. Debe propagarse la covarianza conjunta de la transformación.

El slack de PF, la referencia de fase y la sincronización de PMU son conceptos distintos. Elegir otra referencia matemática es legítimo si se transforman también y_0 , h , Σ y las restricciones. El reporte E06-G señaló bus 31 como slack de *su variante*; bus 39 no debe imponerse como slack por analogía con otra variante. Esa afirmación es [REP] y exige contrastar el archivo de buses del caso congelado.

1.8 Eventos híbridos y semántica física

Un evento se identifica por marca g , instante τ y amplitud a . Para carga, $Pset^+ = (1 + a)Pset^-$; para una línea, $q_e^+ = 0$ altera su primitiva; un shunt agrega una admitancia; una falla de sensor modifica la observación. No todos son la misma suma $q^+ = q^- + a$: puede emplearse $\log Pset$ para saltos aditivos, o una transición discreta para interruptores.

Si el modelo fasorial no requiere reset diferencial,

$$x(\tau^+) = x(\tau^-), \quad 0 = g(x(\tau^+), z(\tau^+), q^+, \vartheta). \quad (1.36)$$

Las algebraicas pueden saltar. En un modelo EMT con capacitores e inductores, sus estados almacenados continúan salvo impulsos físicamente modelados. Reinicializar todo al equilibrio postevento elimina el transitorio que se quiere identificar y define otro experimento.

2 Teoría de grafos que conserva la física observada

2.1 Pasividad del estampado y Laplacianos admisibles

Proposición 2.1 (Potencia disipada por el grafo eléctrico; [DER]). Para ramas pasivas de (1.1), con $\text{Re } y_e \geq 0$ y conductancias shunt no negativas, se cumple $\text{Re}(V^H Y V) \geq 0$. Esto no implica que Y sea real, simétrica ni un Laplaciano PSD.

Demostración. Defina la fila a_e por $(a_e V) = V_i / t_e - V_j$. La parte serie de la admitancia estampada es $y_e a_e^H a_e$. Por tanto $V^H (y_e a_e^H a_e) V = y_e |a_e V|^2$ y su parte real es no negativa. Los shunts contribuyen $g_i |V_i|^2$ después del escalado del tap. La suma de las contribuciones es exactamente $\text{Re}(V^H Y V)$. Una admitancia imaginaria y un tap de fase muestran que la matriz resultante no tiene por qué ser real o simétrica, aunque su parte hermitiana sea semidefinida positiva. $\square$

Para análisis espectral real se puede construir un grafo auxiliar $L_w = B \text{diag}(w_e) B^T$ con $w_e > 0$, explicitando si w_e es susceptancia efectiva, módulo de admitancia o un peso de prior. Sólo bajo hipótesis electromecánicas específicas ese L_w coincide con el Jacobiano físico.

Proposición 2.2 (Laplaciano incremental y energía swing; [EST]). En una red lossless con magnitudes constantes, acoplamientos $b_e > 0$ y potencial

$$U(\delta) = \sum_e b_e v_i v_j [1 - \cos((B^T \delta)_e)],$$

se tiene $\nabla U = B \text{diag}(b_e v_i v_j) \sin(B^T \delta)$ y

$$\nabla^2 U(\delta^*) = B \text{diag}(b_e v_i v_j \cos((B^T \delta^*)_e)) B^T.$$

Si todos los cosenos son positivos y el grafo es conexo, el núcleo es $\text{span}\{\mathbf{1}\}$. Para $M\ddot{\delta} + D\dot{\delta} + \nabla U = u$, con $M \succ 0$, $D \succeq 0$, la energía $\mathcal{H} = \frac{1}{2} \dot{\delta}^T M \dot{\delta} + U$ cumple $\dot{\mathcal{H}} = -\dot{\delta}^T D \dot{\delta} + \dot{\delta}^T u$.

Demostración. La regla de la cadena proporciona las dos derivadas. Para cualquier v , $v^T \nabla^2 U v = \sum_e w_e (B^T v)_e^2$. Si $w_e > 0$, se anula exactamente cuando $B^T v = 0$, es decir, v es constante en cada componente conexa. La derivada de energía es $\dot{\delta}^T M \ddot{\delta} + \nabla U^T \dot{\delta}$; sustituir la ecuación dinámica cancela ∇U y da la identidad. $\square$

Esta identidad es una comprobación de modelo, no una likelihood adicional independiente de las PMU. No se aplica sin cambios a pérdidas AC, excitadores, convertidores o límites. La estructura de sincronización y reducción eléctrica está ampliamente estudiada [4].

2.2 Reducción Kron y medición parcial

Particione buses en P y U , sin asumir que P sea una frontera física completa. Sea $G = Y_{UU}^{-1}$. Entonces

$$V_U = G(I_U - Y_{UP}V_P), \quad (2.1)$$

$$I_P = \Lambda_Y V_P + T I_U, \quad \Lambda_Y = Y_{PP} - Y_{PU} G Y_{UP}, \quad T = Y_{PU} G. \quad (2.2)$$

Estas identidades exigen invertibilidad de Y_{UU} ; no la garantizan sólo contar buses. Los resultados clásicos de Kron ofrecen condiciones para redes resistivas/Laplacianas [4].

Proposición 2.3 (Eliminación compatible con los sensores; [DER]). Si una medición lineal compleja se escribe $y = H_P V_P + H_U V_U$, entonces

$$y = (H_P - H_U G Y_{UP}) V_P + H_U G I_U. \quad (2.3)$$

No es necesario observar I_P para usar esta eliminación; sí es necesario utilizar el verdadero H de corrientes terminales/voltajes.

Demostración. Sustituya la primera identidad de (2.2) en y . Agrupando los términos que multiplican V_P e I_U se obtiene (2.3). La operación es algebraica y no añade datos. $\square$

Cuando cambia una fuente interior y la red permanece fija, $\Delta I_P = \Lambda_Y \Delta V_P + T \Delta I_U$. La expresión $T \Delta I_U$ por sí sola corresponde a mantener V_P fijo, no al experimento pasivo general.

2.3 Actualización exacta de frontera para perturbaciones de bajo rango

La actualización interior de rango uno no es una contribución nueva: está incluida en el análisis de sensibilidad de Dörfler y Bullo [4]. La siguiente forma organiza además casos no simétricos y perturbaciones mixtas P/U .

Teorema 2.4 (Schur actualizado con factores izquierdos y derechos; [DER]). Sea Y_{UU} invertible y $Y' = Y + U \Theta Z^\top$, con $U, Z \in \mathbb{C}^{n \times r}$. Defina

$$L_b = U_P - Y_{PU} G U_U, \quad R_b^\top = Z_P^\top - Z_U^\top G Y_{UP}, \quad (2.4)$$

$$K = Z_U^\top G U_U, \quad \Omega = \Theta(I + K \Theta)^{-1}. \quad (2.5)$$

Si $I + K \Theta$ es invertible, el nuevo bloque interior lo es y

$$\boxed{\Lambda'_Y - \Lambda_Y = L_b \Omega R_b^\top}. \quad (2.6)$$

No se requiere que Θ sea invertible, que Y sea simétrica o que Θ represente un único evento físico.

Demostración. Primero, multiplicando directamente se verifica

$$(Y_{UU} + U_U \Theta Z_U^\top)^{-1} = G - G U_U \Omega Z_U^\top G,$$

porque $\Omega + \Omega K \Theta = \Theta$. La identidad también implica $\Theta - \Theta K \Omega = \Omega$; proviene de $\Theta(I + K \Theta)^{-1} = (I + \Theta K)^{-1} \Theta$. Escriba el nuevo Schur:

$$\begin{aligned} \Lambda'_Y &= Y_{PP} + U_P \Theta Z_P^\top \\ &\quad - (Y_{PU} + U_P \Theta Z_U^\top)(G - G U_U \Omega Z_U^\top G)(Y_{UP} + U_U \Theta Z_P^\top). \end{aligned}$$

Reste $\Lambda_Y = Y_{PP} - Y_{PU} G Y_{UP}$. Los coeficientes de $U_P Z_P^\top$, $Y_{PU} G U_U Z_P^\top$, $U_P Z_U^\top G Y_{UP}$ y $Y_{PU} G U_U Z_U^\top G Y_{UP}$ se simplifican, usando las identidades de Ω , a Ω , $-\Omega$, $-\Omega$, Ω , respectivamente. Por tanto el resultado se factoriza como $(U_P - Y_{PU} G U_U) \Omega (Z_P^\top - Z_U^\top G Y_{UP})$. La inversa interior verificada al principio concluye la prueba. $\square$

Corolario 2.5 (Rango y caso interior simétrico). Se tiene $\text{rank}(\Delta \Lambda_Y) \leq r$. Si $U_P = Z_P = 0$, $U_U = Z_U = b$, $Y = Y^\top$ y $\Theta = \theta$, entonces

$$\Delta \Lambda_Y = \frac{\theta}{1 + \theta b^\top G b} u u^\top, \quad u = Y_{PU} G b.$$

Demostración. El rango del producto de (2.6) es como máximo el de Ω , que no supera r . En el caso particular, $L_b = -Y_{PU}Gb = -u$ y $R_b^\top = -u^\top$; ambos signos se cancelan. $\square$

Interpretación limitada. Una rama π puede producir una actualización de rango dos por charging. Si $t = 1$, su primitiva tiene autovalores y^{sh} y $2y + y^{sh}$ cuando los shunts terminales son iguales; ambos pueden ser no nulos. Por tanto el rango observado no cuenta universalmente líneas, fallas ni cardinalidad. Además, la matriz Λ_Y no está directamente medida por nuestro mapa de ocho corrientes terminales.

2.4 Simetrías del grafo y límites exactos de localización

Teorema 2.6 (Simetría física que preserva sensores; [EST]). Considere dos sistemas descriptor con el mismo lápiz regular $sE - A$ y entradas B_g, B_j . Suponga que existe una permutación ortogonal P tal que $PE = EP$, $PA = AP$, $CP = C$, $B_j = PB_g$ y $D_j = D_g$. Entonces

$$C(sE - A)^{-1}B_j + D_j = C(sE - A)^{-1}B_g + D_g.$$

Si también se preservan las leyes de condición inicial y ruido, las distribuciones observadas son idénticas para el mismo perfil de entrada. Ningún decisor basado exclusivamente en esas observaciones puede distinguir las dos hipótesis con error Bayesiano inferior a $1/2$ bajo priors iguales.

Demostración. Para s fuera del espectro, $P(sE - A) = (sE - A)P$ implica que P conmuta con el resolvente. Por tanto $C(sE - A)^{-1}PB_g = CP(sE - A)^{-1}B_g = C(sE - A)^{-1}B_g$. El feedthrough también coincide. Las respuestas deterministas son iguales; las leyes preservadas de ruido/estado inicial hacen iguales las distribuciones completas. Si su densidad común es p , el error de cualquier regla δ es $\frac{1}{2} \int 1_{\delta=j} p + \frac{1}{2} \int 1_{\delta=g} p = 1/2$. $\square$

La simetría de la adyacencia sola no basta: los parámetros de máquinas, transformadores, controles, puntos de operación y canales PMU también deben respetarla. Los vínculos entre simetría y observabilidad tienen antecedentes [19, 9].




Figura 1: Ejemplo conceptual de indistinguibilidad. No representa la topología IEEE-39 ni afirma que ese par simétrico exista en el banco.

2.5 Descomposición de Hodge: qué demuestra y qué no

Para una red sin taps, sea B la incidencia y $\zeta = Z_e i^{series} = B^\top V$. Defina

$$P_{grad} = B^\top (BB^\top)^\dagger B, \quad P_{cyc} = I - P_{grad}.$$

Proposición 2.7 (Ortogonalidad corte-ciclo; [EST]). P_{grad} es el proyector ortogonal sobre $\text{range}(B^\top)$ y P_{cyc} sobre $\ker B$. Toda señal de caída $\zeta = B^\top V$ cumple $P_{cyc}\zeta = 0$.

Demostración. Tome una SVD $B = U\Sigma V^\top$ con rango r . Entonces $B^\top (BB^\top)^\dagger B = V_r V_r^\top$, simétrica e idempotente. Su imagen es $\text{range}(B^\top)$; el complemento ortogonal es $\ker B$. Aplicarlo a $B^\top V$ da cero. $\square$

Los shunts exigen separar corriente serie de corriente terminal. Los taps sustituyen el gradiente simple por un operador de conexión generalizado. Con corrientes faltantes, un residuo de ciclo construido a partir de corrientes *reconstruidas usando el mismo modelo* puede ser cero por construcción. No constituye evidencia independiente contra una falla. Su uso legítimo es como restricción o como diagnóstico sobre canales realmente medidos, con covarianza conjunta.

3 DAE híbrida, sensibilidad y reducción válida

3.1 Existencia local y coordenadas consistentes

Considere un modo híbrido fijo q y

$$M_x(\vartheta)\dot{x} = f(x, z, u, \vartheta), \quad 0 = g(x, z, u, \vartheta). \quad (3.1)$$

Se supone en un entorno: f, g de clase C^3 , M_x invertible, g_z invertible, entradas regulares entre eventos y una condición inicial consistente. El teorema de función implícita da $z = \phi(x, u, \vartheta)$ y una ODE local bien definida. Las variables con coeficiente diferencial cero se incluyen en z antes de usar esta hipótesis. Si el índice es mayor o hay restricciones adicionales, debe construirse un chart de la variedad consistente o utilizar un solver descriptor adecuado; no se aplica una pseudoinversa informal de M_x .

La formulación DAE sigue siendo el modelo principal. La eliminación local que sigue es un instrumento de análisis y preconditionamiento. Los estimadores DAE con modelos incompletos y variantes de Kalman iterado ya tienen antecedentes directos en power systems [7].

Proposición 3.1 (Modelo local y feedthrough algebraico; [EST]). En un equilibrio consistente, denote por $f_x, f_z, f_u, g_x, g_z, g_u$ los Jacobianos sin normalizar. Para $\delta y = h_x \delta x + h_z \delta z + h_u \delta u$ se obtiene

$$A_r = M_x^{-1}(f_x - f_z g_z^{-1} g_x), \quad B_r = M_x^{-1}(f_u - f_z g_z^{-1} g_u), \quad (3.2)$$

$$C_r = h_x - h_z g_z^{-1} g_x, \quad D_r = h_u - h_z g_z^{-1} g_u. \quad (3.3)$$

Demostración. La restricción lineal $g_x \delta x + g_z \delta z + g_u \delta u = 0$ da $\delta z = -g_z^{-1}(g_x \delta x + g_u \delta u)$. Sustitúyase en las ecuaciones diferencial y de observación. Multiplicar la primera por M_x^{-1} produce (3.3). En implementación se resuelven sistemas lineales; no se construyen inversas densas. Si M_x depende de un parámetro perturbado fuera del equilibrio, aparece además el término $-M_\vartheta \dot{x}_0$. $\square$

Para un step puede existir $D_r \delta u \neq 0$ aun cuando $h_u = 0$: el voltaje algebraico reacciona instantáneamente en el modelo fasorial. Ignorarlo desalinearía las primeras muestras del diccionario.

3.2 Variaciones de primer y segundo orden sin eliminar la DAE

Escriba la ecuación completa como

$$\mathcal{F}(\dot{\xi}, \xi, a, t) = 0.$$

Aquí a es la amplitud física que realmente muta el modelo. Considere una familia de soluciones diferenciable, con $s = \partial_a \xi|_0$ y $t_2 = \partial_{aa} \xi|_0$.

Teorema 3.2 (Ecuaciones variacionales descriptor; [DER]). Sea $w = \text{col}(\dot{\xi}, \xi, a)$ y $w_1 = \text{col}(\dot{s}, s, 1)$. Entonces

$$\mathcal{F}_\xi \dot{s} + \mathcal{F}_\xi s + \mathcal{F}_a = 0, \quad (3.4)$$

$$\mathcal{F}_\xi \dot{t}_2 + \mathcal{F}_\xi t_2 + \mathcal{F}_{ww}[w_1, w_1] = 0. \quad (3.5)$$

Si $h = h(\xi, a)$, los coeficientes de observación son

$$d_g(t) = h_\xi s + h_a, \quad (3.6)$$

$$q_g(t) = \frac{1}{2} (h_\xi t_2 + h_{\xi\xi}[s, s] + 2h_{\xi a}s + h_{aa}). \quad (3.7)$$

Demostración. La primera derivada de $\mathcal{F}(w(a)) = 0$ es $\mathcal{F}_w w' = 0$, con $w' = w_1$. Su segunda derivada es $\mathcal{F}_{ww} w'' + \mathcal{F}_{ww}[w', w'] = 0$. Como la segunda derivada de la coordenada a es cero, $w'' = \text{col}(\dot{t}_2, t_2, 0)$ y resulta (3.5). Aplicar la misma regla a $h(\xi(a), a)$ produce (3.7); el factor 1/2 procede del coeficiente de Taylor, no del Hessiano. No se ha invertido la matriz descriptor. $\square$

Para $E(a)\dot{\xi} = F(\xi, a)$ la forma explícita es

$$E_0\dot{s} = F_\xi s + F_a - E_a\dot{\xi}_0, \quad (3.8)$$

$$E_0\dot{t}_2 = F_\xi t_2 + F_{\xi\xi}[s, s] + 2F_{\xi a}s + F_{aa} - 2E_a\dot{s} - E_{aa}\dot{\xi}_0. \quad (3.9)$$

Si E depende también de ξ , se usa (3.5); no se omiten esas derivadas.

Para eventos a_i, a_j , la variación mixta resuelve la misma ecuación lineal con término fuente $\mathcal{F}_{ww}[w_i, w_j]$, y $q_{ij} = \partial_{a_i a_j} h$ no lleva 1/2. Esta construcción permite obtener interacciones físicas sin inventar coeficientes libres.

3.3 Eventos con inicio y secuencia de modos

Para un evento a tiempo fijo τ , el estado diferencial previo es común a todas las amplitudes; por tanto $s_x(\tau^-) = 0$ cuando no hay perturbación preevento. Después del cambio, las sensibilidades algebraicas satisfacen

$$g_x s_x^+ + g_z s_z^+ + g_a = 0.$$

Si no hay reset diferencial, $s_x^+ = s_x^-$. En presencia de un reset $x^+ = \mathcal{R}(x^-, a)$ se deriva también $s_x^+ = \mathcal{R}_x s_x^- + \mathcal{R}_a$.

Para tiempo desconocido τ y una ODE reducida sin reset, el efecto de desplazar levemente el inicio es, después del evento,

$$\partial_\tau x(t) = \Phi(t, \tau) [f^-(x_\tau) - f^+(x_\tau)], \quad (3.10)$$

porque un retraso $\delta\tau$ sustituye durante ese intervalo el flujo nuevo por el anterior. Con guardas dependientes del estado aparece una matriz de saltación. Un test de amplitud a onset fijo no demuestra identificabilidad de onset ni garantiza derivabilidad al cruzar modos.

3.4 Resolvente, Green y modos de grafo

El lápiz regular $sE - A$ define

$$H_g(s) = C(sE - A)^{-1}B_g + D_g^{dir}.$$

La respuesta del evento se obtiene aplicando también su perfil temporal. Una firma de step contiene el factor $1/s$; omitirlo compara impulso contra step. Los inversos sólo están definidos fuera del espectro, y la reducción debe conservar los términos algebraicos.

En la aproximación swing, después de fijar el gauge y reducir a nodos con masas positivas,

$$H_g(s) = C_\delta(Ms^2 + Ds + L_*)^{-1}b_g.$$

Si $D = \gamma M$ y $M^{-1/2}L_*M^{-1/2} = U\Lambda U^\top$,

$$H_g(s) = C_\delta M^{-1/2}U \operatorname{diag}\left(\frac{1}{s^2 + \gamma s + \lambda_\ell}\right)U^\top M^{-1/2}b_g. \quad (3.11)$$

No se supone que esta diagonalización desacople AVR, PLL o todos los 39 buses. Su función es interpretar qué modos son excitados por una fuente y observados por las PMU.

3.5 Cambios de operador: identidad exacta, interpretación cuidadosa

Si $A' = A + U\Theta Z^\top$ y E no cambia, fuera de los polos:

$$(sE - A')^{-1} = R_s + R_s U\Theta(I - Z^\top R_s U\Theta)^{-1}Z^\top R_s, \quad R_s = (sE - A)^{-1}. \quad (3.12)$$

Se verifica multiplicando por $sE - A - U\Theta Z^\top$, del mismo modo que en (2.6). El lema del determinante da

$$\det(sE - A') = \det(sE - A) \det(I - \Theta Z^\top R_s U).$$

La igualdad es racional y se extiende donde corresponda tras cancelaciones. No permite declarar todos los ceros del segundo factor como nuevos polos observables: pueden existir cancelaciones con el primer factor o con B, C .

Cambiar sólo la entrada de un modelo LTI fijo no cambia sus polos. Pero un cambio de carga ZIP mueve el equilibrio y puede cambiar la linearización. Esta invariancia local no constituye un clasificador físico universal de source frente a operator.

3.6 FD como referencia numérica y su error controlable

Proposición 3.3 (Error del diccionario central y Richardson; [EST]). Si Φ es C^5 en a , entonces

$$D_h = \frac{\Phi(h) - \Phi(-h)}{2h} = D + \frac{h^2}{6} \Phi^{(3)}(0) + O(h^4), \quad (3.13)$$

$$D_R = \frac{4D_{h/2} - D_h}{3} = D + O(h^4). \quad (3.14)$$

Si cada simulación tiene error de norma a lo sumo ε_{sim} , el error adicional de D_h está acotado por ε_{sim}/h .

Demostración. Expanda $\Phi(h)$ y $\Phi(-h)$ alrededor de cero. Los términos pares se cancelan al restar; al dividir por $2h$ quedan el primero, el cúbico dividido por 6 y el resto $O(h^4)$. Combinar $D_{h/2}$ y D_h cancela el coeficiente h^2 . Para el error numérico, la diferencia de dos errores de norma menor que ε_{sim} tiene norma a lo sumo $2\varepsilon_{sim}$; dividir por $2h$ da la cota. $\square$

En particular,

$$\Phi(a) - \Phi(0) - aD_h = a^2q + O(a^3) + O(ah^2) + O(a\varepsilon_{sim}/h).$$

Un orden dos observado en un rango no certifica una derivada exacta en amplitudes arbitrariamente pequeñas. Deben estudiarse h , tolerancia TDS, onset y muestreo conjuntamente. Las diferencias finitas de trayectorias son un operador físico numérico legítimo; no se llaman tangente analítica nativa.

4 Procesos estocásticos físicamente compatibles

4.1 Ruido dentro de una DAE, no sobre restricciones arbitrarias

Sea s el conjunto de coordenadas diferenciales e incertidumbres físicas continuas que parametrizan localmente la variedad consistente, y $z = \phi_q(s)$. Modele

$$ds = \beta_q(s)dt + G_q(s)dW_t, \quad z = \phi_q(s). \quad (4.1)$$

No se añade un Browniano independiente a $g = 0$ y después se espera conservar KCL. Los procesos admisibles actúan en cargas, controles, parámetros o estados; la respuesta algebraica resulta de la restricción.

Proposición 4.1 (Consistencia estocástica local de las algebraicas; [DER]). Si ϕ_q es C^2 y (4.1) admite solución, entonces

$$dz = \left[D\phi_q \beta_q + \frac{1}{2} \sum_{\ell} D^2\phi_q [G_{q,\ell}, G_{q,\ell}] \right] dt + D\phi_q G_q dW_t, \quad (4.2)$$

y toda restricción $g_q(s, \phi_q(s)) = 0$ se mantiene trayectoria a trayectoria hasta salir del chart.

Demostración. Aplique Itô a cada componente de $\phi_q(s_t)$. El término de variación cuadrática es exactamente la suma de Hessianos de (4.2). Como la función $s \mapsto g_q(s, \phi_q(s))$ es idénticamente cero, su gradiente y Hessiano también son cero. Una segunda aplicación de Itô a esa composición da diferencial nulo. En un salto $q^+ \neq q^-$ se asigna $z^+ = \phi_{q^+}(s^+)$; la fórmula continua sólo vale entre saltos. $\square$

El término Itô no aparece en la versión Stratonovich de la regla de cadena, pero entonces cambia la deriva equivalente. La convención estocástica debe fijarse antes de derivar likelihoods.

4.2 Procesos de operación y priors sobre grafos

Para fluctuaciones lentas, una opción lineal es

$$d\eta = -F_\eta(\eta - \bar{\eta})dt + G_\eta dW_\eta. \quad (4.3)$$

Los coeficientes de carga, despacho e impedancia deben respetar positividad o dominios físicos; log-parámetros y transformaciones simplex son preferibles a gaussianas que generen valores imposibles. El prior representa incertidumbre, no datos adicionales.

Sea $L_w = B \text{diag}(w_e) B^\top \succeq 0$ con pesos positivos documentados. Defina

$$Q_G = \tau(\kappa^2 I + L_w)^\alpha, \quad \kappa, \tau > 0. \quad (4.4)$$

Este es un prior tipo Matérn sobre grafo, con antecedente explícito [13]. Para α entero positivo, su precisión tiene alcance finito en potencias del grafo; para α fraccionario generalmente es densa. No debe llamarse GMRF local de un salto a cualquier potencia fraccionaria.

Proposición 4.2 (Difusión de grafo con prior estacionario prescrito; [DER]). Si $Q_G \succ 0$ es simétrica, el proceso

$$d\eta = -\gamma Q_G \eta dt + \sqrt{2\gamma} dW_t, \quad \gamma > 0,$$

tiene distribución estacionaria $\mathcal{N}(0, Q_G^{-1})$.

Demostración. Diagonalice $Q_G = U \text{diag}(q_i) U^\top$, $q_i > 0$. En coordenadas $z = U^\top \eta$ cada componente satisface $dz_i = -\gamma q_i z_i dt + \sqrt{2\gamma} d\tilde{W}_i$. Su solución es $z_i(t) = e^{-\gamma q_i t} z_i(0) + \sqrt{2\gamma} \int_0^t e^{-\gamma q_i(t-s)} d\tilde{W}_i(s)$. La varianza del término estocástico es $(1 - e^{-2\gamma q_i t})/q_i$. En el límite la media es cero y la covarianza diagonal es $1/q_i$; al volver a η , es Q_G^{-1} . $\square$

Con $\kappa = 0$ y grafo conexo, la dirección constante no tiene distribución estacionaria propia. Debe condicionarse/-fijarse el modo o mantener una covarianza no estacionaria, no añadir una inversa ficticia del Laplaciano.

4.3 Covarianza temporal de la física linearizada

Para $dx = Axdt + L_w dW$, con A Hurwitz, la solución estacionaria tiene

$$P = \int_0^\infty e^{At} L_w L_w^\top e^{A^\top t} dt, \quad AP + PA^\top + L_w L_w^\top = 0. \quad (4.5)$$

Demostración. La integral converge porque A es Hurwitz. Derivar $e^{At} L_w L_w^\top e^{A^\top t}$ y luego integrar de cero a infinito da $AP + PA^\top = -L_w L_w^\top$. La solución estocástica lineal y la isometría de Itô producen esa misma covarianza. Si A tiene un modo neutro excitado, la convergencia no está garantizada. $\square$

Para $y = Cx + v$, la covarianza de dos tiempos contiene $Ce^{A|t-s|} P C^\top$ con la orientación temporal correcta, más la del sensor. En frecuencia,

$$S_y(\omega) = C(j\omega I - A)^{-1} L_w L_w^\top (-j\omega I - A^\top)^{-1} C^\top + S_v(\omega).$$

Esta PSD requiere un proceso estacionario y no describe por sí sola un step persistente. Para ventanas finitas se construye la covarianza conjunta directamente.

4.4 Blanqueamiento espacio-temporal y filtro de instrumento

Si una ventana contiene T muestras de p canales, $r \in \mathbb{R}^{Tp}$ tiene covarianza Σ . Un modelo separable es $\Sigma = K_t \otimes R_c$ sólo para el orden de vectorización correspondiente. Un AR(1) estacionario tiene $(K_t)_{ij} = \rho^{|i-j|}$, $|\rho| < 1$. La alternativa no separable usa estados del sensor y de la física en una representación conjunta.

Si $\Sigma = LL^\top$, se aplica $\bar{r} = L^{-1}r$ mediante solve triangular. El NIS de una innovación de dimensión p es $v^\top S^{-1}v$; bajo modelo gaussiano correcto tiene media p , mientras el NIS normalizado divide por p . No son intercambiables las cifras cercanas a 1 y a 32.

El ACF de la norma de una innovación, el ACF de cada canal blanqueado y la correlación cruzada no son el mismo test. Tampoco se concatenan ventanas independientes creando pares temporales ficticios en sus fronteras. Un Ljung–Box con $p > 0.05$ indica no rechazo en ese test; no prueba ruido blanco universal.

4.5 Proceso puntual de eventos y configuración híbrida

Sea $N(dt, dg, da)$ una medida de conteo marcada con intensidad predecible $\lambda_g(t \mid \mathcal{F}_t^-) \pi_g(a) dt da$. La configuración se actualiza mediante un mapa físico $q^+ = \mathcal{R}_q(q^-, g, a)$. Para una secuencia observada de marcas, la densidad del proceso puntual contiene

$$p(\{\tau_j, g_j, a_j\}) \propto \exp \left[- \int_0^T \sum_g \lambda_g(t) dt \right] \prod_j \lambda_{g_j}(\tau_j) \pi_{g_j}(a_j). \quad (4.6)$$

Esto permite cardinalidad y onset sin forzar una clase única por ventana. Un proceso de Poisson continuo simple asigna probabilidad cero a dos tiempos exactamente iguales: los eventos simultáneos se modelan mediante una marca de soporte conjunto, resolución temporal discreta o un mecanismo común. No se supone simultaneidad exacta dentro de un prior que la excluye.

4.6 Likelihood robusta y significado de su escala

La referencia gaussiana utiliza la covarianza conjunta de ventana. Una extensión Student- t multivariante de dimensión p puede escribirse

$$p(r) \propto |\Omega|^{-1/2} \left(1 + \frac{(r - \mu)^\top \Omega^{-1} (r - \mu)}{\nu_t} \right)^{-(\nu_t + p)/2}.$$

Ω es matriz de escala, no covarianza; si $\nu_t > 2$, la covarianza es $\nu_t \Omega / (\nu_t - 2)$. Un único factor latente de escala compartido produce dependencia entre todos los canales, distinta de un Student- t independiente por frame. Esta alternativa sólo se promueve si datos CAL independientes justifican colas pesadas; no para absorber errores físicos sin diagnóstico.

5 Observabilidad funcional e identificabilidad de estados ocultos

5.1 El funcional, no todos los parámetros, es el objetivo

La reconstrucción propuesta evalúa $\psi = \mathcal{R}(V_{\mathcal{U}})$. Puede haber muchas cargas y estados internos compatibles con las mismas PMU. Lo importante es si esas explicaciones producen el mismo ψ , o al menos una dispersión cuantificable. La teoría de observabilidad funcional y sus versiones no lineales ya existe [5]; se particulariza aquí conservando restricciones y nuisance.

Teorema 5.1 (Reconstrucción funcional lineal exacta; [EST]). Para $y = Ox$ y $\psi = Lx$, son equivalentes:

- (i) $Ox_1 = Ox_2$ implica $Lx_1 = Lx_2$;
- (ii) $\ker O \subseteq \ker L$;
- (iii) existe K tal que $L = KO$.

Entonces $\psi = Ky$ es una reconstrucción exacta. Para un sistema dinámico con entradas conocidas se aplica con $O = \text{col}(C, CA_d, \dots, CA_d^N)$, después de descontar las entradas.

Demostración. (i) $\Rightarrow$ (ii): para $v \in \ker O$, las observaciones de v y 0 coinciden, así que $Lv = 0$. (ii) $\Rightarrow$ (i): aplique la inclusión a $x_1 - x_2$. Para (ii) $\Rightarrow$ (iii), defina sobre $\text{range } O$ el mapa $K(Ox) = Lx$. Está bien definido por (i), es lineal y puede extenderse linealmente a todo el espacio de observación. La composición satisface $KO = L$. Finalmente, si $L = KO$, cualquier vector anulado por O es anulado por L . $\square$

Teorema 5.2 (Estimador lineal insesgado óptimo de un funcional; [EST]). Sea $y = Ox + \epsilon$, $\epsilon \sim \mathcal{N}(0, \Sigma)$, $\Sigma \succ 0$. Si $\ker O \subseteq \ker L$, defina $J = O^\top \Sigma^{-1} O$. Entonces

$$\hat{\psi}_* = LJ^\dagger O^\top \Sigma^{-1} y, \quad \text{Cov}(\hat{\psi}_*) = LJ^\dagger L^\top.$$

Es insesgado y tiene mínima covarianza entre estimadores lineales insesgados. Si la inclusión falla, no existe un estimador insesgado de Lx para todos los x .

Demostración. J y O tienen el mismo núcleo, porque $v^\top Jv = \|\Sigma^{-1/2}Ov\|^2$. Por tanto $LJ^\dagger J = L$ y la media del estimador es Lx . Su covarianza es $LJ^\dagger JJ^\dagger L^\top = LJ^\dagger L^\top$. Sea K y otro estimador lineal insesgado, $KO = L$, y escriba $K = K_* + T$. Entonces $TO = 0$ y $K_*\Sigma T^\top = LJ^\dagger O^\top T^\top = 0$. La covarianza es la óptima más $T\Sigma T^\top \succeq 0$. Si existe $v \in \ker O$ con $Lv \neq 0$, los datos bajo x y $x + v$ tienen la misma ley; cualquier esperanza de un estimador es idéntica en ambos casos y no puede igualar a la vez Lx y $Lx + Lv$. $\square$

Advertencia clave. La fórmula con $J^\dagger$ sólo tiene esa interpretación para funcionales estimables. Si L ve el núcleo, el pseudoinverso asigna cero a direcciones sin información y no produce una cota válida para ellas.

5.2 Estado inicial e inputs desconocidos

Si las observaciones de ventana satisfacen

$$Y_N = O_N x_0 + \mathcal{T}_N u,$$

las perturbaciones indistinguibles pertenecen a $\ker[O_N \ \mathcal{T}_N]$. Para recuperar Lx_0 se aplica el teorema anterior a $[L \ 0]$, no a L y O_N solos. Para inferir inputs dispersos se restringe su clase y se estudia la unicidad de soportes. La estimación de entradas desconocidas con estado inicial incierto tiene antecedentes directos [8].

5.3 Versión no lineal correcta sobre una variedad factible

Sea $X = \{\chi : g(\chi) = 0\}$ y g de rango constante completo sobre sus ecuaciones independientes. Así X es una variedad regular y $T_\chi X = \ker J_g(\chi)$. Sea $h : X \rightarrow \mathbb{R}^p$ el mapa de datos y $\psi : X \rightarrow \mathbb{R}^r$ el funcional.

Teorema 5.3 (Factorización funcional local bajo rango constante; [DER]). Suponga que $h|_X$ tiene rango constante en un entorno de χ_0 . En un entorno suficientemente pequeño con fibras locales conexas, existe una función suave φ sobre la imagen de h tal que $\psi = \varphi \circ h$ si y sólo si

$$\ker(Dh|_{T_\chi X}) \subseteq \ker(D\psi|_{T_\chi X}) \quad \text{para todo } \chi \text{ del entorno.} \quad (5.1)$$

En coordenadas ambiente, la condición equivale a $\ker \text{col}(J_g, J_h) \subseteq \ker J_\psi$ en ese entorno.

Demostración. Si $\psi = \varphi \circ h$, la regla de la cadena da $D\psi = D\varphi Dh$ sobre tangentes, así que se cumple la inclusión. Recíprocamente, por el teorema de rango constante existen coordenadas locales (s, t) en X y coordenadas en la imagen donde $h(s, t) = (s, 0)$. Su núcleo tangente está generado por las direcciones $\partial/\partial t_i$. La hipótesis implica $\partial\psi/\partial t_i = 0$ para todas ellas en el entorno. Integrando a lo largo de los segmentos de cada fibra local conexa, $\psi(s, t)$ no depende de t . Por tanto $\psi(s, t) = \varphi(s)$, y deshaciendo las coordenadas se obtiene la factorización. La equivalencia ambiente procede de imponer simultáneamente $J_g \delta\chi = 0$ y $J_h \delta\chi = 0$. $\square$

Contraejemplo a la condición en un solo punto. Con $h(x_1, x_2) = x_1$ y $\psi(x_1, x_2) = x_2^2$, en el origen $J_\psi = 0$ y la inclusión se cumple. Sin embargo, todos los puntos $(0, t)$ tienen la misma medida y distintos valores de ψ . La prueba del teorema necesita la condición en un entorno. No se transforma un pequeño residuo de proyección en un certificado no lineal global.

5.4 Priors, regularización y error experimental

Con un prior propio $x \sim \mathcal{N}(m_0, P_0)$,

$$P_{\text{post}} = (P_0^{-1} + O^\top \Sigma^{-1} O)^{-1}$$

es finita aunque O tenga núcleo. En esas direcciones la precisión proviene del prior. Una covarianza posterior finita no demuestra que las PMU identifiquen el funcional sin prior.

Se deben publicar conjuntamente: escalas físicas, espectro singular del operador blanqueado, sensibilidad a tolerancia, contribución del prior y desempeño en direcciones difíciles. Formar $J = O^\top O$ eleva al cuadrado el condicionamiento; una comparación de rangos SVD/Gramiana sólo es válida con umbrales relacionados. Los valores reportados de rango 39/114 y 93–94/114 no pueden fusionarse sin igualar horizonte, operador y tolerancia.

5.5 Más sensores nunca empeoran la información ideal, pero no garantizan un algoritmo mejor

Proposición 5.4 (Monotonía de distancia con observaciones adicionales; [DER]). Sean dos bloques gaussianos con covarianza conjunta fija $\Sigma \succ 0$. Para dos explicaciones con diferencia de medias $\delta = \text{col}(\delta_1, \delta_2)$,

$$\delta^\top \Sigma^{-1} \delta = \delta_1^\top \Sigma_{11}^{-1} \delta_1 + \tilde{\delta}_2^\top \Sigma_{2|1}^{-1} \tilde{\delta}_2,$$

donde $\tilde{\delta}_2 = \delta_2 - \Sigma_{21} \Sigma_{11}^{-1} \delta_1$ y $\Sigma_{2|1} = \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$. Minimizar ambos lados sobre la misma clase de explicaciones nuisance demuestra que la distancia perfilada con ambos bloques no es menor que con el primero.

Demostración. Factorice la gaussiana conjunta en la marginal del primer bloque y la condicional del segundo. El término cuadrático se descompone exactamente como se indica; equivalentemente, se obtiene de la inversa por bloques. El segundo término es no negativo. Para cada nuisance la desigualdad es válida; tomar el ínfimo en la misma clase preserva la desigualdad frente al ínfimo del primer término. $\square$

Si las distancias locales son $c_1|a|^{r_1}$ y $c_{12}|a|^{r_{12}}$, con coeficientes positivos, la desigualdad para todo a pequeño implica $r_{12} \leq r_1$. Añadir sensores puede revelar evidencia a un orden menor; no puede ocultarla en el problema ideal correctamente especificado. Errores de modelo, ruido mal calibrado o una implementación deficiente sí pueden empeorar un estimador concreto.

6 Información eficiente, nuisance físico e historia preevento

6.1 Dos experimentos estadísticos distintos

En una ventana real blanqueable considere

$$r = \mu(a) + Nv + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \Sigma), \quad \Sigma \succ 0. \quad (6.1)$$

El nuisance puede representar estado inicial, operación, parámetros, sesgos o discrepancia. No se presume que todas esas variables sean independientes, observables ni gaussianas en la planta real. Los resultados siguientes delimitan exactamente el caso lineal-gaussiano y su aproximación local. La geometría de score eficiente es establecida [11]; la aplicación eléctrica exige derivar N desde perturbaciones admisibles.

Teorema 6.1 (Proyección eficiente para nuisance determinista; [EST]). Suponga $\mu(a) = ad$ y v determinista desconocido. Sean $W\Sigma W^\top = I$, $\tilde{N} = WN$, $\tilde{d} = Wd$ y $P_\perp = I - \tilde{N}\tilde{N}^\dagger$. La información eficiente de primer orden sobre a es

$$I_{a|v}^{\text{det}} = \tilde{d}^\top P_\perp \tilde{d} = d^\top \Sigma^{-1} d - d^\top \Sigma^{-1} N (N^\top \Sigma^{-1} N)^\dagger N^\top \Sigma^{-1} d. \quad (6.2)$$

Se anula exactamente cuando $d \in \text{range } N$.

Demostración. En coordenadas blanqueadas el score de a es $\tilde{d}^\top \tilde{\epsilon}$ y los scores nuisance generan $\{u^\top \tilde{\epsilon} : u \in \text{range } \tilde{N}\}$. Su producto interno de Fisher es euclídeo porque $\mathbb{E} \tilde{\epsilon} \tilde{\epsilon}^\top = I$. Proyectar $\tilde{d}$ sobre el complemento entrega el score eficiente $(P_\perp \tilde{d})^\top \tilde{\epsilon}$, cuya varianza es $\|P_\perp \tilde{d}\|^2$. Una SVD de $\tilde{N}$ da la igualdad con el pseudoinverso. La norma se anula si y sólo si $\tilde{d}$ pertenece a $\text{range } \tilde{N}$; W invertible conserva esa pertenencia. $\square$

Teorema 6.2 (Marginalización con prior propio y sus límites; [EST]). Si $v \sim \mathcal{N}(m_v, \Gamma)$, $\Gamma \succ 0$, independiente de ϵ , entonces

$$r|a \sim \mathcal{N}(\mu(a) + Nm_v, \Sigma + N\Gamma N^\top), \quad (6.3)$$

$$G_v = (\Sigma + N\Gamma N^\top)^{-1} \quad (6.4)$$

$$= \Sigma^{-1} - \Sigma^{-1} N (\Gamma^{-1} + N^\top \Sigma^{-1} N)^{-1} N^\top \Sigma^{-1}. \quad (6.5)$$

Para $\mu(a) = ad$, $I_{a|v}^{\text{Bayes}} = d^\top G_v d$. Se cumple $0 < G_v \preceq \Sigma^{-1}$. Si $\Gamma = t\Gamma_0$, los límites $t \downarrow 0$ y $t \uparrow \infty$ recuperan respectivamente la precisión sin nuisance y $W^\top P_\perp W$.

Demostración. Una transformación lineal de gaussianas independientes es gaussiana con media y covarianza sumadas. La fórmula de Woodbury se verifica multiplicando el lado derecho por $\Sigma + N\Gamma N^\top$. En coordenadas blanqueadas, $G_v = W^\top (I + \bar{N}\Gamma\bar{N}^\top)^{-1}W$. La matriz intermedia tiene autovalores en $(0, 1]$, de donde el orden indicado. Para $t \downarrow 0$ converge a I . Para $t \uparrow \infty$, diagonalice $\bar{N}\Gamma_0\bar{N}^\top$; los autovalores positivos producen límites cero y su núcleo produce uno. El núcleo es el complemento ortogonal de $\text{range } \bar{N}$, que da $P_\perp$. $\square$

Contraejemplo que debe conservarse. Con $d = N = (1, 0)^\top$, $\Sigma = I$ y $\Gamma = 2$, la información determinista es cero, pero la marginal bayesiana es $1/3$. El prior limita cuánto puede desplazarse la explicación normal. No se declara imposibilidad universal a partir de Fisher proyectada cero.

Para $d \neq 0$ el cociente $R_g = d^\top G_v d / (d^\top \Sigma^{-1} d)$ pertenece a $(0, 1]$, y en el límite de nuisance libre a $[0, 1]$. Es un índice de conservación de información *respecto al prior y métrica elegidos*, no una propiedad exclusiva de topología.

6.2 Covarianza dependiente del evento

Proposición 6.3 (Información de media y covarianza; [EST]). Si $r|a \sim \mathcal{N}(\mu(a), \Sigma(a))$, con $\Sigma(a) \succ 0$ diferenciable, la información escalar es

$$I(a) = \mu'^\top \Sigma^{-1} \mu' + \frac{1}{2} \text{tr}(\Sigma^{-1} \Sigma' \Sigma^{-1} \Sigma'). \quad (6.6)$$

Demostración. Escriba $e = r - \mu$ y derive la logdensidad: $s = \mu'^\top \Sigma^{-1} e + \frac{1}{2} e^\top \Sigma^{-1} \Sigma' \Sigma^{-1} e - \frac{1}{2} \text{tr}(\Sigma^{-1} \Sigma')$. El término lineal y el cuadrático centrado son ortogonales porque una gaussiana centrada tiene terceros momentos cero. La varianza del primero es $\mu'^\top \Sigma^{-1} \mu'$. Para $e = \Sigma^{1/2} z$, diagonalice la matriz simétrica $A = \Sigma^{-1/2} \Sigma' \Sigma^{-1/2}$; la varianza de $\frac{1}{2} \sum_i \lambda_i (z_i^2 - 1)$ es $\frac{1}{2} \sum_i \lambda_i^2$, puesto que $\text{Var}(z_i^2) = 2$. Eso produce el segundo término. $\square$

Cuando $N = N(a)$, $\Sigma_{eff}(a) = \Sigma + N(a)\Gamma N(a)^\top$ y aparece ese término adicional. Si se utiliza una precisión fija como aproximación, se declara como tal.

6.3 El preevento reduce la incertidumbre admisible

Teorema 6.4 (Ganancia de información por historia preevento; [DER]). Suponga $v \sim \mathcal{N}(m_0, \Gamma_0)$ y

$$y_p = N_p v + \epsilon_p, \quad r_f = \mu(a) + N_f v + \epsilon_f,$$

con ruidos gaussianos independientes entre sí y de v . Entonces

$$\Gamma_p = (\Gamma_0^{-1} + N_p^\top \Sigma_p^{-1} N_p)^{-1}, \quad (6.7)$$

$$m_p = \Gamma_p (\Gamma_0^{-1} m_0 + N_p^\top \Sigma_p^{-1} y_p), \quad (6.8)$$

$$r_f|a, y_p \sim \mathcal{N}(\mu(a) + N_f m_p, \Sigma_f + N_f \Gamma_p N_f^\top). \quad (6.9)$$

Además, $\Gamma_p \preceq \Gamma_0$ y, para firma d , la información posterior al preevento es no menor que la que usa sólo el prior inicial.

Demostración. Complete cuadrados en la densidad conjunta de v, y_p para obtener Γ_p, m_p . La independencia permite marginalizar $v|y_p$ en la segunda ecuación. La precisión añadida $N_p^\top \Sigma_p^{-1} N_p$ es PSD, por lo que invertir invierte el orden: $\Gamma_p \preceq \Gamma_0$. Multiplicar por N_f y sumar Σ_f conserva el orden; invertir de nuevo da $(\Sigma_f + N_f \Gamma_p N_f^\top)^{-1} \succeq (\Sigma_f + N_f \Gamma_0 N_f^\top)^{-1}$. La forma cuadrática con d concluye. $\square$

6.3.1 Caso correlacionado: no reutilizar dos veces la misma historia

Si $\text{Cov}(\epsilon_f, \epsilon_p) = S_{fp}$, defina

$$\tilde{r}_f = r_f - S_{fp} \Sigma_p^{-1} y_p, \quad (6.10)$$

$$\tilde{N}_f = N_f - S_{fp} \Sigma_p^{-1} N_p, \quad \Sigma_{f|p} = \Sigma_f - S_{fp} \Sigma_p^{-1} S_{pf}. \quad (6.11)$$

Entonces

$$\tilde{r}_f|a, y_p \sim \mathcal{N}(\mu(a) + \tilde{N}_f m_p, \Sigma_f|p + \tilde{N}_f \Gamma_p \tilde{N}_f^\top).$$

La prueba consiste en restar la predicción gaussiana de ϵ_f a partir de ϵ_p ; el residuo resultante es independiente de ϵ_p y de ν . Es la forma adecuada cuando filtros PMU o ventanas solapadas correlacionan pre y postevento.

6.4 Qué puede aprenderse sin atribuirlo erróneamente al evento

El posterior preevento se estima sin los datos futuros que decidirán la fuente. Puede permanecer ancho en parámetros individuales y aun así reducir mucho $N_f \Gamma_p N_f^\top$. Ésta es una ganancia funcional: no requiere recuperar cada carga, impedancia o estado.

Una discrepancia aprendida sólo de innovaciones del filtro no es necesariamente un proceso físico independiente: puede contener error de estado, ruido de observación y efectos de filtrado correlacionados. Por eso las campañas D2-M/D2-P no certifican dónde debe insertarse todo nuisance. El modelo generativo debe declarar covarianzas cruzadas o reconocer que se están despreciando.

7 Orden de distinguibilidad: tangentes, curvatura relativa y límites

Resultado central desarrollado en esta monografía

Una perturbación puede ser indistinguible del nuisance a primer orden y, sin embargo, separarse a segundo orden. La cantidad decisiva es la curvatura del evento *relativa a la variedad de explicaciones normales*, no la curvatura del evento por sí sola. La aplicación IEEE-39 es candidata de investigación; la existencia de tasas estadísticas no regulares tiene antecedentes [12].

7.1 Definición del problema geométrico local

Trabajamos en coordenadas blanqueadas con métrica euclídea. El modelo sin evento es una subvariedad local $\mathcal{M}_0 = \{F_0(b) : b \in U \subset \mathbb{R}^r\}$, $F_0(0) = 0$, y $N = DF_0(0)$ tiene rango columna completo. Si el nuisance original no es identificable, b parametriza la *imagen observable local*, no todos sus parámetros internos. Se presupone que existe ese chart regular.

Para un evento de tipo g a un nuisance verdadero fijado, la curva de medias es

$$c_g(a) = ad_g + a^2 q_g + O(a^3), \quad F_0(b) = Nb + \frac{1}{2} H_0[b, b] + O(\|b\|^3). \quad (7.1)$$

Defina la distancia *local* perfilada

$$\Delta_g(a) = \min_{b \text{ cerca de } 0} \|c_g(a) - F_0(b)\|. \quad (7.2)$$

Se excluyen otras ramas remotas de la variedad que pudieran acercarse más; la distinción global se estudia por separado. Es una restricción esencial, no una formalidad.

Teorema 7.1 (Separación de primer y segundo orden relativa al nuisance; [DER]). Sean F_0, c_g de clase C^4 , con N de rango completo. Existe una rama única suave de mínimos locales $b_*(a)$ cerca de $(a, b) = (0, 0)$. Sea $P_\perp = I - N(N^\top N)^{-1}N^\top$.

Si $P_\perp d_g \neq 0$, entonces

$$\Delta_g^2(a) = a^2 \|P_\perp d_g\|^2 + O(a^3). \quad (7.3)$$

Si $d_g = N\nu$, defina

$$\kappa_g = P_\perp \left(q_g - \frac{1}{2} H_0[\nu, \nu] \right). \quad (7.4)$$

Entonces

$$\Delta_g^2(a) = a^4 \|\kappa_g\|^2 + O(a^5). \quad (7.5)$$

Si $\kappa_g \neq 0$, el evento se separa a segundo orden aunque su información eficiente de primer orden sea cero.

Demostración. La condición de primer orden del mínimo es

$$\mathcal{H}(b, a) = DF_0(b)^\top (F_0(b) - c_g(a)) = 0.$$

En $(0, 0)$ se tiene $\mathcal{H} = 0$ y $D_b \mathcal{H} = N^\top N \succ 0$. El teorema de función implícita produce una única rama $b_*(a)$ y la Hessiana del criterio permanece positiva cerca de cero, así que es mínimo local estricto.

Escriba $b_*(a) = av + a^2w + O(a^3)$. A primer orden, $N^\top (Nv - d_g) = 0$, luego $v = (N^\top N)^{-1} N^\top d_g$. El residuo es $aP_\perp d_g + O(a^2)$ y su norma cuadrada da (7.3).

Si $d_g = Nv$, el término de orden uno del residuo desaparece. Expanda ahora

$$F_0(b_*(a)) = aNv + a^2 \left(Nw + \frac{1}{2} H_0[v, v] \right) + O(a^3).$$

La condición de mínimo a orden dos queda $N^\top (Nw + \frac{1}{2} H_0[v, v] - q_g) = 0$. Por tanto Nw es la proyección tangencial de $q_g - \frac{1}{2} H_0[v, v]$ y el residuo es $a^2 \kappa_g + O(a^3)$. Al elevar al cuadrado: $a^4 \|\kappa_g\|^2 + 2a^2 \langle \kappa_g, O(a^3) \rangle + O(a^6)$, lo que da (7.5). $\square$

Proposición 7.2 (Invariancia de la curvatura relativa ante coordenadas nuisance; [DER]). En el caso $d_g \in \text{range } N$, el vector normal κ_g no cambia al sustituir el chart nuisance por otro chart suave invertible. Bajo una reparametrización de amplitud $a = c\tilde{a} + O(\tilde{a}^2)$, $c \neq 0$, cambia por el factor c^2 ; el orden de separación es invariante.

Demostración. Sea $b = T(\tilde{b})$ con $T(0) = 0$, $A = DT(0)$ invertible. El nuevo Jacobiano es NA , que tiene el mismo espacio tangente, y $\tilde{v} = A^{-1}v$. Su Hessiano evaluado en $\tilde{v}$ es $H_0[v, v] + ND^2T[\tilde{v}, \tilde{v}]$. El segundo sumando está en $\text{range } N$ y es anulado por $P_\perp$, así que (7.4) no cambia. Para la amplitud, el nuevo coeficiente cuadrático es $c^2 q_g + c_2 d_g$ y el desplazamiento nuisance de primer orden es $c v$. La proyección elimina $c_2 d_g$, quedando $c^2 \kappa_g$. $\square$

7.2 Ejemplos que distinguen Fisher nula e imposibilidad exacta

Ejemplo 1: nuisance lineal. $\mu(v, a) = (v + a, a^2)^\top$. El nulo es $F_0(v) = (v, 0)^\top$; $N = d = (1, 0)^\top$ y $q = (0, 1)^\top$. La información eficiente de primer orden es cero, pero el mínimo se alcanza en $v = a$ y $\Delta^2(a) = a^4$ exactamente. Se detecta magnitud, no signo, a este orden.

Ejemplo 2: no toda curvatura sirve. Sea $F_0(b) = (b, \gamma b^2)^\top$ y $c(a) = (a, \zeta a^2)^\top$. Entonces $\kappa = (0, \zeta - \gamma)^\top$. Si $\zeta = \gamma$, el evento cae exactamente sobre el nulo en este ejemplo. Usar sólo $q = (0, \zeta)$ habría producido una falsa promesa de detectabilidad.




Figura 2: Ejemplo analítico de separación a segundo orden. Las curvas comparten tangente; su diferencia de curvatura, no cada curvatura aislada, produce evidencia. No es una simulación IEEE-39.

7.3 Escala estadística y demostración de un límite de detección

Definición 7.3 (Orden de distinguibilidad local). Si el residuo a la explicación normal más cercana satisface $c(a) - F_0(b_*(a)) = a^r k_r + O(a^{r+1})$ con $k_r \neq 0$, diremos que ese contacto tiene orden r . El orden puede depender de sensores, nuisance admisible, parámetros, perfil y onset.

Teorema 7.4 (Límite local por orden de contacto; [DER]). Considere n réplicas gaussianas independientes, blanqueadas, de media $c(a)$, y un nulo compuesto de medias $F_0(b)$. Suponga que la distancia local al nulo es $\Delta(a) = |a|^r \|k_r\| + O(|a|^{r+1})$. Para cualquier prueba de nivel α lo sumo α uniformemente sobre ese nulo,

$$\text{Potencia}_a \leq \alpha + \min \left\{ 1, \frac{\sqrt{n}\Delta(a)}{2} \right\}. \quad (7.6)$$

En particular, si $n|a_n|^{2r} \rightarrow 0$, la potencia no puede separarse asintóticamente de α . En el experimento auxiliar de cociente gaussiano con dirección conocida k_r , la escala $|a| \asymp n^{-1/(2r)}$ es alcanzable por un filtro apareado.

Demostración. Para cada a tome el nulo local más cercano $b_*(a)$. La divergencia KL entre las leyes conjuntas de n gaussianas de igual covarianza identidad es $n\Delta(a)^2/2$. Para cualquier evento de rechazo, la diferencia de probabilidades entre alternativa y ese nulo está acotada por su variación total. La desigualdad de Pinsker da $\text{TV} \leq \sqrt{\text{KL}/2} = \sqrt{n}\Delta(a)/2$, además de la cota trivial uno. El nivel uniforme controla precisamente ese nulo, dando (7.6). La condición asintótica hace tender a cero el segundo término.

Para la alcanzabilidad *en el experimento auxiliar*, observe $Z_i = a^r k_r + \epsilon_i$, $\epsilon_i \sim \mathcal{N}(0, I)$. El estadístico $T = \sqrt{n} k_r^\top \bar{Z} / \|k_r\|$ es $N(\sqrt{n}a^r \|k_r\|, 1)$. Para signo conocido de a^r , rechazar si $T > z_{1-\alpha}$ tiene potencia $1 - \Phi(z_{1-\alpha} - \sqrt{n}a^r \|k_r\|)$. Igualarla a $1 - \beta$ requiere $|a| = [(z_{1-\alpha} + z_{1-\beta}) / (\sqrt{n}\|k_r\|)]^{1/r}$. Para signo desconocido se utiliza una prueba bilateral. Esta construcción no afirma automáticamente alcanzabilidad uniforme en toda DAE con nuisance desconocido. $\square$

Para $r = 1$ se obtiene la escala familiar $n^{-1/2}$; para $r = 2$, $n^{-1/4}$. Los antecedentes de inferencia con información singular impiden presentar esas tasas como nuevas universalmente [12]. La contribución candidata es medir y explotar el *orden físico relativo* de eventos en PMU dispersas.

Treinta frames correlacionados no equivalen a treinta réplicas independientes. En una sola ventana se utiliza su covarianza conjunta; al cambiar duración se vuelve a calcular la información. No se sustituye n por el número de muestras sin justificar independencia o una teoría de información acumulada.

7.4 Magnitud y signo pueden aparecer a órdenes distintos

Proposición 7.5 (Ejemplo exacto de signo de tercer orden; [DER]). Para $\mu(v, a) = (v + a, a^2, a^3)^\top$ con covarianza identidad, la detección frente al nulo tiene distancia cuadrada $a^4 + a^6$. Al comparar $+a$ contra $-a$ permitiendo un nuisance distinto, la distancia cuadrada es $4a^6$. Así, la detección de presencia aparece a orden dos, pero el signo a orden tres.

Demostración. Frente al nulo $(v, 0, 0)$ se elige $v = a$ y queda $(0, a^2, a^3)$. Frente a la curva con amplitud $-a$, su nuisance puede cancelar la diferencia $2a$ de la primera coordenada. La segunda es idéntica para ambos signos y la tercera difiere en $2a^3$. Las normas cuadradas son las declaradas. Aplicar el teorema anterior da las escalas auxiliares $n^{-1/4}$ y $n^{-1/6}$. $\square$

Este ejemplo no prueba que el IEEE-39 contenga tal degeneración. Sí demuestra por qué un filtro que estima bien $|a|$ no necesariamente identifica su signo ni su fuente.

7.5 Cómo obtener curvatura relativa desde las ecuaciones eléctricas

Para un equilibrio $g(z, a) = 0$ con g_z invertible,

$$z_a = -g_z^{-1} g_a, \quad (7.7)$$

$$z_{aa} = -g_z^{-1} (g_{aa} + 2g_{za}z_a + g_{zz}[z_a, z_a]). \quad (7.8)$$

La primera ecuación proviene de derivar una vez; derivarla otra vez da la segunda. Aplicando (3.7) se obtienen d_g, q_g . Las mismas ecuaciones con parámetros nuisance producen N, H_0 . Para una ventana dinámica se usan (3.5) y el operador PMU temporal. Así la teoría de contacto se construye desde el power flow/DAE, no desde una curva arbitraria ajustada a etiquetas.

7.6 Estabilidad numérica de un certificado de primer orden

Si sólo conocemos $\widehat{P}$ y $\widehat{d}$ con $\|P - \widehat{P}\|_2 \leq \epsilon_P$ y $\|d - \widehat{d}\| \leq \epsilon_d$, entonces

$$\|Pd\| \geq \|\widehat{P}\widehat{d}\| - \epsilon_P \|\widehat{d}\| - \epsilon_d. \quad (7.9)$$

Se demuestra escribiendo $Pd - \widehat{P}\widehat{d} = (P - \widehat{P})\widehat{d} + P(d - \widehat{d})$ y usando $\|P\|_2 = 1$. Un valor numérico casi cero no certifica un contacto de orden dos: primero debe resolverse el margen de error del proyector y de la tangente.

8 Inferencia bayesiana de fuente, severidad y soporte

8.1 Likelihood física de uno o varios eventos

En una ventana de T frames, el modelo V2 de un evento es

$$r|g, a \sim \mathcal{N}(\mu_g(a), \Sigma_0), \quad \mu_g(a) = ad_g + a^2 q_g. \quad (8.1)$$

Para soporte S ,

$$\mu_S(a_S) = \sum_{g \in S} (a_g d_g + a_g^2 q_g) + \sum_{i < j \in S} a_i a_j q_{ij} + O(\|a_S\|^3). \quad (8.2)$$

Las firmas son obtenidas del operador físico de trayectorias. $q_g = \frac{1}{2} \partial_{a_g a_g} \Phi$ y $q_{ij} = \partial_{a_i a_j} \Phi$. La extensión multievento es [HIP] hasta validar físicamente interacciones y el posterior; no se infiere de la exactitud single-event.

Con nuisance gaussiano local y prior preevento,

$$r|S, a_S, Y_{pre} \sim \mathcal{N}(\mu_S(a_S) + N_S(a_S)m_{pre}, \Sigma_0 + N_S(a_S)\Gamma_{pre}N_S(a_S)^\top).$$

Si la covarianza depende de amplitud/soporte, se conserva su determinante en la evidencia. No se comparan sólo los residuos mínimos.

8.2 Severidad física y priors propios

Para una carga de base P_{g0} , la amplitud relativa a induce $\Delta P_g = P_{g0}a$ y $\Delta Q_g = Q_{g0}a$. Fisher transforma como

$$I_{\Delta P_g} = \frac{I_a}{P_{g0}^2}, \quad (8.3)$$

cuando $P_{g0} \neq 0$ y se mantiene esa dirección P/Q. Se demuestra aplicando $\partial_{\Delta P} = (1/P_{g0})\partial_a$ al score. Debe reportarse visibilidad por cambio relativo y por MW; un EVI alto no es necesariamente un efecto exclusivo de ubicación.

Los priors de amplitud deben ser propios y físicamente admisibles. Un prior gaussiano no acotado es una aproximación local cómoda; para una carga multiplicativa real debe excluir $a \leq -1$ y estados que invaliden la trayectoria. Al comparar cardinalidades, la densidad y normalización del slab no pueden omitirse.

8.3 Caso conjugado como prueba de referencia

Proposición 8.1 (Posterior de amplitud y Bayes factor lineal; [EST]). Sea $r = ad + \epsilon$, $\epsilon \sim \mathcal{N}(0, \Sigma)$ y $a \sim \mathcal{N}(0, \sigma_a^2)$. Defina $I = d^\top \Sigma^{-1} d$ y $s = d^\top \Sigma^{-1} r$. Entonces

$$v = (I + \sigma_a^{-2})^{-1}, \quad m = vs, \quad (8.4)$$

$$a|r, g \sim \mathcal{N}(m, v), \quad (8.5)$$

$$\log \frac{p(r|g)}{p(r|H_0)} = \frac{1}{2} \frac{s^2}{I + \sigma_a^{-2}} - \frac{1}{2} \log(1 + \sigma_a^2 I). \quad (8.6)$$

Demostración. En la logdensidad conjunta, los términos que dependen de a son $-\frac{1}{2}[(I + \sigma_a^{-2})a^2 - 2sa]$. Completar cuadrados da $-\frac{1}{2}v^{-1}(a-m)^2 + \frac{1}{2}vs^2$. Integrar esa gaussiana produce un factor $\sqrt{v/\sigma_a^2}$ y el exponencial $e^{vs^2/2}$ respecto a H_0 . Su logaritmo es (8.6). La normalización demuestra por qué una hipótesis flexible paga un coste de volumen, no sólo recibe una mejora de ajuste. $\square$

Este es un caso particular de inferencia gaussiana estándar [14, 15]; el aporte específico debe estar en la física de d , nuisance, curvatura y validación, no en completar cuadrados.

8.4 Por qué la curvatura puede restaurar cobertura sin inflar ruido

Teorema 8.2 (Sesgo de la inversión lineal frente a una media cuadrática; [DER]). Suponga datos verdaderos $r = ad + a^2q + \epsilon$, con a fijo y $\epsilon \sim \mathcal{N}(0, \Sigma)$. El estimador que usa el modelo lineal conjugado anterior tiene

$$\mathbb{E}\hat{a} - a = -v\sigma_a^{-2}a + va^2b, \quad b = d^\top \Sigma^{-1} q, \quad (8.7)$$

$$\text{Var}(\hat{a}|a) = v^2 I. \quad (8.8)$$

En el límite de prior difuso, $\hat{a} \sim \mathcal{N}(a + a^2b/I, 1/I)$. La cobertura frecuentista de un intervalo lineal nominal $1 - \alpha$ es

$$\Phi(z_{1-\alpha/2} - \beta_a) - \Phi(-z_{1-\alpha/2} - \beta_a), \quad \beta_a = \frac{a^2b}{\sqrt{I}}. \quad (8.9)$$

Demostración. La media posterior lineal es $\hat{a} = vd^\top \Sigma^{-1} r$. Sustituir la media verdadera da $v(Ia + a^2b)$. Restar a y utilizar $vI = 1 - v\sigma_a^{-2}$ produce el sesgo. El término aleatorio es gaussiano con varianza $v^2 d^\top \Sigma^{-1} \Sigma \Sigma^{-1} d = v^2 I$. Con prior difuso, $v \rightarrow 1/I$. El intervalo contiene a exactamente cuando $-z_{1-\alpha/2} \leq (\hat{a} - a)\sqrt{I} \leq z_{1-\alpha/2}$; esta variable es $N(\beta_a, 1)$, dando (8.9). $\square$

La componente q paralela a d en la métrica estadística sesga amplitud. La componente ortogonal puede ser importante para bondad de ajuste y fuente sin producir ese sesgo escalar. Ésta es una explicación más precisa que atribuir toda mala cobertura a un ruido mal estimado.

Si q se modela de forma determinista y exacta, el resto suave es $O(a^3)$. Una covarianza $a^4 K$ sólo surge naturalmente si existe incertidumbre de orden dos, por ejemplo $q = \hat{q} + \delta q$ con $\text{Cov} \delta q = K$. Un resto cúbico aleatorio tendría escala de covarianza a^6 . El modelo de discrepancia no debe escogerse por el exponente que mejora coverage.

8.5 Evidencia no conjugada y posterior de soporte

Con la media cuadrática, a es escalar por fuente y la evidencia se calcula mediante cuadratura verificable:

$$Z_g = \int p(r|g, a) \pi_g(a) da, \quad P(g|r) = \frac{\pi_g Z_g}{\pi_0 Z_0 + \sum_j \pi_j Z_j}. \quad (8.10)$$

La región de integración, errores de truncación, tolerancia y multimodalidad se auditan. Un prior local de Laplace alrededor de un único máximo puede perder otras soluciones o equivocarse cerca de amplitud cero; se compara con cuadratura en casos pequeños.

Para cardinalidad $M \in \{0, 1, 2\}$ y 16 candidatos:

$$\pi(S) = \frac{\pi_M}{\binom{16}{M}}, \quad M = |S|, \quad 1 + 16 + 120 = 137 \text{ soportes.}$$

Integrar amplitudes de dimensión dos es conceptualmente directo, pero su coste multiplicado por todos los soportes y ventanas debe medirse; no se promete ejecución trivial. La inclusión marginal se obtiene como $P(g \in S|r) = \sum_{S: g \in S} P(S|r)$. Para una magnitud firmada por fuente, la distribución no condicionada incluye masa en cero cuando esa fuente está ausente.

8.6 Detección: fuente conocida, búsqueda de fuente y onset

Con fuente conocida y signo positivo, el estadístico $Z = d^\top \Sigma^{-1} r / \sqrt{I}$ es $N(0, 1)$ bajo H_0 y $N(a\sqrt{I}, 1)$ bajo el evento lineal. La potencia exacta del umbral $z_{1-\alpha}$ es $1 - \Phi(z_{1-\alpha} - a\sqrt{I})$. Para signo desconocido, el umbral bilateral es $z_{1-\alpha/2}$ y la potencia incluye ambas colas.

Al buscar entre 16 fuentes, una cota conservadora asigna $\alpha/16$ a cada prueba; una calibración nominal conjunta puede aprovechar correlaciones. Buscar además onset y ventanas requiere un control adicional de multiplicidad o una construcción secuencial válida. Los límites PMU basados en divergencias entre hipótesis tienen antecedentes [10]. El EVI no es un umbral universal independiente de ese procedimiento.

8.7 Distancia entre curvas físicas, no sólo entre tangentes

Sea $G \succeq 0$ una métrica fija y $\mu_g(a) = ad_g + a^2q_g + O(a^3)$. Para un evento verdadero fijado en g :

$$\Delta_{g \rightarrow j}^2(a) = \min_{b \text{ local}} \|\mu_g(a) - \mu_j(b)\|_G^2. \quad (8.11)$$

Teorema 8.3 (Límite local de la distancia perfilada; [DER]). Si $d_j^\top G d_j > 0$ y el mínimo local está en la rama cercana a $b = 0$, entonces

$$b_*(a) = a \frac{d_j^\top G d_g}{d_j^\top G d_j} + O(a^2), \quad (8.12)$$

$$\Delta_{g \rightarrow j}^2(a) = a^2 J_{g \rightarrow j} + O(a^3), \quad (8.13)$$

$$J_{g \rightarrow j} = d_g^\top G d_g - \frac{(d_g^\top G d_j)^2}{d_j^\top G d_j} \geq 0. \quad (8.14)$$

Demostración. El score de b es $\mu'_j(b)^\top G(\mu_j(b) - \mu_g(a))$. En cero su derivada respecto a b es $d_j^\top G d_j > 0$; la función implícita da la rama de mínimo. Al expandir el score a primer orden se obtiene $b_*(a)$ indicado. Sustituyendo en el residuo queda $a(d_g - c d_j) + O(a^2)$, con $c = d_j^\top G d_g / (d_j^\top G d_j)$. Expandir su norma cuadrada da J . Su no negatividad se deduce de Cauchy–Schwarz en el semiproducto definido por G , o de ser el mínimo de una norma cuadrática. $\square$

Para columnas normalizadas en esa métrica, $J_{g \rightarrow j} = I_g(1 - \mu_{gj}^2)$. Con amplitudes firmadas, la antiparalelidad también puede causar confusión: un coseno cercano a -1 no significa separación fuerte. El ángulo entre subespacios usa el valor absoluto del coseno.

Para gaussianas *simples*, mismo Σ y priors iguales, el clasificador óptimo tiene error $\Phi(-\Delta/2)$: el logcociente se proyecta sobre la diferencia de medias y su distribución bajo cada clase tiene medias $\pm\Delta^2/2$ y varianza Δ^2 . Para curvas/soportes compuestos, integrar amplitudes y priors modifica la decisión. Δ sigue siendo un diagnóstico geométrico, no una fórmula exacta de confusión multicategoría.

8.8 Multievento: amplitud condicional frente a soporte global

Para $S = \{i, j\}$,

$$J_S(a) = \begin{bmatrix} d_i + 2a_i q_i + a_j q_{ij} & d_j + 2a_j q_j + a_i q_{ij} \end{bmatrix}.$$

La información condicional local es $\mathcal{I}_S = J_S^\top G J_S$. Si es definida positiva, las amplitudes son localmente separables *condicionado a ese soporte*. No excluye que otro soporte produzca la misma media.

La distancia uniforme $\min_{a_S, b_T} \|\mu_S(a_S) - \mu_T(b_T)\|_G$ es cero si ambos dominios admiten amplitud cero. Para garantías globales se fija a_S , se impone una amplitud mínima por evento y se controlan cancelaciones.

Proposición 8.4 (Certificado de unicidad lineal por coherencia; [EST]). Sea D un diccionario con columnas de norma uno y coherencia $\mu = \max_{i \neq j} |d_i^\top d_j|$. Si $(2k - 1)\mu < 1$, una representación con a lo sumo k coeficientes no nulos es única entre las representaciones de ese tamaño.

Demostración. Si $Dx = Dx'$ y ambos tienen soporte a lo sumo k , su diferencia $v = x - x'$ tiene a lo sumo $2k$ entradas. Para cualquier subdiccionario de $s \leq 2k$ columnas, la Gramiana tiene diagonal uno y suma absoluta fuera de diagonal por fila a lo sumo $(s - 1)\mu < 1$. Por el teorema de Gershgorin sus autovalores son positivos; las columnas son independientes. Así $Dv = 0$ implica $v = 0$. $\square$

Es una condición suficiente clásica [18], no la capacidad exacta del sistema ni una garantía directa para el modelo cuadrático. En PMU se aplica después de elegir ventana, ruido y nuisance; las columnas anuladas por la proyección se excluyen como no identificables a ese orden.

8.9 Onset desconocido: una degeneración inevitable en eventos débiles

Los experimentos reportados de LOAD-BAYES-FD-V2 fijan $\tau = 2$ s. Un detector realmente autónomo debe inferir el onset o marginalizarlo. La dificultad no es sólo computacional: el tiempo deja de ser identificable cuando desaparece el evento.

Proposición 8.5 (Información de onset y amplitud débil; [DER]). Para $\mu(a, \tau) = ad(\tau)$ y covarianza fija Σ , la Fisher conjunta de (a, τ) es

$$\mathcal{I}(a, \tau) = \begin{bmatrix} d^\top \Sigma^{-1} d & ad^\top \Sigma^{-1} \dot{d} \\ a \dot{d}^\top \Sigma^{-1} d & a^2 \dot{d}^\top \Sigma^{-1} \dot{d} \end{bmatrix}, \quad (8.15)$$

donde $\dot{d} = \partial_\tau d$. Condicionado a amplitud desconocida, la información eficiente del onset es

$$I_{\tau|a} = a^2 \left[\dot{d}^\top \Sigma^{-1} \dot{d} - \frac{(d^\top \Sigma^{-1} \dot{d})^2}{d^\top \Sigma^{-1} d} \right]. \quad (8.16)$$

En $a = 0$ el onset no es identificable. Si $\dot{d}$ es proporcional a d , onset y ganancia se confunden localmente incluso con $a \neq 0$.

Demostración. Las derivadas de la media son $\partial_a \mu = d$ y $\partial_\tau \mu = a \dot{d}$. La Fisher gaussiana de media es el producto del Jacobiano por Σ^{-1} y su transpuesta. El complemento de Schur del bloque de amplitud da $I_{\tau|a}$. La proporcionalidad anula el término entre corchetes por igualdad en Cauchy–Schwarz. Para $a = 0$ la distribución es independiente de τ , por lo que ninguna inferencia de onset es posible. $\square$

La tasa y los límites de tiempo deben evaluarse en ventanas compatibles y con un operador PMU causal. Una derivada temporal de una onda con discontinuidad en el instante de evento puede no ser ordinaria; se utiliza el mapa de muestras/filtrado real o sensibilidad híbrida. Este resultado impide trasladar directamente la accuracy con onset conocido a un sistema de vigilancia continua.

9 Estimador recursivo Hybrid-DAE: derivación y garantías locales

9.1 Posterior completo y unidad de información

Para una ventana $\mathcal{W}_k = [k - N, k]$ defina $\chi = \text{col}(X, Z, \eta, \vartheta, c, b)$ y soporte/tiempos (S, τ_S) . La factorización generativa conceptual es

$$\begin{aligned} p(\chi, S, a_S, \tau_S | Y) &\propto p_A(\chi_{k-N}) \pi(S, a_S, \tau_S) \\ &\times \prod_t p(x_{t+1}, \eta_{t+1}, c_{t+1} | x_t, \eta_t, c_t, S, a_S, \tau_S) \\ &\times \prod_t p(y_t | x_t, z_t, b_t, S, a_S, \tau_S), \end{aligned} \quad (9.1)$$

sujeta a las restricciones DAE consistentes y transiciones híbridas. Las variables algebraicas se obtienen por pushforward de las coordenadas consistentes. Si se utiliza una representación con deltas de restricciones en coordenadas ambiente, hay que conservar los factores de cambio de medida; no se puede cambiar el volumen de integración de una hipótesis sin modificar su evidencia.

La factorización temporal requiere que los estados latentes absorban la memoria de ruido; si no, se utiliza la densidad conjunta de ventana. La factorización espacial requiere independencia condicional, no simplemente proximidad de buses.

Proposición 9.1 (Posterior bien definido bajo un contrato físico compacto; [DER]). Suponga un conjunto finito de soportes, priors propios, un dominio físico compacto de variables continuas y un mapa de observación continuo. Si $\Sigma(\chi, S) \succeq \sigma_{\min}^2 I$ con $\sigma_{\min} > 0$, la evidencia de cada soporte con prior no nulo es finita y positiva. Si además la densidad posterior es continua, existe un MAP; no se garantiza unicidad.

Demostración. La likelihood gaussiana es positiva y está acotada por $(2\pi)^{-p/2} \sigma_{\min}^{-p}$, independientemente de la media. Integrarla contra un prior propio da evidencia finita; su positividad y una masa previa positiva dan evidencia estrictamente positiva. La suma finita sobre soportes también es finita y positiva. La densidad continua alcanza un máximo en un compacto por Weierstrass. Distintas soluciones físicas pueden compartir el mismo máximo, de modo que no se deduce unicidad. $\square$

La teoría general de problemas inversos bayesianos proporciona un marco más amplio [15]; aquí se adopta un enunciado finito suficiente para el prototipo y que no oculta regiones no físicas.

9.2 Discretización dinámica y residuos

Un integrador implícito define un residuo $r_t^{\text{dyn}}(x_{t+1}, x_t, z_t, u_t, \vartheta, q_t)$ con el orden y las unidades del solver. No se sustituye automáticamente por Euler explícito. Para el caso lineal, la discretización exacta de un input retenido se obtiene de

$$\exp\left(\Delta t \begin{bmatrix} A_r & B_r \\ 0 & 0 \end{bmatrix}\right) = \begin{bmatrix} A_d & B_d \\ 0 & I \end{bmatrix}. \quad (9.2)$$

La covarianza discreta de proceso es $Q_d = \int_0^{\Delta t} e^{A_r s} L_w L_w^\top e^{A_r^\top s} ds$, no necesariamente $\Delta t Q_c$.

Condicionado en S, a_S, τ_S , un MAP gaussiano local minimiza

$$\begin{aligned} J(\chi) &= \frac{1}{2} \|\chi_{k-N} - m_A\|_{P_A^{-1}}^2 + \frac{1}{2} \sum_t \|r_t^{\text{dyn}}\|_{Q_t^{-1}}^2 + \frac{1}{2} \|r^{\text{pmu}}\|_{\Sigma^{-1}}^2 \\ &+ \frac{1}{2} \|r^\eta\|_{Q_\eta^{-1}}^2 + \frac{1}{2} \|r^\vartheta\|_{Q_\vartheta^{-1}}^2 + \frac{1}{2} \|r^b\|_{Q_b^{-1}}^2 + \frac{1}{2} \|r^c\|_{Q_c^{-1}}^2, \end{aligned} \quad (9.3)$$

sujeto a $g_t = 0$ y restricciones físicas de modos. Un término de proceso es una hipótesis estocástica, no un permiso para violar KCL. Si una covarianza depende de variables optimizadas se agrega su logdet; omitirlo cambia el modelo probabilístico.

9.3 Iteración Gauss–Newton restringida

Sea r el vector apilado de residuos con precisión Ω y $c(\chi) = 0$ las restricciones. En $\chi^{(j)}$:

$$H = J_r^\top \Omega J_r + H_{prior}, \quad b = -\nabla J(\chi^{(j)}), \quad G_c = J_c, \quad (9.4)$$

$$\begin{bmatrix} H & G_c^\top \\ G_c & 0 \end{bmatrix} \begin{bmatrix} \Delta\chi \\ \lambda \end{bmatrix} = \begin{bmatrix} b \\ -c(\chi^{(j)}) \end{bmatrix}. \quad (9.5)$$

La matriz KKT es indefinida. Se resuelve con $LDL^\top$ pivotado, métodos de punto silla o eliminación por espacio nulo; Cholesky se aplica a un bloque SPD, no al KKT completo sin prueba. Un paso $\alpha\Delta\chi$ con función mérito/trust region controla factibilidad y descenso. El ordenamiento disperso depende del grafo temporal y eléctrico.

Teorema 9.2 (Unicidad del paso y covarianza sobre el espacio factible; [EST]). Suponga G_c de rango fila completo y sea Z una base de $\ker G_c$. Si $Z^\top HZ \succ 0$, el sistema KKT de (9.5) es no singular. Para una aproximación gaussiana linealmente restringida, la covarianza marginal local es

$$P_\chi = Z(Z^\top HZ)^{-1}Z^\top. \quad (9.6)$$

Demostración. Si (v, λ) pertenece al núcleo del KKT, $G_c v = 0$ y $Hv + G_c^\top \lambda = 0$. Así $v = Zq$. Multiplicar por $v^\top$ da $q^\top Z^\top HZq = 0$, luego $q = 0$ y $v = 0$. Queda $G_c^\top \lambda = 0$; el rango fila completo implica $\lambda = 0$. Para la covarianza, parametrize la perturbación factible como $\delta\chi = Zq$. Su densidad gaussiana es proporcional a $\exp[-\frac{1}{2}q^\top Z^\top HZq]$, por lo que $\text{Cov}(q) = (Z^\top HZ)^{-1}$. El pushforward lineal da (9.6). $\square$

La covarianza es de Laplace/Gauss–Newton local; no captura multimodalidad ni regiones lejanas. En una restricción no lineal se usa un chart consistente. La medida del prior y el Jacobiano del chart se conservan en la evidencia, aunque para una covarianza local a primer orden pueda utilizarse la expresión tangente.

Proposición 9.3 (Convergencia local cuadrática en el caso residual cero; [EST]). En coordenadas factibles u , suponga $r(u_*) = 0$, Jacobiano $J(u)$ Lipschitz y de rango columna completo en un entorno, con $\|J(u)^\dagger\| \leq K$. El paso Gauss–Newton completo satisface $\|u_+ - u_*\| \leq (KL/2)\|u - u_*\|^2$ en ese entorno.

Demostración. Con $e = u - u_*$, por la fórmula integral $r(u) = J(u)e + R$, donde $R = \int_0^1 [J(u_* + te) - J(u)]edt$. El Lipschitz da $\|R\| \leq \int_0^1 L(1-t)\|e\|^2 dt = (L/2)\|e\|^2$. El paso $u_+ = u - J(u)^\dagger r(u)$ y $J^\dagger J = I$ implican $u_+ - u_* = -J^\dagger R$. Aplicar la cota de $J^\dagger$ concluye. $\square$

Con ruido, priors o mismatch el residual óptimo no suele ser cero y no se deduce esa tasa. Tampoco hay garantía de convergencia global de todos los experimentos por haber probado un toy. Ésta es una garantía local con hipótesis verificables, no una promesa de estimador perfecto.

9.4 Kalman aparece como marginalización gaussiana exacta

Teorema 9.4 (Reducción al filtro de Kalman; [EST]). Para $x_{k+1} = Ax_k + w_k$, $y_k = Cx_k + v_k$, con gaussianas independientes y prior gaussiano, la inferencia secuencial exacta de (9.1) satisface

$$m_k^- = Am_{k-1}^+, \quad P_k^- = AP_{k-1}^+ A^\top + Q, \quad (9.7)$$

$$S_k = CP_k^- C^\top + R, \quad K_k = P_k^- C^\top S_k^{-1}, \quad (9.8)$$

$$m_k^+ = m_k^- + K_k(y_k - Cm_k^-), \quad P_k^+ = P_k^- - P_k^- C^\top S_k^{-1} CP_k^-. \quad (9.9)$$

Demostración. Asuma por inducción $x_{k-1}|Y_{1:k-1} \sim \mathcal{N}(m_{k-1}^+, P_{k-1}^+)$. La transformación afín y suma de ruido dan el prior predictivo con m_k^- , P_k^- . Multiplicar su densidad por $p(y_k|x_k)$ y completar cuadrados produce precisión $(P_k^-)^{-1} + C^\top R^{-1}C$ y vector información $(P_k^-)^{-1}m_k^- + C^\top R^{-1}y_k$. Woodbury convierte su inversa a P_k^+ ; al multiplicar el vector información se obtiene la actualización de media indicada. El caso inicial gaussiano comienza la inducción. Como sólo se han aplicado integración y condicionamiento exactos, el resultado coincide

con marginalizar el MAP gaussiano de toda la cadena. En matrices semidefinidas se trabaja en su soporte, no con una inversa inexistente. $\square$

En software conviene la forma Joseph $(I - KC)P^-(I - KC)^\top + KKK^\top$ o una forma de raíz cuadrada. La equivalencia con Kalman es obligatoria para validar el algoritmo general, pero no constituye novedad [14].

9.5 RTS y el valor real de observar el futuro

En el modelo lineal gaussiano, la distribución de x_t condicionada en x_{t+1} y datos hasta t tiene media $m_t^+ + J_t(x_{t+1} - m_{t+1}^-)$, donde $J_t = P_t^+ A^\top (P_{t+1}^-)^{-1}$. Promediar esa condicional respecto al posterior futuro da

$$m_{t|k} = m_t^+ + J_t(m_{t+1|k} - m_{t+1}^-), \quad (9.10)$$

$$P_{t|k} = P_t^+ + J_t(P_{t+1|k} - P_{t+1}^-)J_t^\top. \quad (9.11)$$

Es una consecuencia de condicionamiento gaussiano y varianza total. El fixed-lag entrega el tiempo $t = k - L$ usando datos hasta k , no una estimación contemporánea gratuita.

Proposición 9.5 (Más datos reducen el riesgo bayesiano correcto; [EST]). Para $\mathcal{F} \subseteq \mathcal{G}$ y $X \in L^2$,

$$\mathbb{E}\|X - \mathbb{E}[X|\mathcal{F}]\|^2 - \mathbb{E}\|X - \mathbb{E}[X|\mathcal{G}]\|^2 = \mathbb{E}\|\mathbb{E}[X|\mathcal{G}] - \mathbb{E}[X|\mathcal{F}]\|^2 \geq 0.$$

Demostración. Descomponga el primer error como $(X - \mathbb{E}[X|\mathcal{G}]) + (\mathbb{E}[X|\mathcal{G}] - \mathbb{E}[X|\mathcal{F}])$. El término cruzado tiene esperanza cero porque la segunda parte es $\mathcal{G}$ -medible y la primera tiene esperanza condicional cero dada $\mathcal{G}$. Expandir la norma prueba la identidad. $\square$

Por ello, el resultado reportado “lag cero fue mejor” no demuestra que el futuro no contenga información. Es compatible con mismatch, pérdida elegida, errores finitos o métricas no cuadráticas. La comparación debe alinear exactamente el tiempo objetivo y las muestras disponibles.

9.6 Prior de llegada con normalización de evidencia

Teorema 9.6 (Eliminación gaussiana completa; [EST]). Sea una densidad no normalizada $\exp[-\frac{1}{2}z^\top \Lambda z + h^\top z + c]$ con $z = \text{col}(a, b)$ y $\Lambda_{aa} \succ 0$. Al integrar a resulta la misma forma en b con

$$\Lambda_{new} = \Lambda_{bb} - \Lambda_{ba}\Lambda_{aa}^{-1}\Lambda_{ab}, \quad (9.12)$$

$$h_{new} = h_b - \Lambda_{ba}\Lambda_{aa}^{-1}h_a, \quad (9.13)$$

$$c_{new} = c + \frac{1}{2}h_a^\top \Lambda_{aa}^{-1}h_a + \frac{n_a}{2} \log(2\pi) - \frac{1}{2} \log \det \Lambda_{aa}. \quad (9.14)$$

Demostración. Agrupe los términos en a : $-\frac{1}{2}a^\top \Lambda_{aa}a + a^\top (h_a - \Lambda_{ab}b)$. Al completar cuadrados, la media condicional es $\Lambda_{aa}^{-1}(h_a - \Lambda_{ab}b)$ y aparece $\frac{1}{2}(h_a - \Lambda_{ab}b)^\top \Lambda_{aa}^{-1}(h_a - \Lambda_{ab}b)$. La integral del cuadrado gaussiano aporta $(2\pi)^{n_a/2} \det(\Lambda_{aa})^{-1/2}$. Expandir la expresión restante separa los términos cuadrático, lineal y constante de (9.14). $\square$

Descartar c_{new} es inocuo para la media de una única hipótesis, pero puede alterar Bayes factors entre soportes. Si hay constraints, primero se integra en coordenadas factibles con la medida correspondiente.

9.7 Posterior del campo oculto, no sólo del soporte ganador

Teorema 9.7 (Incertidumbre total de PMU virtuales; [EST]). Sean $w_S = P(S|Y)$, $m_S = \mathbb{E}[\psi|Y, S]$ y $P_S = \text{Cov}(\psi|Y, S)$. Entonces

$$\bar{m} = \sum_S w_S m_S, \quad (9.15)$$

$$\text{Cov}(\psi|Y) = \sum_S w_S P_S + \sum_S w_S (m_S - \bar{m})(m_S - \bar{m})^\top. \quad (9.16)$$

Demostración. Escriba $\psi - \bar{m} = (\psi - m_S) + (m_S - \bar{m})$. Condicionando en S , el primer término tiene media cero y los términos cruzados desaparecen. Promediar la matriz del producto exterior sobre S entrega ambas sumas. La media se obtiene por esperanza iterada. $\square$

El mismo principio se aplica a centro de operación y desviación dinámica. Si $\psi = \psi_{center} + Lx$, su covarianza incluye $\text{Cov}(\psi_{center}, x)L^\top + L\text{Cov}(x, \psi_{center})$. Estimarlos con las mismas PMU y sumar sólo varianzas puede producir incertidumbre incorrecta.

9.8 Fusión distribuida sin contar la evidencia dos veces

En un grafo de factores, cada likelihood local aporta una precisión y un vector de información. La suma es válida sólo para factores condicionalmente independientes y un prior contado una vez. Si dos nodos comparten datos o priors, promediar posteriors locales como si fueran independientes sobreconfía.

En un árbol de cliques/separadores, eliminar variables interiores de cada clique mediante (9.14) produce mensajes gaussianos exactos sobre el separador. Un recorrido hacia raíz integra todas las hojas; un recorrido inverso obtiene marginales. La prueba es inducción sobre hojas: cada integral elimina variables que no aparecen fuera del separador, y Fubini permite reordenar las integraciones de densidades integrables. En grafos con ciclos, una implementación exacta requiere triangulación/junction tree; el coste depende del ancho de separadores, no sólo del número de buses. Las bases de este algoritmo son conocidas [17].

La red IEEE-39 no es un árbol. La marginalización suele producir *fill-in*. Un prior de grafo disperso y la locality de KCL ayudan al ensamblado, pero no garantizan coste lineal ni que una simple regla de consenso reproduzca el posterior centralizado. El calificativo “distribuido” queda como [HIP] hasta verificar exactitud, comunicación, sincronización y latencia frente al oráculo central.

10 Aprendizaje restringido, error numérico y detección secuencial

10.1 Qué puede aprender ML sin reemplazar la evidencia física

Una integración útil puede aprender distribuciones nuisance, hiperparámetros de covarianza, correcciones de operador o una propuesta de soporte que acelere la búsqueda. Debe mantenerse una vía física de likelihood y un contrato de error. Una GNN que prediga etiquetas no es necesaria para la formulación; tampoco queda prohibida como baseline independiente, siempre que no se confunda su salida con evidencia física calibrada.

La opción más conservadora usa información preevento para aprender $p_\phi(v \mid \text{contexto})$, congela la actualización durante la ventana de decisión y marginaliza esa distribución. Para priors no gaussianos, la integral puede evaluarse por cuadratura de baja dimensión o mezcla; no hay razón para convertir toda la física a una red neuronal.

Teorema 10.1 (Protección exacta y aproximada de evidencia proyectada; [DER]). En coordenadas blanqueadas fije el proyector verdadero $P_\perp$ al complemento nuisance. Si una corrección c_ϕ cumple $P_\perp c_\phi = 0$, entonces $P_\perp(r - c_\phi) = P_\perp r$. Si sólo se conoce $\hat{P}_\perp$ con $\|P_\perp - \hat{P}_\perp\|_2 \leq \varepsilon_P$ y se impone $\hat{P}_\perp c_\phi = 0$, se tiene

$$\|P_\perp c_\phi\| \leq \varepsilon_P \|c_\phi\|. \quad (10.1)$$

Para una firma d fija, $|d^\top P_\perp d - d^\top \hat{P}_\perp d| \leq \varepsilon_P \|d\|^2$.

Demostración. La identidad exacta se obtiene por linealidad. En el caso aproximado, $P_\perp c_\phi = (P_\perp - \hat{P}_\perp)c_\phi$; aplicar la norma de operador da la cota. La última desigualdad es $|d^\top (P_\perp - \hat{P}_\perp)d| \leq \|d\| \|(P_\perp - \hat{P}_\perp)d\|$. $\square$

La protección no conserva toda la información bayesiana con prior finito, ni garantiza que el subespacio aprendido sea correcto. Si el proyector se adapta usando el propio evento, debe analizarse como un procedimiento aleatorio; no se reutiliza sin más el teorema de proyector fijo. Un límite de norma de c_ϕ transforma el error de subespacio en una garantía operativa verificable.

10.2 Certificar aproximaciones del operador físico mediante evidencia

Esta sección conecta errores FD, truncamiento y posibles surrogates ML con decisiones bayesianas. Se fija el mismo prior y la misma covarianza en el modelo exacto y aproximado; si también cambia la covarianza, se deben acotar logdet e inversas por separado.

Teorema 10.2 (Cota de error de likelihood y posterior odds; [DER]). Sean medias $\mu_S(a)$ y $\hat{\mu}_S(a) = \mu_S(a) + \delta_S(a)$ bajo covarianza $\Sigma \succ 0$. Si para todo a del dominio $\|W\delta_S(a)\| \leq \varepsilon_S$ y $\|W(r - \mu_S(a))\| \leq R_S$, entonces

$$|\log \hat{p}(r|S, a) - \log p(r|S, a)| \leq b_S := \varepsilon_S R_S + \frac{1}{2} \varepsilon_S^2. \quad (10.2)$$

Con el mismo prior propio sobre amplitudes, $e^{-b_S} Z_S \leq \hat{Z}_S \leq e^{b_S} Z_S$. Para soportes S, T , el error de log posterior odds está acotado por $b_S + b_T$.

Demostración. El cambio de loglikelihood es $\delta_S^\top \Sigma^{-1} (r - \mu_S) - \frac{1}{2} \delta_S^\top \Sigma^{-1} \delta_S$. Cauchy–Schwarz y la cota uniforme dan el primer resultado. Exponenciar produce una desigualdad punto a punto de densidades. Multiplicar por el mismo prior e integrar conserva el orden y da la desigualdad de evidencias. Restar las dos logevidencias, con priors de soporte idénticos en ambos modelos, proporciona la cota de odds. $\square$

Si la diferencia entre las dos mejores logevidencias supera sus errores certificados, su orden es estable frente a esas aproximaciones. Pero medir error en unos pocos amplitudes no da una cota uniforme de toda la DAE. Se necesita un dominio y control de derivadas/restos, o declarar el certificado como empírico local.

Proposición 10.3 (Poda de soportes con masa posterior controlada; [DER]). Si se retienen soportes en $\mathcal{K}$ y su masa posterior excluida es ϵ , el posterior renormalizado sobre $\mathcal{K}$ está a distancia de variación total exactamente ϵ del posterior completo. Si sólo hay cotas de pesos no normalizados $w_S = \pi_S Z_S$, una cota suficiente es

$$\epsilon \leq \frac{\sum_{S \notin \mathcal{K}} \bar{w}_S}{\sum_{S \in \mathcal{K}} \underline{w}_S + \sum_{S \notin \mathcal{K}} \bar{w}_S}.$$

Demostración. En el conjunto retenido, la distribución condicionada multiplica las probabilidades por $1/(1 - \epsilon)$. La suma de diferencias absolutas allí es ϵ y en el complemento también es ϵ ; dividir por dos da $TV = \epsilon$. La masa excluida es $W_{out} / (W_{in} + W_{out})$, creciente en W_{out} y decreciente en W_{in} . Sustituir sus cotas demuestra la segunda fórmula. $\square$

Esto permite usar un modelo aprendido como propuesta rápida sin otorgarle el poder de borrar soportes sin control. Es una ruta más defendible que truncar a Top- K y presentar luego sus probabilidades renormalizadas como el posterior completo.

10.3 Por qué KCL, energía y features derivadas no añaden observaciones independientes

Proposición 10.4 (No incremento de información por duplicación determinista; [DER]). Sea $Y \sim \mathcal{N}(\mu(a), \Sigma)$ y se entregue además AY . La observación aumentada $Z = \text{col}(Y, AY) = TY$ con $T = \text{col}(I, A)$ contiene exactamente la misma información que Y . Su covarianza correcta es $T\Sigma T^\top$, singular. En el caso escalar de media diferenciable, su información Fisher, calculada sobre su soporte, coincide con $\mu'^\top \Sigma^{-1} \mu'$.

Demostración. Y se recupera tomando el primer bloque de Z , y Z se calcula determinísticamente de Y , así que ambos experimentos son equivalentes. Para la identidad algebraica, escriba $B = T\Sigma^{1/2}$, que tiene rango columna completo. Su SVD muestra $B^\top (BB^\top)^\dagger B = I$. Entonces $\mu'^\top T^\top (T\Sigma T^\top)^\dagger T \mu' = \mu'^\top \Sigma^{-1/2} I \Sigma^{-1/2} \mu'$. $\square$

Si se trata el bloque AY como ruido independiente se inventa información. Esto afecta frecuencia derivada de fase, corrientes reconstruidas, residuos de ciclos y balances de energía inferidos de las mismas PMU. Pueden ayudar computacionalmente o expresar constraints, pero su incertidumbre debe mantenerse conjunta.

10.4 Evidencia secuencial con garantía explícita

Sea $\mathcal{F}_t$ la historia disponible. Una alternativa predictiva $q_t(y|\mathcal{F}_{t-1})$ puede mezclar soportes y tiempos de cambio, siempre que sea una densidad normalizada y predecible. Bajo un nulo conocido con predictiva $p_{0,t}$, define

$$L_t = \prod_{s=1}^t \frac{q_s(Y_s|\mathcal{F}_{s-1})}{p_{0,s}(Y_s|\mathcal{F}_{s-1})}.$$

Teorema 10.5 (Control de falsa alarma con stopping arbitrario; [EST]). Bajo el nulo correcto y condiciones de soporte que hagan finitas las razones, L_t es un martingala no negativo con $\mathbb{E}_0 L_t = 1$. Para $\alpha \in (0, 1)$,

$$\mathbb{P}_0(\sup_t L_t \geq 1/\alpha) \leq \alpha.$$

Demostración. La esperanza condicional del factor nuevo es $\int q_t(y)/p_{0,t}(y) p_{0,t}(y) dy = 1$. Así $\mathbb{E}_0[L_t|\mathcal{F}_{t-1}] = L_{t-1}$. Sea τ el primer cruce de $1/\alpha$. Para horizonte fijo T , el martingala detenido no negativo satisface $\mathbb{E}L_{\tau \wedge T} = 1$; en $\{\tau \leq T\}$ es al menos $1/\alpha$. Markov da $\mathbb{P}(\tau \leq T) \leq \alpha$. La continuidad monótona de eventos al hacer $T \rightarrow \infty$ concluye. $\square$

El argumento es la forma clásica de Ville; la literatura moderna desarrolla extensiones amplias [16]. Ventanas solapadas no producen factores independientes: deben utilizarse predictivas condicionales coherentes, no multiplicar repetidamente Bayes factors de ventanas con los mismos datos.

Proposición 10.6 (Construcción conservadora para un nulo compuesto; [DER]). Sea $\mathcal{P}_{0,t}$ una familia predecible que contiene la verdadera densidad condicional bajo cada nulo admisible. Defina $u_t(y) = \sup_{p \in \mathcal{P}_{0,t}} p(y)$, finita y positiva sobre el soporte, y $E_t = \prod_{s \leq t} q_s(Y_s)/u_s(Y_s)$. Entonces E_t es supermartingala no negativo bajo cada nulo de la familia y satisface la misma cota de cruce.

Demostración. Para cualquier verdadera predictiva $p_{0,t} \in \mathcal{P}_{0,t}$,

$$\mathbb{E} \left[\frac{q_t(Y_t)}{u_t(Y_t)} \middle| \mathcal{F}_{t-1} \right] = \int \frac{q_t(y)p_{0,t}(y)}{u_t(y)} dy \leq \int q_t(y) dy = 1.$$

Multiplicar por E_{t-1} da la propiedad supermartingala. El argumento de parada de la prueba anterior usa sólo no negatividad y esperanza a lo sumo uno, por lo que se mantiene. $\square$

La familia debe contener la ley real de ruido y operación. Un ajuste AR1 en CAL no certifica esa inclusión en RAW o en toda planta IBR. La envolvente puede ser demasiado conservadora; su potencia debe medirse. No se declara garantía anytime para el localizador V2 hasta construir esas predictivas.

10.5 Open-set, abstención y decisión

La distancia a la unión de explicaciones conocidas, $d_{open}(r) = \min_{S,a,v} \|r - \mu_S(a) - Nv\|_{\Sigma^{-1}}$, puede diagnosticar inadecuación. Pero nuisance libre de alta dimensión puede absorber casi todo; la clase admisible y el umbral se fijan con controles independientes. Un residuo grande rechaza el catálogo, no identifica automáticamente un tipo nuevo de falla.

Para decisiones operativas conviene una pérdida explícita: falsa alarma, no detección, fuente equivocada y abstención no cuestan lo mismo. El decisor bayesiano minimiza $\sum_S P(S|Y) \mathcal{L}(d, S)$. Si varias fuentes son indistinguibles, puede reportarse una región eléctrica con masa posterior agregada en lugar de una etiqueta de bus arbitraria. La resolución espacial debe depender de la información y del coste de error, no sólo de Top-1.

11 Claims, evidencia experimental y agenda de contribución

11.1 Qué proviene de los archivos y qué se desarrolló aquí

Esta monografía reorganiza [P1] y conserva la terminología del proyecto, pero aplica explícitamente las correcciones de [P2]. Las secciones de teoremas son demostraciones algebraicas/estadísticas en modelos delimitados. Las cifras de esta sección proceden de reportes [P3] suministrados en la conversación; no se han abierto en esta sesión los CSV del repositorio Windows ni se han ejecutado las campañas TDS. Los resultados numéricos nuevos del apéndice son comprobaciones toy independientes y no se mezclan con [P3].

La documentación pública confirma familias de componentes y métodos de bibliotecas, no el exacto estado del commit de Luna. Las páginas `stable/latest` pueden cambiar: para reproducir el proyecto prevalecen el Manifest, los CSV y el commit congelados. La autoría, afiliaciones y orden de autores del paper deben confirmarse; este documento no los inventa.

11.2 Registro experimental depurado

Bloque [REP]	Resultado comunicado	Alcance que se conserva
Banco PD	39 buses, 46 ramas; 192 coordenadas, 114 diferenciales y 78 algebraicas; residual de equilibrio 4.66×10^{-13} .	Benchmark definido por el paquete, nivel C. No equivalencia automática con otras variantes IEEE-39 ni validación física externa.
Red/PMU	Paridad estática del mismo caso: $\Delta Y_{max} \approx 1.14 \times 10^{-13}$; mapa de ocho terminales sintéticos auditado.	Paridad de implementación estática, no corrección de toda DAE ni semántica de corrientes de RAW.
E04-A	B2 TVE medio 0.009634 % en 100 trayectorias de 3 s; B0 0.3402 %, B1 0.009904 %.	Campo oculto bajo ese régimen/ruido; no prueba de identificabilidad global ni superioridad frente a todos los estimadores.
Fixed-lag	Mejor TVE reportado en lag cero; lags hasta 60 frames no mejoraron la media de esa métrica.	No concluye inutilidad general de historia; confrontar tiempos objetivo, sesgo de modelo y riesgo bayesiano.
Calibración nominal	U2 ajustado en CAL dio cobertura 95 % aproximadamente 93.92/94.24 % Re/Im, pero 50 % fue 71.10/61.93 %.	Mejor cobertura en una cola nominal; no calibración completa de toda distribución ni transferibilidad bajo mismatch.
Discrepancia	D2-M redujo ACF y produjo subcobertura oculta; D2-P quedó muy próximo a D0, conservador.	No se afirma que la ubicación física de todo residual esté identificada. D2-P no es una mejora sustancial sobre D0.
E06 STANDARD	980 casos físicos más 175 de refinamiento; degradación principal reportada en red y operación.	Umbrales usan el mismo contrato. Se preservan cambios/correcciones de agregación, no se mezclan tablas antiguas.
Oráculos E06-D	O1/O2 usando equilibrio/modelo verdadero recuperaron error en ciertas familias.	Experimento de 0.5 s/31 frames sin ruido añadido según el contrato reportado; no comparable directamente con E04-A/Standard. No es un método online.
E06-F/G	Base PQ incompleta; base extendida representable. Rango nuisance cercano a 25/43; residual funcional 0.0419.	Identificabilidad parcial. Se retira la conclusión de necesidad de parámetros de red derivada del solver no convergido de E06-F.
Tangente LOAD	16 candidatos, ± 0.5 % FD central, eventos a $t = 2$ s sin reinicialización; Jacobiano descriptor analítico pendiente.	Operador físico numérico validado en un régimen. No llamarlo extracción analítica nativa.

Bloque [REP]	Resultado comunicado	Alcance que se conserva
LOAD-BAYES V2	496 trayectorias físicas; CAL normal 1000, DEV normal 500; weak TEST 9600 eventos + 800 H0; finite TEST 8000 eventos.	Muchas realizaciones de ruido sobre menos trayectorias físicas. No son miles de plantas independientes.
V2 desempeño	AUROC 0.9391, Top-1 débil 68.38 %, Top-3 83.57 %, cobertura finita 95 % 0.9471.	Carga simple, catálogo de 16 fuentes, onset conocido, ruido sintético ensayado. No cubre línea/falla/IBR/RAW.
V2 teoría	Pendiente truncamiento 2.000001, IC [1.7891, 2.2403]; Spearman $EVI-a_{90} = -0.7938$.	Soporte experimental local, no derivada exacta ni ley universal calibrada con todos los tests.
Geometría pares	Correlación $-J$ -confusión 0.3613, estado inconcluso.	No se afirma éxito de predicción completa de confusión ni que la curvatura sea ya la explicación de su límite.

Dos detalles estadísticos para el manuscrito. En weak TEST la prevalencia de evento fue $9600/(9600+800) = 92.31\%$: una AUPRC alta debe interpretarse frente a esa prevalencia. FPR 0.0025 sobre 800 controles equivale a dos falsas alarmas si la métrica fue un conteo binario de ventanas; se debe reportar intervalo binomial y dependencia entre ventanas. El promedio PIT próximo a 0.5 no demuestra uniformidad: se requieren cuantiles/histograma y pruebas calibradas por trayectoria.

11.3 Claims matemáticos admisibles y expresiones que se retiran

ID	Claim admisible	Condición / límite
C01	Reconstrucción funcional lineal exacta.	$\ker O \subseteq \ker L$; entradas conocidas o nuisance incorporado. No se infiere de RMSE bajo.
C02	Identificabilidad funcional no lineal local.	Rango constante e inclusión en un entorno de una variedad regular; no un único Jacobiano nominal.
C03	Información proyectada del evento.	Nuisance determinista libre. Fisher cero es invisibilidad de primer orden, no imposibilidad no lineal.
C04	Información tras marginalizar nuisance.	Prior propio y covarianzas declaradas. $N(a)$ obliga a considerar información de covarianza.
C05	Preevento reduce incertidumbre/eleva información.	Mismo modelo correcto, condicionamiento conjunto y correlación pre/post tratada.
C06	Curvatura relativa separa eventos tangencialmente ocultos.	Chart regular, mínimo local, $\kappa_g \neq 0$; aplicación IEEE-39 pendiente.
C07	Escala de separación por orden de contacto.	Réplicas gaussianas independientes y condiciones locales; alcanzabilidad general de DAE no probada.
C08	Kron de bajo rango.	Identidad conocida; inversas/regímenes válidos y mapa de medición reducido correctamente.
C09	Simetría física implica indistinguibilidad.	Simetría de toda la física, sensores, feedthrough y ley estocástica, no sólo adyacencia.
C10	Fisher multievento identifica amplitudes localmente.	Condicionado al soporte; no garantiza recuperación global del soporte.
C11	ML proyectado preserva evidencia del cociente.	Proyector fijo correcto; garantía aproximada depende del error de subespacio y norma de corrección.
C12	Control secuencial de falsa alarma.	Predictiva nula correcta o envolvente que contiene a cada nulo; no resultado actual de V2.

ID	Claim admisible	Condición / límite
C13	Evidencia estable frente a aproximación de firmas.	Cota uniforme de error en dominio declarado y mismos priors/covarianzas.

Se retiran como afirmaciones generales: “la curvatura siempre distingue eventos”; “rango de frontera es cardinalidad”; “KCL/KVL separan siempre carga y línea”; “source events nunca cambian polos físicos”; “ocho PMU bastan para todo el campo en cualquier régimen”; y “Bayes en sí mismo garantiza calibración”. Sus versiones condicionadas o contraejemplos permanecen en esta monografía.

11.4 Novedad: qué se reconoce y qué se propone investigar

Los antecedentes más cercanos impiden centrar la novedad sólo en DAE, MHE, Fisher, grafos o Bayes. Katanic, Lygeros y Hug proponen estimación conjunta de red/generadores y un estimador recursivo con modelos DAE incompletos [6, 7]. Anguluri, Sankar y Kosut tratan entradas dispersas y estado inicial desconocido [8]. Jamei y colaboradores analizan límites de localización con PMU insuficientes para observabilidad total [10]. Dörfler y Bullo derivan sensibilidad de Kron [4]; Montanari y colaboradores desarrollan observabilidad funcional no lineal [5]. Un preprint de 2026 aborda inferencia bayesiana conjunta de parámetros de generadores y red en DAE [20].

Propuesta de contribución específica, no certificado de prioridad

Una inferencia sparse-PMU que use el posterior preevento de incertidumbre física, clasifique el *orden de contacto* entre eventos y explicaciones normales, y conserve curvatura, error numérico e incertidumbre de soporte en la reconstrucción y localización. El mérito depende de demostrar utilidad nueva en power systems y contrastar antecedentes, no de renombrar identidades clásicas.

Los tres resultados [DER] con mayor valor de integración son: la curvatura relativa de la sección 7; el condicionamiento preevento con ruido correlacionado de la sección 6; y la cota de estabilidad de evidencia bajo errores físicos/surrogates de la sección 10. Sus ingredientes abstractos no se reivindican como nuevos. La combinación permite una pregunta operacional concreta: *cuándo una firma débil requiere más historia, más sensores, más orden físico o simplemente mejor control del error numérico*.

11.5 Experimentos que falsarían la propuesta

Gate	Experimento mínimo	Evidencia que se exigiría
G-T1	N físico de preevento y firmas d_g .	Sensibilidades de condiciones iniciales/operación/parámetros verificadas. Medir norma proyectada y su cota de error, no sólo singular values.
G-T2	Curvatura relativa para candidatos casi tangentes.	Estimar $H_0[v, v]$ con perturbaciones normales y q_g con eventos, splits separados. Contrastar distancia perfilada $\propto a^4$ frente a explicación alternativa.
G-T3	Preevento de duración creciente.	Comparar información predictiva, FPR y localización con el mismo postevento. Controlar ruido correlacionado y no entregar parámetros verdaderos.
G-T4	Visibilidad por MW y por porcentaje.	Mostrar qué cambios de ranking proceden del tamaño de carga y cuáles del grafo/sensores.
G-T5	Diccionario $D_h, D_{h/2}, D_R$.	Evaluar eventos más débiles con tolerancias TDS refinadas; separar truncamiento físico de error de derivada.
G-T6	Multi-evento y nuisance juntos.	$M = 0/1/2$, signos mixtos, intensidades desiguales, falsos splits/merges, covarianza total entre soportes.

Gate	Experimento mínimo	Evidencia que se exigiría
G-T7	Onset no revelado.	Ventanas pre/post reales, posterior sobre τ , falsas alarmas por tiempo y delay, no sólo por ventana.
G-T8	Nuisance aprendido frente a físico.	Dataset preevento independiente, cota de subespacio, comparación con ML no restringido y tasa de borrado de evidencia.
G-T9	Transferencia de planta y datos.	Mantener método congelado al pasar a otra parametrización/simulador y luego RAW. Confirmar CT, polaridad, fases y filtros PMU.

Ningún resultado positivo debe producirse a fuerza de añadir estados o aumentar el número de simulaciones idénticas. Las réplicas de ruido miden variabilidad condicional; plantas/puntos de operación independientes miden otra dimensión de generalización.

11.6 Arquitectura operativa propuesta, paso a paso

1. **Construir la física.** Cargar tablas/versiones, bases, PV/PQ/slack, primitivas y dispositivos; comprobar equilibrio y orden de variables. Mantener DAE y mapa PMU explícitos.
2. **Aprender sólo la incertidumbre normal autorizada.** Con datos preevento/CAL, estimar un prior propio sobre nuisance y la ley de sensor. Fijar el protocolo de actualización, evitando contaminación por el evento.
3. **Generar operadores físicos certificados localmente.** Obtener d_g, q_g, N, H_0 por derivadas nativas o FD controlado, registrar unidades y error. Usar la tangente sólo en su rango validado.
4. **Evaluar información y orden.** Computar información marginal/proyectada, curvatura relativa y firmas degeneradas. Reportar regiones no identificables; no normalizar columnas de norma nula.
5. **Inferir de forma recursiva.** Actualizar estados y nuisance con factores DAE; para soportes competidores integrar severidades y conservar normalización. Recuperar Kalman en el caso lineal.
6. **Devolver incertidumbre total.** Mezclar por soporte, centro y parámetros; producir probabilidades de evento, inclusión, severidad y campo oculto. Abstenerse o agrupar fuentes cuando corresponda.
7. **Actualizar sólo con evidencia permitida.** No ajustar priors/thresholds con TEST. Cuando el modelo sea rechazado, distinguir desconocido, error de sensor y mismatch, sin forzar un bus.

11.7 Instrucciones para redactar el artículo desde esta monografía

No trasladar todos los capítulos a un solo paper. Un artículo necesita una pregunta central y pocas contribuciones verificadas. Una narrativa plausible es: *el orden de distinguibilidad física bajo incertidumbre preevento gobierna los límites y la calibración de la inferencia con PMU dispersas*. Sus resultados pueden apoyarse en la tangente/curvatura y posterior V2 ya reportados, pero los teoremas de orden relativo requieren sus experimentos propios.

En el repositorio de manuscrito, construir CLAIMS.md con ID de teorema, hipótesis, cita previa y artefacto experimental; EVIDENCE.csv con split, semillas, unidades, commit y hash; y PENDING.md para resultados aún no ejecutados. No incrustar números de conversación sin verificar su archivo. Las derivaciones conocidas se citan; las contribuciones propuestas se presentan como tales hasta una revisión bibliográfica dedicada. No inventar que la variante es distribuida, que se resolvió la DAE completa o que existe validación IBR/RAW.

El apéndice siguiente suministra comprobaciones matemáticas ejecutables. Son una protección contra errores algebraicos, no una sustitución del control de versiones ni una demostración empírica del estimador final.

A Derivadas eléctricas explícitas y unidades

Este apéndice permite implementar los factores sin diferenciar numéricamente todo el simulador. Las fórmulas son analíticas para el circuito especificado; su traducción a cada componente y base debe conservar los índices del modelo.

A.1 Jacobiano polar de potencia

Para $Y = G + jB$, $V_i = v_i e^{j\theta_i}$ y $\theta_{ij} = \theta_i - \theta_j$,

$$P_i = \sum_j v_i v_j (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij}), \quad (\text{A.1})$$

$$Q_i = \sum_j v_i v_j (G_{ij} \sin \theta_{ij} - B_{ij} \cos \theta_{ij}). \quad (\text{A.2})$$

Si $j \neq i$, diferenciando término a término se obtiene

$$\partial_{\theta_j} P_i = v_i v_j (G_{ij} \sin \theta_{ij} - B_{ij} \cos \theta_{ij}), \quad (\text{A.3})$$

$$\partial_{\theta_j} Q_i = -v_i v_j (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij}), \quad (\text{A.4})$$

$$\partial_{v_j} P_i = v_i (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij}), \quad (\text{A.5})$$

$$\partial_{v_j} Q_i = v_i (G_{ij} \sin \theta_{ij} - B_{ij} \cos \theta_{ij}). \quad (\text{A.6})$$

Los términos diagonales son

$$\partial_{\theta_i} P_i = -Q_i - B_{ii} v_i^2, \quad \partial_{\theta_i} Q_i = P_i - G_{ii} v_i^2, \quad (\text{A.7})$$

$$\partial_{v_i} P_i = P_i / v_i + G_{ii} v_i, \quad \partial_{v_i} Q_i = Q_i / v_i - B_{ii} v_i. \quad (\text{A.8})$$

Estas expresiones presuponen $v_i > 0$. Para $\rho_i = \log v_i$, la regla de la cadena da $\partial_{\rho_i} = v_i \partial_{v_i}$. En un residual de balance debe restarse también la derivada de las cargas ZIP, los controles y las inyecciones que dependan del estado. Diferenciar solamente la potencia de red no produce el Jacobiano DAE completo.

A.2 Derivadas direccionales complejas de primer y segundo orden

Para $S(V, Y) = \text{diag}(V) \overline{YV}$, variaciones arbitrarias $\delta V, \delta Y$ satisfacen

$$\delta S = \text{diag}(\delta V) \overline{YV} + \text{diag}(V) \overline{Y \delta V} + \delta Y V. \quad (\text{A.9})$$

A Y fijo, el segundo diferencial bilineal es

$$D_{VV}^2 S[u, v] = \text{diag}(u) \overline{Yv} + \text{diag}(v) \overline{Yu}. \quad (\text{A.10})$$

En particular, $D_{VV}^2 S[u, u] = 2 \text{diag}(u) \overline{Yu}$. El diferencial mixto en V, Y es

$$D_{VY}^2 S[u, \Delta Y] = \text{diag}(u) \overline{\Delta Y V} + \text{diag}(V) \overline{\Delta Y u}. \quad (\text{A.11})$$

Demostración. Escriba $S(V + tu, Y) = S(V, Y) + t[\text{diag}(u) \overline{YV} + \text{diag}(V) \overline{Yu}] + t^2 \text{diag}(u) \overline{Yu}$. El coeficiente de t es la primera derivada y el doble del coeficiente de t^2 es la segunda. Para dos direcciones u, v , el coeficiente mixto ts da la fórmula bilineal. Sustituir $Y + s\Delta Y$ en la primera derivada y tomar el coeficiente de s produce el diferencial mixto. Se trata de diferenciación real de una función compleja, no de holomorfía en V . $\square$

A.3 La incertidumbre de magnitud y ángulo

En un bus, sea $u = (V_R, V_I)^\top$ y $v = \sqrt{V_R^2 + V_I^2} > 0$. El Jacobiano local del cambio de coordenadas es

$$J_{v,\theta} = \begin{bmatrix} V_R/v & V_I/v \\ -V_I/v^2 & V_R/v^2 \end{bmatrix}. \quad (\text{A.12})$$

La aproximación delta da $P_{v,\theta} \simeq J_{v,\theta} P_{RI} J_{v,\theta}^\top$. Cerca de voltaje cero la transformación angular es singular: se informa incertidumbre cartesiana, no una banda angular artificialmente estrecha. El error angular se envuelve mediante $\text{atan2}(\sin \Delta\theta, \cos \Delta\theta)$ antes de expresarlo en grados.

B Comprobaciones algebraicas ejecutadas y reproducibilidad

Alcance exacto

Se ejecutaron **27 comprobaciones numéricas, 27 satisfactorias**, del código adjunto. Son identidades de álgebra lineal, ejemplos analíticos y sistemas pequeños de referencia. **No son simulaciones IEEE-39, no reproducen las campañas de Luna y no certifican novedad ni validez industrial.** Las demostraciones del cuerpo son el soporte matemático; estas pruebas verifican implementaciones y contraejemplos concretos.

El archivo `checks/verify_mathematics.py` usa semilla 20260913. Entorno de esta ejecución: Python 3.13.5, NumPy 2.3.5, SciPy 1.17.0. Los errores son absolutos o relativos según la identidad; el JSON describe el significado de cada prueba. Las tolerancias no son tolerancias del simulador eléctrico.

N.º	Comprobación	Error observado	Tolerancia
1	Schur complejo generalizado	4.89×10^{-15}	1.00×10^{-11}
2	Medicion parcial tras Kron	2.79×10^{-16}	1.00×10^{-12}
3	Potencia pasiva con tap	7.22×10^{-16}	1.00×10^{-11}
4	Woodbury nuisance	9.13×10^{-16}	1.00×10^{-12}
5	Limite a nuisance libre	2.59×10^{-8}	1.00×10^{-6}
6	Contraejemplo informacion Bayes	0	1.00×10^{-14}
7	Preevento correlacionado	3.15×10^{-16}	1.00×10^{-12}
8	OU con precision de grafo	4.37×10^{-15}	1.00×10^{-12}
9	Hodge corte-ciclo	3.14×10^{-16}	1.00×10^{-12}
10	Reconstruccion funcional	8.16×10^{-16}	1.00×10^{-12}
11	Covarianza KKT restringida	4.81×10^{-16}	1.00×10^{-12}
12	Schur con evidencia completa	8.88×10^{-16}	1.00×10^{-12}
13	Curvatura mixta sin factor medio	2.88×10^{-14}	1.00×10^{-10}
14	Contacto relativo de orden dos	4.73×10^{-6}	1.00×10^{-3}
15	Signo de tercer orden	4.14×10^{-25}	1.00×10^{-20}
16	Curvatura compleja no paralela real	0	1.00×10^{-14}
17	Cobertura por curvatura omitida	1.10×10^{-3}	3.00×10^{-3}
18	Varianza de mezcla de soportes	8.88×10^{-16}	1.00×10^{-14}
19	Aprendizaje proyectado aproximado	6.94×10^{-18}	1.00×10^{-12}
20	No doble conteo de features	4.44×10^{-16}	1.00×10^{-10}
21	Transferencia descriptor/reducida	2.05×10^{-16}	1.00×10^{-12}
22	Kalman RTS versus MAP gaussiano batch	4.48×10^{-15}	1.00×10^{-10}
23	Richardson de orden cuatro	1.89×10^{-3}	5.00×10^{-2}
24	Equivalencia source/operator	4.62×10^{-15}	1.00×10^{-12}
25	Cota loglikelihood por error fisico	0	1.00×10^{-14}
26	Consistencia Ito algebraica	5.55×10^{-17}	1.00×10^{-14}
27	Simetria fisica sensor-preservadora	1.67×10^{-16}	1.00×10^{-12}

En el ejemplo de contacto con nuisance curvo, la pendiente ajustada de la distancia *cuadrada* fue 3.9999953, frente a cuatro. En el ejemplo de curvatura omitida, la cobertura exacta predicha fue 0.6403775 y la estimada con 200 000 muestras gaussianas fue 0.64148. Ninguno de esos números utiliza datos de PMU del usuario.

B.1 Cómo reproducir las comprobaciones

Desde la raíz del paquete de fuentes:

```
python -m pip install numpy scipy
python checks/verify_mathematics.py --output-dir checks/output
```

El script termina con código no nulo si falla una comprobación y escribe `verification_results.json`, `verification_results.csv` y `contact_order.csv`. El JSON conserva versiones, semilla, error, tolerancia, estado y significado. Repetir con otras versiones puede cambiar los últimos decimales; una divergencia material debe investigarse, no ocultarse elevando tolerancias.

Para compilar la monografía desde `src/`:

```
latexmk -pdf -interaction=nonstopmode -halt-on-error main.tex
```

También son válidas tres ejecuciones consecutivas de `pdflatex`. La bibliografía del PDF está en `references.tex`; el archivo `references.bib` se adjunta como base editable para el manuscrito. El paquete no incluye archivos de fuentes tipográficas, dependencias del sistema ni material bibliográfico de terceros.

B.2 Qué faltaría para una comprobación física reproducible

El ejecutor debe exportar, por caso, el identificador de planta, checksum de parámetros, estado inicial, semántica del evento, trayectorias sin ruido, realizaciones de ruido y operadores de observación. Cada matriz reducida necesita su mapa hacia coordenadas físicas y unidades. Los resultados agrupados deben poder recalcularse desde CSV/Parquet, no desde este texto.

Los priors deben registrarse antes del TEST; las realizaciones de ruido de una misma trayectoria no se tratan como nuevas plantas independientes. Para un análisis por bus o fuente se conserva el agrupamiento de trayectorias y se reportan intervalos acordes con esa dependencia. Un test que sólo verifica dimensiones o archivos existentes no sustituye una prueba de residual, sensibilidad o recuperación.

B.3 Integridad del material recibido

Los siguientes hashes identifican los documentos locales que sirvieron de contexto, no el repositorio remoto del proyecto. El dossier maestro anterior marcaba V2 pendiente; las cifras V2 del cuerpo provienen del reporte posterior de la conversación. **Se ha pegado el markdown(4).md**

SHA256: [70274660424d876b6026fa2579ade4c6fdf1e574d8eb154e99aa3d334bfc09c](#)

PMU_Hybrid_DAE_Master_Paper_Dossier_2026-09-13.pdf

SHA256: [363202eb64882d08b46d2fd8c75f66299aaf13f90d0dcbfde7fef3482f7891a7](#)

PMU_Hybrid_DAE_Bayesian_Mega_Theory.pdf

SHA256: [3c9e9a5720f33429cba8fcf5cb619205ea65a62a3a7da0d64485e545b1cb6a43](#)

Fuentes internas y bibliografía verificada

[P1] Dossier del usuario. *Se ha pegado el markdown(4).md.* Inventario de modelos, ecuaciones, resultados reportados y teoremas candidatos adjunto en esta conversación. Se conserva como fuente de propuestas, no como demostración independiente.

[P2] Auditoría matemática del proyecto. Revisión posterior en esta conversación: correcciones sobre DAE, mediciones de frontera, identificabilidad local, nuisance determinista/probabilístico, Kron, complejidad, ruido y segundo orden. Las demostraciones de esta monografía formalizan esa revisión y añaden derivaciones identificadas como [DER].

[P3] Reportes experimentales comunicados por el usuario. Secuencias E04-A, E06 y LOAD-BAYES-FD-V1/V2, con cifras y commits citados en el cuerpo. No se inspeccionaron sus CSV ni se ejecutó el repositorio para esta entrega. Se requiere su auditoría antes del envío del paper.

Criterio bibliográfico. Las siguientes son fuentes primarias o documentación oficial, verificadas en la consulta del 13 de septiembre de 2026. Se cita la versión preprint cuando no se ha consolidado la ficha editorial. La presencia de una fuente cercana no resuelve por sí sola la novedad de la propuesta integrada; impide reivindicar como nuevos resultados ya conocidos.

Referencias

- [1] JuliaEnergy, *PowerDynamics.jl: IEEE 39-Bus System, Part I — Modeling*, documentación oficial. https://juliaenergy.github.io/PowerDynamics.jl/stable/generated/ieee39_part1/. El sitio documenta el modelo actual; el experimento exige además el Manifest y hashes de la versión efectivamente congelada.
- [2] MATPOWER, *makeYbus: bus admittance matrix and branch admittance matrices*, documentación oficial, versión 7.0. <https://matpower.org/docs/ref/matpower7.0/lib/makeYbus.html>.
- [3] P. W. Sauer y M. A. Pai, *Power System Dynamics and Stability*. Prentice Hall, 1998. Manuscrito de autores actualizado disponible en el curso ECE576 de University of Illinois. <https://courses.physics.illinois.edu/ece576/sp2018/Sauer%20and%20Pai%20book%20-%20Jan%202007.pdf>.
- [4] F. Dörfler y F. Bullo, “Kron reduction of graphs with applications to electrical networks,” *IEEE Transactions on Circuits and Systems I: Regular Papers*, vol. 60, n.º 1, pp. 150–163, 2013. DOI: 10.1109/TCSI.2012.2215780. Preprint: <https://arxiv.org/abs/1102.2950>.
- [5] A. N. Montanari, L. Freitas, D. Proverbio y J. Gonçalves, “Functional observability and subspace reconstruction in nonlinear systems,” *Physical Review Research*, vol. 4, art. 043195, 2022. DOI: 10.1103/PhysRevResearch.4.043195. <https://arxiv.org/abs/2301.04108>.
- [6] M. Katanic, J. Lygeros y G. Hug, “Moving-horizon state estimation for power networks and synchronous generators,” preprint, 2022. <https://arxiv.org/abs/2207.12150>.
- [7] M. Katanic, J. Lygeros y G. Hug, “Recursive dynamic state estimation for power systems with an incomplete nonlinear DAE model,” preprint, 2023. <https://arxiv.org/abs/2305.10065>.
- [8] R. Anguluri, L. Sankar y O. Kosut, “Localization and estimation of unknown forced inputs: A group LASSO approach,” preprint, 2022. <https://arxiv.org/abs/2201.07907>.
- [9] F. Pasqualetti, F. Dörfler y F. Bullo, “Attack detection and identification in cyber-physical systems,” *IEEE Transactions on Automatic Control*, vol. 58, n.º 11, pp. 2715–2729, 2013. DOI: 10.1109/TAC.2013.2266831. Versión de autores: <https://arxiv.org/abs/1202.6144>.
- [10] M. Jamei, R. Ramakrishna, T. Tesfay, R. Gentz, C. Roberts, A. Scaglione y S. Peisert, “Phasor measurement units optimal placement and performance limits for fault localization,” *IEEE Transactions on Power Systems*, 2020; registro del proyecto publicado en 2019. <https://iti.illinois.edu/credc/publications/phasor-measurement-units-optimal-placement-and-performance-limits-fault-localization>.
- [11] E. H. Kennedy, “Semiparametric theory,” preprint, 2017. <https://arxiv.org/abs/1709.06418>.
- [12] A. Rotnitzky, D. R. Cox, M. Bottai y J. Robins, “Likelihood-based inference with singular information matrix,” *Bernoulli*, vol. 6, n.º 2, pp. 243–284, 2000. <https://projecteuclid.org/journals/bernoulli/volume-6/issue-2/Likelihood-based-inference-with-singular-information-matrix/bj/1081788028.pdf>.

- [13] V. Borovitskiy, I. Azangulov, A. Terenin, P. Mostowsky, M. P. Deisenroth y N. Durrande, “Matérn Gaussian processes on graphs,” en *Proceedings of AISTATS*, PMLR, vol. 130, 2021. <https://proceedings.mlr.press/v130/borovitskiy21a.html>.
- [14] S. Särkkä y L. Svensson, *Bayesian Filtering and Smoothing*, segunda edición. Cambridge University Press, 2023. Versión de autores: https://users.aalto.fi/~ssarkka/pub/bfs_book_2023_online.pdf.
- [15] A. M. Stuart, “Inverse problems: A Bayesian perspective,” *Acta Numerica*, vol. 19, pp. 451–559, 2010. DOI: [10.1017/S0962492910000061](https://doi.org/10.1017/S0962492910000061).
- [16] S. R. Howard, A. Ramdas, J. McAuliffe y J. Sekhon, “Time-uniform Chernoff bounds via nonnegative supermartingales,” *Probability Surveys*, vol. 17, 2020. DOI: [10.1214/18-PS321](https://doi.org/10.1214/18-PS321). <https://arxiv.org/abs/1808.03204>.
- [17] F. R. Kschischang, B. J. Frey y H.-A. Loeliger, “Factor graphs and the sum-product algorithm,” *IEEE Transactions on Information Theory*, vol. 47, n.º 2, pp. 498–519, 2001. DOI: [10.1109/18.910572](https://doi.org/10.1109/18.910572).
- [18] D. L. Donoho y M. Elad, “Optimally sparse representation in general (nonorthogonal) dictionaries via ℓ^1 minimization,” *Proceedings of the National Academy of Sciences*, vol. 100, n.º 5, pp. 2197–2202, 2003. DOI: [10.1073/pnas.0437847100](https://doi.org/10.1073/pnas.0437847100).
- [19] A. J. Whalen, S. N. Brennan, T. D. Sauer y S. J. Schiff, “Observability and controllability of nonlinear networks: The role of symmetry,” *Physical Review X*, vol. 5, art. 011005, 2015. DOI: [10.1103/PhysRevX.5.011005](https://doi.org/10.1103/PhysRevX.5.011005).
- [20] A. Alalem Albustami, A. F. Taha y S. Mahadevan, “DAE-aware Bayesian inference for joint generator-network parameter estimation,” preprint, abril de 2026. <https://arxiv.org/abs/2604.15686>. Se cita el preprint fechado, sin atribuir a 2026 una ficha editorial posterior.